Hackathon IA — La Banque Postale × CGI × ENSEIRB-MATMECA — Sujet 1

Un assistant bancaire frugal, explicable, et qui agit

Résumé de la proposition de solution et de la répartition

Yahya (IA) — Sohayb (génie logiciel) — Younes (calcul intensif) — lundi 26 octobre 2026

Version complète, avec annexes (85 intentions, catalogue, parcours, glossaire, commandes) : `rapport/main.pdf`. Ce résumé fait foi là où il en diffère : nous ne traduisons pas Banking77.

L'essentiel

Le problème. Un client écrit à sa banque en langage libre (« Je veux acheter un appartement », « J'ai perdu ma carte »). L'assistant doit comprendre, poser les bonnes questions, tenir compte de sa situation et proposer une piste — avec une IA open source, locale, la plus sobre possible, et dont chaque conseil se justifie.

Notre réponse : une cascade. Chaque étage ne passe la main au suivant que s'il ne sait pas faire lui-même ; le calcul le plus cher n'arrive qu'en dernier, et c'est mesuré.

Étage	Qui fait le travail	Pourquoi
1. Comprendre	Mots-clés, sinon `multilingual-e5-small` (118 M) + régression logistique	Moins d'une milliseconde pour les cas évidents ; mesurable sur le test officiel de Banking77
2. Converser	Parcours YAML : quoi demander, dans quel ordre	On ne redemande jamais ce que le profil sait
3. Conseiller	Règles publiques (plafonds, 35 % d'endettement) + appétence	Une décision financière doit être reproductible et justifiable
4. Agir	Opposition, virement guidé, transmission au conseiller	Toujours après confirmation
5. Formuler	**Le seul appel LLM du tour, à la fin** : `ministral-3:3b` + garde-fou ; gabarits pour les réponses simples	Le LLM met en mots des faits calculés, n'en invente aucun
Escalade	`ministral-3:14b`, seulement si le doute persiste après une question	L'exception, comptée et affichée

Quatre décisions. (1) Comprendre sans LLM ; (2) décider sans LLM, avec les raisons *et* les produits écartés ; (3) un seul appel au plus petit LLM qui suffit, choisi en descendant en taille depuis le 14B ; (4) tout mesurer contre une version « tout LLM ».

À retenir. *L'assistant comprend souvent avec de simples mots-clés, sinon avec 118 millions de paramètres ; il décide avec des règles que le client peut lire ; il n'appelle un LLM qu'une fois, à la fin, pour mettre en mots ce qui est déjà calculé.* Un organisateur nous l'a confirmé : « pour gagner, c'est moins de LLM, plus d'algo ».

1 Le cadre

La règle commune. Open source uniquement, aucune API de LLM externe, données en local ; le plus petit modèle qui suffit, un plus gros seulement si le gain est *mesuré* ; serveur GPU sur site ; mesurer taille (en Go, quantisation comprise), énergie (CodeCarbon) et latence. Utiliser d'autres IA *pour développer* est autorisé. CGI : la frugalité, c'est « surtout » l'énergie ; un gros modèle « à un instant précis », c'est « là que vous allez innover ».

Le sujet 1. Objectifs : comprendre les demandes en langage naturel ; personnaliser selon l'âge, les revenus et l'historique ; recommander un produit bancaire simple. Livrables : **données préparées en français, modèle de compréhension des intentions, chatbot relié à une base clients simulée, moteur de conseils personnalisés, mesures de frugalité**. Démarche attendue : cadrer, préparer, concevoir, démontrer. À l'oral : on peut *agir* (couper la carte) ou seulement guider ; ils veulent notre regard de jeunes clients ; réponse immédiate.

Thème	Message	Profil	Attendu
Carte	« J'ai perdu ma carte hier soir, je fais quoi ? »	Inès, 34 ans	Réagir vite, opposition, rassurer
Frais	« Pourquoi j'ai payé 8 € de frais ce mois-ci ? »	Marc, 52 ans, découverts	Expliquer, orienter
Épargne	« Je voudrais mettre de côté pour mes enfants. »	Sophie, 41 ans	Demander l'horizon
Virement	« Je dois envoyer 500 € à mon fils. »	Paul, 68 ans	Pas à pas, mots simples
Crédit	« Je veux un crédit pour acheter une voiture. »	Karim, 29 ans, 1 900 €	Questionner, prudence
Insatisfaction	« Votre appli ne marche jamais ! »	3e message du jour	Reconnaître, passer la main
Autres	Logement (énoncé), prêt étudiant et jargon (oral)	—	Questionner, expliquer

Le jury. Adrien (CGI), Denis Barthou (ENSEIRB), Jean-Michel (La Banque Postale, à distance). 30 minutes : 15 de présentation **avec démo en direct sur le serveur fourni**, 10 de questions, 5 de retour. Code déposé sur Git et support remis avant.

Pertinence métier	Qualité technique	Frugalité	Explicabilité	Démonstration	Présentation
25 %	**20 %**	**20 %**	**15 %**	**10 %**	**10 %**

Ce que La Banque Postale valorise. Sa priorité IA n° 1 est l'expérience client (chatbot, réclamations, offres personnalisées). Elle insiste sur l'accessibilité, l'inclusion des clients fragiles et la responsabilité. Un Français sur quatre est son client.

Les conseils de l'organisateur. Lors d'un échange lundi à 17h30 : moins de LLM, plus d'algorithmes ou de modèles spécialisés ; en entrée, les mots-clés règlent environ 30 % des cas pour presque rien et peuvent dire quand ils ne sont pas sûrs ; en sortie, un LLM, appelé une seule fois, à la fin ; choisir sa taille en descendant (15B ou 30B, puis 4B, 2B, 1B) ; un seul sujet ; d'abord une solution sûre, ensuite les idées exotiques ; se faire plaisir.

Les moyens. Postes de la salle : RTX 3060 12 Go, Ollama avec `gemma4:e2b` (7,2 Go) et `ministral-3:14b` (9,1 Go). DeepEirb : 2 × A6000 48 Go, SSH et vLLM *sur demande à Denis Barthou.* Jetson et OrangePi dès mardi, pour le déploiement. Un jour et demi de travail.

2 Les données

Banking77. 13 083 questions de clients d'une néobanque britannique, **en anglais**, 77 intentions ; 10 003 en entraînement (35 à 187 par intention), 3 080 en test (40 par intention). Références de l'article : 87,19 % (BERT figé) à 93,66 % (BERT affiné) ; un encodeur figé et un classifieur léger se placent à un ou deux points. **Il couvre le service (carte, frais, virements), pas le conseil** : aucune demande d'épargne, de crédit ou de logement. Il contient aussi un peu de bruit d'étiquetage. Nous rangeons les 77 intentions en 9 familles et créons 8 intentions françaises :

Familles Banking77	carte perdue, usage de la carte, commande de carte, frais et contestations, virements, compte et identité, espèces, change, alimentation du compte
Nouvelles intentions	`epargne_projet`, `credit_immobilier`, `credit_conso`, `pret_etudiant`, `faire_virement`, `question_definition`, `insatisfaction`, `hors_sujet`
Au total	14 familles, 85 intentions ; environ 80 exemples générés hors ligne par intention nouvelle (relus), 20 exemples de test écrits à la main

Pas de traduction de Banking77. C'est notre choix. L'encodeur `multilingual-e5-small` place une phrase et sa traduction très près l'une de l'autre dans l'espace des vecteurs : un classifieur entraîné sur les phrases anglaises reconnaît les mêmes demandes écrites en français. Traduire 13 083 phrases coûterait du temps et de l'énergie, et ajouterait des erreurs de traduction, pour un gain non prouvé. **Ce qui est en français** : le lexique de mots-clés ; les exemples des 8 nouvelles intentions ; 5 phrases par famille Banking77 ajoutées à l'entraînement ; un **test français de 250 phrases écrites à la main** (10 par famille Banking77, 20 par nouvelle intention) ; le glossaire, le catalogue et les libellés des profils. C'est notre livrable « données préparées en français ». L'écart de précision entre le test anglais officiel et notre test français mesure ce que l'encodeur transfère d'une langue à l'autre : un résultat à présenter.

Bank Marketing. 45 211 clients d'une banque portugaise (2008–2010) : âge, métier, situation, études, solde (3 766 négatifs, 8,3 %), crédit immobilier (55,6 %), crédit personnel (16,0 %) ; cible `y` = a souscrit un dépôt à terme (11,7 %). Pas de revenus, d'enfants ni d'historique : on les simule (graine fixe, drapeau `simule=True`, affichés en italique) derrière un adaptateur unique, prêt pour la version enrichie promise par les organisateurs.

> `duration` **est une fuite** : la durée de l'appel n'est connue qu'après l'appel et détermine presque la réponse. On l'exclut (avec `contact`, `day`, `month`). Le dire au jury.

Les 8 clients de démonstration. Ancrés sur des lignes réelles de Bank Marketing : C01 Inès (carte), C02 Marc (frais, découverts), C03 Sophie (épargne, 2 enfants), C04 Paul (68 ans, virement), C05 Karim (1 900 €, crédit en cours), C06 Julie (3 contacts aujourd'hui), C07 Léa (2 900 €, 25 000 € d'épargne, appartement), C08 Lucas (20 ans, étudiant).

Le catalogue. En JSON, une fiche par produit, avec **source publique et date** : Livret A (22 950 €), LDDS (12 000 €), LEP (10 000 €, sous condition de revenu), Livret Jeune (12–25 ans, 1 600 €), PEL (61 200 €), CEL (15 300 €), crédit immobilier, PTZ, prêt personnel, prêt étudiant, offre clientèle fragile, opposition de carte. **Aucun taux en dur** : c'est un paramètre daté du catalogue.

3 La solution

3.1 Étage 1 — Comprendre (cible : moins de 30 ms)

— **Mots-clés d'abord.** Lexique d'expressions par famille (« perdu ma carte », « virement », « appartement »…), cherché dans le message normalisé (minuscules, sans accents). Il ne conclut que s'il est sûr : une seule famille touchée, phrase courte ou plusieurs expressions. Expressions gardées seulement si leur précision dépasse 97 %.

— **Sinon, classifieur à deux niveaux** (14 familles, puis 85 intentions) : `multilingual-e5-small` (préfixe `query:`) + régression logistique scikit-learn, entraînée sur Banking77 en anglais, **sans traduction**, plus nos phrases françaises. Quelques secondes d'entraînement sur CPU ; affiche aussi la phrase d'entraînement la plus proche.

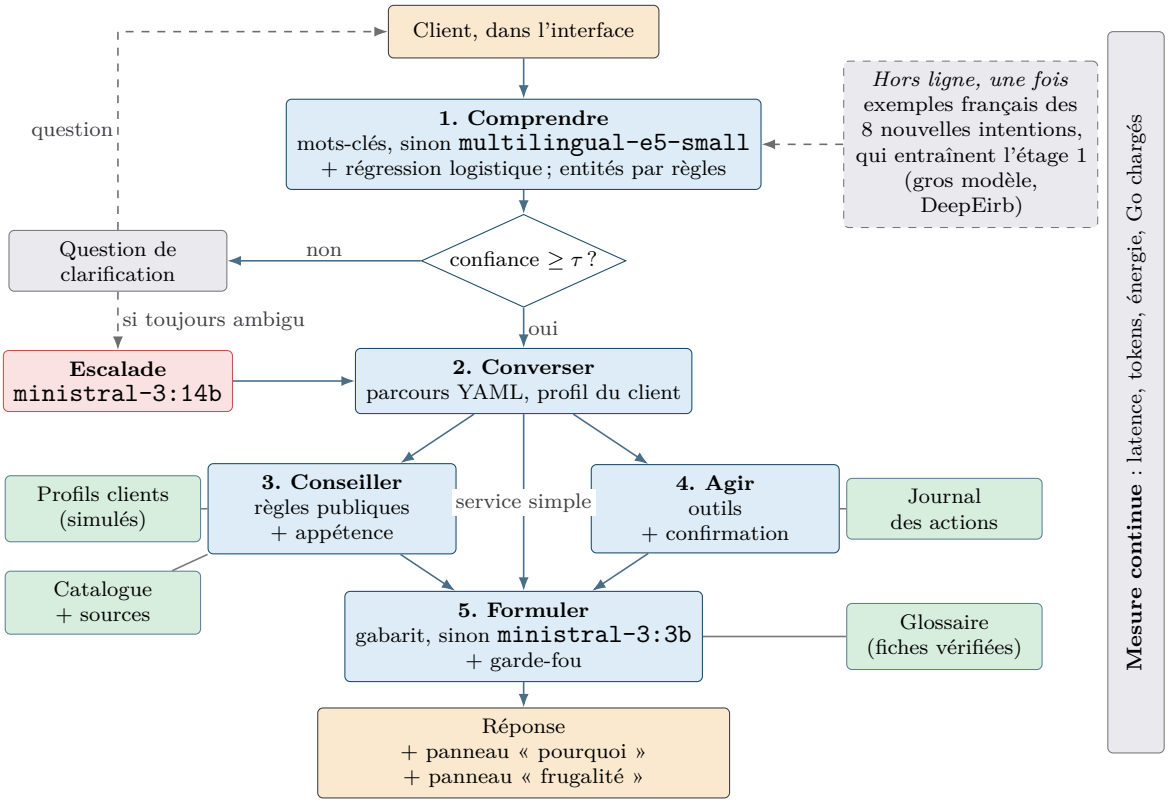


Figure 1 – La cascade. En bleu, sans gros modèle ; en rouge, l'exception comptée.

— **Seuil** τ choisi par balayage (97 % de précision sur les messages acceptés). En dessous : question fermée (« votre carte, ou un virement ? »), puis escalade.

— **Contexte** : si un parcours attend un montant, « 250 000 » est une réponse. **Entités** par expressions régulières (montants, durées, liens, objets, dates) ; ce qui manque est demandé au client, pas deviné par un LLM. **Insatisfaction** : classifieur + nombre de contacts du jour.

3.2 Étage 2 — Converser

Un fichier YAML par parcours : informations nécessaires, source (profil ou question), ordre, fin (conseil, action, passage de main). Un automate déterministe les lit. **On confirme ce que le profil sait au lieu de le demander.** Mode « mots simples » automatique dès 70 ans ou « peu à l'aise en ligne » (phrases courtes, une étape par message). Glossaire : fiches écrites et vérifiées par nous, retrouvées par similarité en mémoire (numpy), sans LLM.

3.3 Étage 3 — Conseiller

Éligibilité (âge, revenu, plafonds), puis pertinence (horizon, objectif), puis classement. Chaque règle a un identifiant et une phrase d'explication : la sortie donne **les propositions avec leurs raisons, et les produits écartés avec la règle qui les écarte**. Appétence épargne : régression logistique sur Bank Marketing, sans `duration`, évaluée en AUC, trois facteurs principaux affichés ; LightGBM seulement si le gain est mesuré. Crédit immobilier (règles HCSF) : $m = 0{,}35 \times R - C$ et capacité $= m \times \frac{1-(1+i)^{-n}}{i}$, durée ≤ 25 ans, taux indicatif daté. Crédit : mention légale obligatoire, aucune promesse, rendez-vous conseiller.

3.4 Étage 4 — Agir

`consulter_profil` et `expliquer_frais` (lecture libre) ; `bloquer_carte`, `preparer_virement` et `transmettre_conseiller` (**après confirmation**, avec trace dans un journal). Le conseiller reçoit un

résumé des faits du parcours.

3.5 Étage 5 — Formuler

Un seul appel LLM par tour, à la fin, après que tout a été compris, décidé et calculé. Gabarits relus pour les réponses simples. Le petit LLM ne reçoit que la consigne, les faits structurés et la question en cours. **Garde-fou** : chaque nombre du texte doit figurer dans les faits, aucune formule interdite (« accordé », « garanti »), longueur bornée ; sinon, le gabarit s'affiche et l'échec est compté.

3.6 Un exemple : l'appartement de Léa

Tour	Ce qui se passe	Par
« Je veux acheter un appartement »	Mots-clés « acheter » + « appartement » : une seule famille, phrase courte ; revenus connus, donc confirmés ; on demande le prix et l'apport	mots-clés, gabarit
« Autour de 250 000, je mets les 25 000 »	Notaire 7,5 % ⇒ besoin 243 750 € ; à 3,5 % sur 25 ans, mensualité ≈ 1 220 €, soit **42,1 % > 35 %** ; prix maximal ≈ 212 000 € ; leviers et rendez-vous ; écarté : prêt sur 30 ans	règles, `ministral-3:3b`

Conformité. Données simulées et traitement local. Le règlement européen sur l'IA classe à haut risque la notation de solvabilité : nous n'en faisons pas, un conseiller décide ; l'utilisateur est informé qu'il parle à une IA. Rappel anti-arnaque : aucun code ne se communique.

4 Modèles et technologies

Rôle	Modèle	Taille	Où
Filtre d'entrée	Lexique de mots-clés	quelques Ko	CPU
Encodeur	`multilingual-e5-small` (118 M)	≈ 0,47 Go	CPU ou GPU
Têtes famille + intention	Régression logistique (≈ 38 000 poids)	< 1 Mo	CPU
Formulation	`ministral-3:3b` Q4_K_M (hypothèse)	3,0 Go	RTX 3060
Escalade	`ministral-3:14b` Q4_K_M	9,1 Go	DeepEirb (vLLM) ou 8B en local
Appétence	Régression logistique	< 1 Mo	CPU
Exemples des 8 intentions	`ministral-3:14b` via vLLM, relus à la main	—	DeepEirb, une fois

Choisir le LLM en descendant. Référence `ministral-3:14b` (ou un 30B sur DeepEirb), puis `gemma4:e2b` (7,2 Go), `ministral-3:8b` (6,0), `ministral-3:3b` (3,0), `qwen3:1.7b` (1,4, réflexion coupée), `gemma3:1b` (0,8), `qwen3:0.6b` (0,5), `gemma3:270m` (0,3). Seuil fixé avant : zéro nombre inventé et 27 réponses sur 30 jugées bonnes. **On garde le plus petit qui tient le seuil** ; la courbe qualité–taille–énergie va dans le support.

Brique	Technologie
Langage, environnement	Python 3, `venv`, Git (branches courtes)
Compréhension	`sentence-transformers`, `scikit-learn`, numpy, expressions régulières
Dialogue	PyYAML (parcours), automate maison
LLM	Ollama (API `/api/chat`, `num_ctx` 4 096, température 0,2, 200 tokens max, `keep_alive`), vLLM sur DeepEirb (API compatible OpenAI)
Données	pandas (DuckDB si besoin), JSON pour catalogue et glossaire, CSV pour les clients
Interface	Streamlit : conversation, profil, panneaux « pourquoi » et « frugalité », mode mots simples, taille du texte
Mesure	CodeCarbon (`OfflineEmissionsTracker`, pays FRA), NVML / `nvidia-smi`, `tegrastats` sur Jetson
Tests	pytest pour les règles ; rejeu YAML des 30 scénarios

Mémoire. Le 3B et le 14B ne tiennent pas ensemble dans 12 Go : escalade sur DeepEirb, ou 8B en local, ou un seul modèle chargé à la fois.

5 Évaluer et mesurer

— **Compréhension**, sur deux jeux : le test officiel Banking77 en anglais (3 080, comparable à l'article) et notre test français écrit à la main (250) ; leur écart mesure le transfert de l'anglais au français. Précision et F1 macro, par intention et par famille ; part acceptée par les mots-clés (l'organisateur l'estime à 30 %). Comparé : mots-clés, TF-IDF, MiniLM, e5-small, e5-base, et deux LLM qui classent seuls (1.7B, 14B).

— **Scénarios** : 30 conversations YAML (9 parcours × 3 variantes + 3 hors périmètre). Vérifiés : famille, questions posées *et interdites*, produits proposés et écartés, action, passage de main, aucun nombre inventé. Un scénario qui casse bloque la fusion.

— **Frugalité** : répartition par niveau (mots-clés, classifieur, escalade), part sans LLM, latence p50/p95, Go chargés, énergie par requête.

	Configuration	Réussite	Wh / 1 000 req.	Latence p95	Go	Sans LLM
A	Tout LLM : `ministral-3:14b` fait tout	*à mesurer*	*à mesurer*	*à mesurer*	9,1	0 %
B	**Notre cascade**	*à mesurer*	*à mesurer*	*à mesurer*	3,5	*à mesurer*
C	Cascade, gabarits seuls	*à mesurer*	*à mesurer*	*à mesurer*	0,5	100 %

Énergie : CodeCarbon hors ligne, par lots de 200 requêtes, après chauffe, puissance de repos (60 s) soustraite, trois répétitions : $(E - P_0 t)/N$ par requête. Le coût de la préparation hors ligne est donné à part.

6 La démonstration (6 minutes)

Temps	Scène	Ce que le jury voit	Critère
0 min	Inès, carte perdue	Confirmation, opposition, référence ; compris par mots-clés, aucun LLM	Métier, frugalité
1 min	Léa, appartement	Revenus non redemandés ; refus chiffré ; pourquoi et pourquoi pas	Explicabilité
2 min 30	Sophie puis Lucas	Même phrase, deux clients, deux conseils	Personnalisation
3 min 30	Marc, 8 € de frais	Historique, plafond légal, offre clientèle fragile	Inclusion
4 min 30	Julie, mécontente	Excuses, passage de main avec résumé	Métier
5 min 15	Bilan	Panneau frugalité cumulé ; graphique A/B/C	Frugalité

Secours : vidéo enregistrée mercredi matin, mode gabarits, vérification réelle d'Ollama, modèles préchargés, messages de démo cliquables, répétition sur la machine de démo.

7 L'organisation

Principes. Un module, un responsable, un suppléant. Contrats figés lundi soir, bouchons pour avancer sans attendre. `main` tourne toujours. Deux intégrations mardi (12h30, 18h), jugées par les scénarios. D'abord une solution sûre (jusqu'à J2), ensuite les idées exotiques.

	M1 — Comprendre et mesurer	**M2 — Converser et formuler**	**M3 — Conseiller et agir**
Responsable	**Younes** (suppléant Yahya)	**Yahya** (suppléant Sohayb)	**Sohayb** (suppléant Younes)
Données	Test français écrit à la main ; 8 intentions ; fiche de données	Glossaire, gabarits	8 clients simulés ; catalogue
Modèle	Mots-clés ; encodeur et têtes ; seuil τ	Choix du LLM en descendant ; garde-fou ; escalade	Appétence (AUC)
Logiciel	`comprendre()` ; instrumentation ; bancs NLU et A/B/C ; Jetson (bonus)	`reply()` ; automate et 9 parcours ; interface Streamlit ; vidéo de secours	Moteur de règles et calculs ; 5 outils ; rejeu des scénarios ; dépôt Git final
Fichiers	`src/comprendre/`, `src/mesure/`, `eval/bench_*.py`	`src/assistant.py`, `src/converser/`, `app.py`	`src/conseiller/`, `eval/run_scenarios.py`, `tests/`
Dans le pitch	Résultats et frugalité	Problème, architecture, démo	Explicabilité et conformité

Chacun écrit au moins dix scénarios et la diapositive de son module. Le découpage suit la cascade, pas les filières : chaque module a une part données, une part modèle et une part logiciel.

Le contrat commun. Sohayb l'a posé dans `src/contrats.py` (commit du lundi 18h23), avec le squelette de `reply()` et de l'interface. À relire ensemble ce soir, puis à figer :

```
Comprehension(famille, intention, confiance, alternatives, entites, insatisfaction,
              modele, exemple_proche)                                    # M1
Conseil(propositions=[Proposition(produit_id, raisons, sources, score)],
        ecartees, manque, alertes, faits)                                 # M3
Action(outil, parametres, confirmee, resultat)                            # M3
Etape(nom, modele, latence_ms, tokens)                                    # M1
Reponse(texte, comprehension, conseil, action, escalade, trace=[Etape])   # M2
EtatConversation(intention, slots, derniere_reponse, historique, action_en_attente)
reply(message, client_id, etat) -> (Reponse, EtatConversation)   # point d'entree, M2
```

Le dépôt. `app.py` ; `src/` (`contrats.py`, `assistant.py`, `comprendre/`, `converser/`, `conseiller/`, `mesure/`) ; `data/raw/` (données téléchargées, versionnées) et `data/processed/` (versionné : c'est un livrable) ; `eval/` (scénarios, bancs) ; `tests/`.

	Lundi 18h–20h	Mardi 8h30–12h30	Mardi 13h30–18h	Mardi soir (option)	Mercredi 8h30–12h
Younes	Accès DeepEirb ; lancer la génération des 8 intentions	Mots-clés ; têtes v1 ; entités ; `comprendre()`	Test français ; 8 intentions ; τ ; escalade ; instrumentation	Banc A/B/C	Chiffres finaux ; graphique ; Jetson
Yahya	Parcours carte sur le squelette	Automate ; carte et frais ; gabarits ; LLM branché	Épargne, crédits, virement, insatisfaction ; garde-fou ; panneaux	Scénarios en échec	Vidéo de secours ; finitions
Sohayb	8 clients ; catalogue v0	`clients.py` ; règles épargne et crédit ; opposition ; frais	Appétence ; écartés ; virement ; conseiller ; scénarios	Scénarios en échec	Dépôt Git final ; README
Tous	Relire et figer le socle de Sohayb	Test français : environ 85 phrases chacun			Diapositives ; 2 répétitions
Jalon	**J0** 20h : `app.py` répond	**J1** 12h30 : Inès et Marc de bout en bout	**J2** 18h : 9 parcours, **gel**	—	**J3** 11h30 : code, vidéo, support remis

Tableau 1 – Le planning.

Priorités. **Indispensable à J2** : étage 1 mesuré ; parcours carte, frais, épargne, appartement, crédit auto ; règles avec raisons et écartés ; 8 clients ; LLM et garde-fou ; panneaux ; banc A/B/C. **Important** : virement en mots simples, insatisfaction, jargon, prêt étudiant, appétence, escalade. **Si le temps le permet** : idées exotiques, Jetson, langue du client, MCP, voix locale. **Hors périmètre** : affinage de LLM, vrai SI bancaire.

Règles. Branches `m1/`, `m2/`, `m3/` fusionnées dans la demi-journée après relecture du suppléant ; ni données brutes ni secrets dans Git ; point de cinq minutes toutes les trois heures ; chaque chiffre noté avec sa commande. « **Fini** » = dans `main`, scénarios verts, mesures notées, diapositive écrite.

8 Les risques principaux

Risque	Parade	Qui
DeepEirb inaccessible lundi soir	Exemples des 8 intentions générés par `ministral-3:14b` sur un poste de la salle ; escalade en 8B local	M1
Transfert anglais → français insuffisant	Plus de phrases françaises écrites à la main dans l'entraînement ; les mots-clés en premier ; écart mesuré et présenté	M1
Petit LLM faible en français	Gabarits ; la descente s'arrête plus haut (8B) si mesuré	M2
Mots-clés trop sûrs d'eux	Précision $\geq 97\,\%$ par expression ; une seule famille ; sinon classifieur	M1
Base enrichie en retard	Simulation dès lundi ; un seul adaptateur à changer	M3
Intégration tardive	Contrats J0, bouchons, deux intégrations datées	Tous
Démo qui plante	Vidéo, mode gabarits, vérification d'Ollama, répétition sur place	M2
Le temps	**Priorités figées ; gel à J2 ; on coupe sans débat**	Tous

9 Le pitch (15 minutes)

Temps	Partie	Contenu	Qui
0 min	Le problème	Client, priorité de La Banque Postale, règle commune	Yahya
1 min 30	La démarche	Quatre temps, constat Banking77, la cascade	Yahya
4 min	La démo	Le script ci-dessus	Yahya pilote, Sohayb commente
10 min	Les résultats	Tests anglais et français, scénarios, A/B/C, coût de la préparation	Younes
12 min 30	L'explicabilité	Pourquoi et pourquoi pas, garde-fou, conformité	Sohayb
14 min	Limites et suite	Ce qui est simulé ; passer à 17 000 bureaux	Younes

Questions attendues. *Pourquoi pas tout en LLM ?* Mesuré : A contre B. *L'énergie ?* CodeCarbon par lots, repos soustrait. *Si le classifieur se trompe ?* Seuil, question, escalade ; courbe à l'appui. *Le LLM invente un taux ?* Il ne reçoit que des faits, et chaque nombre est contrôlé. *Pourquoi Ministral ?* Le plus petit qui tient le seuil en descendant, et européen. *Pourquoi ne pas traduire Banking77 ?* L'encodeur est multilingue : on mesure le transfert au lieu de payer une traduction. *Des mots-clés en 2026 ?* Une part mesurée des demandes pour presque rien, et ils disent quand ils doutent. *Conformité ?* Pas de notation de solvabilité, un conseiller décide, transparence, mention légale.

10 Ce qu'on fait ce soir

Déjà fait : le socle de Sohayb (contrats, `reply()`, interface, tests) est sur GitHub ; les données sont dans `data/raw/`, versionnées.

1. Lire ce résumé ; valider la répartition, puis ne plus y revenir.
2. Relire ensemble `src/contrats.py` et le squelette, puis les figer.
3. Rendre le dépôt GitHub privé.
4. **Younes** : écrire à Denis Barthou (DeepEirb, modèle vLLM) ; lancer la génération des exemples des 8 nouvelles intentions.
5. **Yahya** : brancher le parcours carte et ses gabarits sur le squelette.
6. **Sohayb** : les 8 clients, le catalogue v0, le rejeu des scénarios.
7. En filaire : télécharger `ministral-3:3b`, `qwen3:1.7b`, `gemma3:1b` et `multilingual-e5-small` sur un poste de la salle.
8. Avant de partir, vérifier J0 : `streamlit run app.py` répond.