Hackathon IA

La Banque Postale × CGI × ENSEIRB-MATMECA

Sujet 1 — Assistant bancaire personnalisé

Proposition de solution et feuille de route

Un assistant bancaire frugal, explicable, et qui agit

Comprendre, personnaliser, conseiller
avec le plus petit calcul qui suffit

Yahya Bel Hajjam Intelligence artificielle

Sohayb Génie logiciel

Younes Calcul intensif

Document de travail interne à l'équipe — lundi 26 octobre 2026

Soutenance : mercredi 28 octobre, 13h30

Table des matières

La solution en une page **3**

1 Ce que le hackathon attend **5**
1.1 La règle commune aux deux sujets . . . 5
1.2 Le sujet 1 . . . 5
1.3 Ce que le jury regarde . . . 6
1.4 Ce que La Banque Postale valorise . . . 6
1.5 Les contraintes . . . 7
1.6 Ce qu'un organisateur nous a conseillé . . . 7
1.7 Les exigences, numérotées . . . 8

2 Ce que disent les données **9**
2.1 Banking77 : la compréhension des demandes . . . 9
2.2 Bank Marketing : la base clients . . . 10
2.3 Ce qui manque, et comment on le comble . . . 10
2.4 Le catalogue de produits . . . 11

3 Ce que Timso AI nous apprend **12**
3.1 Les leçons transposables . . . 12
3.2 Ce qu'on ne reprend pas . . . 13

4 La solution **14**
4.1 Le principe : une cascade . . . 14
4.2 Étage 1 — Comprendre . . . 15
4.3 Étage 2 — Converser . . . 16
4.4 Étage 3 — Conseiller . . . 17
4.5 Étage 4 — Agir . . . 18
4.6 Étage 5 — Formuler . . . 18
4.7 Mesurer, en continu . . . 19
4.8 Un exemple complet : l'appartement . . . 19
4.9 Les parcours . . . 19
4.10 Conformité . . . 20

5 Les modèles, et comment on les choisit **21**
5.1 Les modèles retenus . . . 21
5.2 « Le plus petit modèle qui suffit », rendu opérationnel . . . 21
5.3 Le gros modèle, à l'instant précis . . . 22
5.4 La traduction de Banking77 . . . 22
5.5 Ce qu'il faut demander lundi soir . . . 23

6 Évaluer et mesurer **24**
6.1 Ce qu'on mesure . . . 24
6.2 La compréhension . . . 24
6.3 Les scénarios de bout en bout . . . 25
6.4 La formulation . . . 25
6.5 La frugalité : trois configurations . . . 25

6.6 Le protocole de mesure de l'énergie . . . 26

7 L'interface et la démonstration 27
7.1 L'interface . . . 27
7.2 Le script de la démonstration . . . 27
7.3 Le plan de secours . . . 28

8 L'organisation de l'équipe 29
8.1 Les principes . . . 29
8.2 Les trois modules . . . 29
8.2.1 Module 1 — Comprendre et mesurer (Younes) . . . 29
8.2.2 Module 2 — Converser et formuler (Yahya) . . . 30
8.2.3 Module 3 — Conseiller et agir (Sohayb) . . . 30
8.2.4 Ce qui est commun . . . 30
8.3 Les contrats entre modules . . . 30
8.4 L'arborescence du dépôt . . . 31
8.5 Le planning . . . 32
8.6 Les priorités . . . 33
8.7 Les règles de travail . . . 33

9 Les risques et leurs parades 34

10 Vérification : toutes les cases sont remplies 35
10.1 Les exigences . . . 35
10.2 Les livrables du sujet . . . 36
10.3 La démarche en quatre temps . . . 36

11 Comparaison avec la proposition reçue 37
11.1 Ce qu'on garde . . . 37
11.2 Ce qu'on change . . . 37

12 Le pitch, et ce qu'on fait ce soir 39
12.1 Les quinze minutes . . . 39
12.2 Trois messages . . . 39
12.3 Les questions probables du jury . . . 39
12.4 Ce qu'on fait ce soir . . . 40

A Taxonomie des intentions 41

B Le catalogue de produits 42

C Le détail des parcours 44

D Le glossaire 45

E Commandes utiles 46

La solution en une page

Le problème. Un client écrit à sa banque en langage libre : « Je veux acheter un appartement », « J'ai perdu ma carte hier soir », « Pourquoi j'ai payé 8 € de frais ? ». L'assistant doit comprendre, poser les bonnes questions, tenir compte de la situation du client, et proposer une piste — avec une IA open source, locale, la plus sobre possible, et dont chaque conseil se justifie.

Notre réponse : une cascade. Chaque étage ne passe la main au suivant que s'il ne sait pas faire lui-même. Le calcul le plus cher n'est appelé qu'en dernier recours, et c'est mesuré.

Étage	Qui fait le travail	Pourquoi pas un LLM
1. Comprendre	Mots-clés, sinon petit encodeur (118 M de paramètres) et régression logistique	Les cas évidents coûtent moins d'une milliseconde, les autres quelques millisecondes ; tout se mesure sur le jeu de test officiel de Banking77.
2. Converser	Parcours décrits en YAML : quoi demander, dans quel ordre	Les questions à poser se déduisent du profil : on ne demande jamais ce qu'on sait déjà.
3. Conseiller	Règles publiques (plafonds, 35 % d'endettement) et modèle d'appétence	Une décision financière doit être reproductible et justifiable, pas générée.
4. Agir	Outils : opposition, virement guidé, transmission au conseiller	Une action ne part qu'après confirmation explicite du client.
5. Formuler	Le seul appel LLM du tour, à la fin : `ministral-3:3b` (3,0 Go) sous garde-fou ; gabarits pour les réponses simples	Le LLM met en forme des faits calculés ; il n'en invente aucun.
Escalade	`ministral-3:14b` (9,1 Go), seulement si l'étage 1 doute encore après une question	Le « gros modèle à un instant précis » que CGI a explicitement encouragé.

Les quatre décisions qui font la différence.

1. **Comprendre sans LLM.** Des mots-clés pour les cas évidents, un petit classifieur pour le reste. Il est entraîné sur Banking77 traduit en français, plus 8 intentions que Banking77 ne couvre pas : épargne, crédit immobilier, crédit à la consommation, prêt étudiant, virement à un proche, jargon, insatisfaction, hors sujet.
2. **Décider sans LLM.** Chaque proposition vient avec ses raisons *et* avec la liste des produits écartés et pourquoi (« pourquoi pas le LEP ? »).
3. **Formuler avec le plus petit modèle qui suffit, une seule fois par tour.** On part d'un modèle qui parle bien (14B), on descend en taille, et on garde le plus petit qui tient encore le seuil de qualité.
4. **Tout mesurer contre une version « tout LLM ».** Même jeu de scénarios, trois configurations, et un tableau qualité / énergie / latence / taille au cœur du pitch.

Ce qu'un organisateur nous a dit. « Pour gagner, c'est moins de LLM, plus d'algo, ou des modèles d'IA plus spécialisés », y compris pour le sujet 1 : des mots-clés et un classifieur en entrée, un LLM appelé une seule fois, à la fin, et dont on choisit la taille en descendant. C'est l'architecture ci-dessus.

Ce que la grille du jury y gagne.

Critère	Poids	Notre preuve
Pertinence métier	25 %	Les 6 situations des slides, plus l'appartement, le prêt étudiant et le jargon ; priorité n° 1 de La Banque Postale ; inclusion et accessibilité.
Qualité technique	20 %	Précision sur le test officiel Banking77 (anglais et français) ; taux de réussite d'un jeu de 30 scénarios automatisés.
Frugalité	20 %	Énergie par requête (CodeCarbon), latence, Go chargés, part des requêtes traitées sans LLM ; comparaison à la version « tout LLM ».
Explicabilité	15 %	Panneau « pourquoi » : intention et confiance, règles appliquées, produits proposés et écartés, sources publiques.
Démonstration	10 %	Six minutes en direct, avec les profils fournis par les slides ; vidéo de secours.
Présentation	10 %	Trois voix, une par module ; un tableau de résultats, une démo, un message.

L'organisation. Trois modules, un responsable et un suppléant chacun : *Comprendre et mesurer* (Younes), *Converser et formuler* (Yahya), *Conseiller et agir* (Sohayb). Les contrats entre modules sont figés lundi soir ; deux intégrations mardi (12h30 et 18h) ; gel fonctionnel mardi 18h ; mercredi matin consacré aux mesures finales, à la vidéo et aux répétitions.

La phrase à retenir. *Notre assistant comprend souvent avec de simples mots-clés, sinon avec un modèle de 118 millions de paramètres ; il décide avec des règles que le client peut lire ; et il n'appelle un LLM qu'une fois, à la fin, pour mettre en mots ce qui a déjà été calculé.*

CHAPITRE 1

Ce que le hackathon attend

Ce chapitre rassemble tout ce qui a été demandé, écrit ou dit, sans interprétation. Il se termine par une liste d'exigences numérotées : le chapitre 10 vérifie que la solution répond à chacune.

1.1 La règle commune aux deux sujets

Les slides de CGI posent quatre règles, « deux sujets, une même règle : une IA frugale et open source pour le domaine bancaire ».

Règle	**Ce qu'elle impose**
Open source uniquement	Licences ouvertes, aucune API de LLM externe, données en local.
Le plus petit modèle qui suffit	Le GPU est partagé : une base simple d'abord, un modèle plus gros seulement si le gain est *mesuré*.
Serveur GPU sur site	Données et modèles restent en interne.
Mesurer sa frugalité	Taille du modèle, énergie (CodeCarbon) et latence, présentées dans le pitch.

Denis Barthou a précisé : la solution tourne uniquement sur les machines locales ; utiliser d'autres IA pour *développer* est autorisé ; dans la solution, on privilégie de petits LLM, « des algorithmes au lieu de LLM quand c'est possible », des bases de données et d'autres types d'IA (classifieurs). Le critère de frugalité retient le plus petit LLM *en Go, quantisation comprise*.

À l'oral, CGI a ajouté trois nuances qui orientent directement notre architecture :

— la frugalité, c'est peu de tokens, « mais surtout » peu d'énergie ;

— « le plus petit modèle qui suffit » est une phrase « à double tranchant » : une architecture peut appeler **un gros modèle à un instant précis, pour un besoin précis**, et de petits modèles le reste du temps — « c'est là que vous allez innover » ;

— le sujet 1 est « de l'IA générative qu'on orchestre », « du chatbot, mais pas du chatbot traditionnel ».

1.2 Le sujet 1

> « Un client écrit : *Je veux acheter un appartement.* Votre assistant doit comprendre, poser les bonnes questions et lui proposer une piste adaptée à sa situation. »

Objectifs. Comprendre les questions des clients en langage naturel ; personnaliser selon l'âge, les revenus et l'historique ; conseiller, c'est-à-dire recommander un produit bancaire simple.

Démarche attendue, en quatre temps. *Cadrer* (quels besoins et quelles intentions prioriser ?), *Préparer* (rendre les données exploitables en français), *Concevoir* (quelle architecture, et pourquoi la plus sobre ?), *Démontrer* (prouver la valeur et la frugalité).

Livrables attendus. Données préparées en français ; modèle de compréhension des intentions ; chatbot relié à une base clients simulée ; moteur de conseils personnalisés ; mesures de frugalité.

Données fournies. Banking77 (intentions) ; Bank Marketing, « enrichi de revenus et d'historique simulés » ; le catalogue de produits est à construire à partir d'informations publiques.

Les situations données en exemple. Six sur les slides, trois de plus à l'oral.

Thème	Message	Profil	Comportement attendu
Carte	« J'ai perdu ma carte hier soir, je fais quoi ? »	Inès, 34 ans, cadre	Réagir vite, guider l'opposition, rassurer
Réclamation	« Pourquoi j'ai payé 8 € de frais ce mois-ci ? »	Marc, 52 ans, découverts fréquents	Expliquer les frais, orienter si besoin
Épargne	« Je voudrais mettre de côté pour mes enfants. »	Sophie, 41 ans, deux enfants	Demander l'horizon, proposer une piste
Virement	« Je dois envoyer 500 € à mon fils. »	Paul, 68 ans, peu à l'aise en ligne	Guider pas à pas, avec des mots simples
Crédit	« Je veux un crédit pour acheter une voiture. »	Karim, 29 ans, 1 900 € de revenus	Questionner, rester prudent sur l'endettement
Insatisfaction	« Votre appli ne marche jamais ! »	Client mécontent, 3e message du jour	Reconnaître la frustration, passer la main
Logement	« Je veux acheter un appartement. »	(énoncé principal)	Comprendre, questionner, proposer une piste
Prêt étudiant	« Je veux faire un prêt étudiant, comment je fais ? »	(exemple oral)	Regard d'un jeune client
Jargon	Un mot ou un sigle bancaire non compris	(exemple oral)	Expliquer avec des mots simples

Précisions données à l'oral. Les jeux de données sont « indicatifs » : on peut en croiser d'autres. La profondeur est à notre choix : « un agent qui va jusqu'au bout d'un workflow et qui fait lui-même l'action » (couper la carte selon la gravité), ou un assistant qui guide seulement. Ils veulent « notre regard » de jeunes clients sur le niveau de service attendu. Le chatbot doit répondre « immédiatement ». Les attentes seront précisées avec chaque équipe au fil des jours.

1.3 Ce que le jury regarde

Jury de trois personnes : Adrien (CGI, aussi coach), Denis Barthou (ENSEIRB) et Jean-Michel (La Banque Postale, à distance ; les équipes peuvent lui poser des questions). Il « évalue votre démarche autant que votre résultat ».

Poids	Critère	Formulation officielle
25 %	Pertinence métier	Utile pour un client ou un analyste
20 %	Qualité technique	Résultats mesurés et bien évalués
20 %	Frugalité	Taille, énergie, latence
15 %	Explicabilité	Chaque conseil ou alerte se justifie
10 %	Démonstration	Elle fonctionne et se comprend
10 %	Présentation	Claire et tenue en 15 minutes

Format. 30 minutes par équipe (20 s'il y a plus de 7 groupes) : 15 minutes de présentation avec **démonstration en direct sur le serveur fourni**, environ 10 minutes de questions, 5 minutes de retour à chaud. À remettre avant : le code source déposé sur un dépôt Git et le support de présentation.

1.4 Ce que La Banque Postale valorise

La directrice SI de La Banque Postale a présenté ses priorités IA dans cet ordre :

1. **l'expérience client** : chatbot conversationnel sur ses contrats, **les réclamations** (« un sujet prégnant »), et la personnalisation des offres à partir des avoirs du client — c'est exactement le sujet 1 ;
2. l'optimisation des processus (dossiers de crédit, anti-blanchiment, anti-fraude) ;
3. l'innovation (outils pour les collaborateurs, incubateur).

Elle a insisté sur trois valeurs : **l'accessibilité** (clients et collaborateurs malvoyants ou malentendants : tout ce que construit la DSI doit être compatible), **l'inclusion bancaire** (la banque a le devoir d'accueillir tous les clients, y compris les plus fragiles) et la **responsabilité** (banque citoyenne, finance durable). CGI a mentionné la souveraineté et la RSE parmi les enjeux de ses clients. Un client sur quatre en France est client de La Banque Postale, accueilli dans 17 000 points de contact.

1.5 Les contraintes

— **Le temps.** Lundi soir, mardi, mercredi matin : un jour et demi de travail effectif.

— **Les machines.** Postes de la salle (RTX 3060 12 Go, 30 Go de RAM) : machine principale de développement. DeepEirb (2 × A6000 48 Go) : SSH et serveur d'inférence vLLM, à condition de *demander à Denis Barthou* les modèles voulus. Jetson AGX Orin et OrangePi : disponibles mardi, pour le déploiement uniquement.

— **Les modèles déjà installés.** `gemma4:e2b` (7,2 Go) et `ministral-3:14b` (9,1 Go) sous Ollama, contexte réglé à 16 384 tokens. Télécharger d'autres modèles est possible, « pas en wifi ».

— **L'équipe.** Trois personnes : Yahya (IA), Sohayb (génie logiciel), Younes (calcul intensif).

1.6 Ce qu'un organisateur nous a conseillé

Lundi vers 17h30, un organisateur du hackathon a pris le temps d'échanger avec nous (transcription dans `infos/transcription-3-echange-organisateur.txt`). Ses conseils précisent la règle commune :

— **« Pour gagner, c'est moins de LLM, plus d'algo »**, ou des algorithmes différents, ou des modèles d'IA plus spécialisés — « même pour le premier » sujet.

— **En entrée, pas besoin de LLM** pour savoir de quoi parle le client : un algorithme de catégorisation est plus rapide. Une simple recherche de **mots-clés**, presque gratuite, trouve le sujet dans environ 30 % des cas (« ça fait 30 % de gagné »), et peut donner **un degré de confiance** : un seul mot-clé trouvé dans une longue phrase, ce n'est pas sûr. Les autres cas passent à un outil plus lourd.

— **En sortie, un LLM**, parce qu'il faut parler français à un humain ; mais il faut **minimiser les appels** et ne l'appeler **qu'à la fin**.

— **Choisir sa taille en descendant** : commencer avec un modèle qui parle correctement (« un 15B ou un 30B »), puis descendre vers un 4B, un 2B (« même le Gemma 4 que vous avez »), voire un 1B.

— **Se demander, à chaque endroit, si un LLM est nécessaire** : jamais, ou seulement pour une partie des cas. « Seulement 30 % des cas avec un LLM, c'est intéressant » : on prend le vélo pour aller chercher le pain, la voiture pour le week-end.

— **Un seul sujet**, bien fait. Puis, **une fois la solution sûre**, essayer des idées nouvelles, même exotiques ; utiliser l'IA pour coder et discuter des idées ; et « se faire plaisir ».

1.7 Les exigences, numérotées

N°	Exigence	Source
E1	Comprendre les demandes en langage naturel, en français	Objectif 01, livrable
E2	Fournir des données préparées en français	Livrable
E3	Poser les bonnes questions avant de proposer	Énoncé
E4	Personnaliser selon l'âge, les revenus et l'historique	Objectif 02
E5	Recommander un produit bancaire simple	Objectif 03, livrable
E6	Relier le chatbot à une base clients simulée	Livrable
E7	Construire le catalogue à partir d'informations publiques	Données
E8	Open source, aucune API externe, données locales	Règle commune
E9	Le plus petit modèle qui suffit ; un plus gros seulement si le gain est mesuré	Règle commune
E10	Mesurer taille, énergie (CodeCarbon) et latence	Règle commune, livrable
E11	Justifier chaque conseil	Grille (15 %)
E12	Répondre immédiatement	Oral
E13	Choisir et assumer la profondeur : guider ou agir	Oral
E14	Traiter les six situations avec le comportement attendu	Slide 3
E15	Expliquer le jargon ; apporter le regard d'un jeune client	Oral
E16	Démo en direct sur le serveur fourni ; code sur Git ; support remis	Soutenance
E17	Respecter accessibilité et inclusion (souhaitable)	Présentation de La Banque Postale
E18	En entrée, des algorithmes ; un seul appel au LLM, à la fin ; mesurer la part des cas sans LLM	Échange avec un organisateur
E19	D'abord une solution sûre, ensuite des idées nouvelles	Échange avec un organisateur

CHAPITRE 2

Ce que disent les données

Les deux jeux de données ont été téléchargés et lus le 26 octobre. Les chiffres de ce chapitre sont comptés sur les fichiers, pas recopiés d'une documentation.

2.1 Banking77 : la compréhension des demandes

Ce que c'est. 13 083 questions de clients d'une banque en ligne britannique, chacune étiquetée par l'une de 77 intentions (Casanueva et al., 2020, licence CC-BY-4.0). Le jeu d'entraînement compte 10 003 questions, réparties de façon inégale (de 35 à 187 par intention) ; le jeu de test en compte 3 080, exactement 40 par intention. **Tout est en anglais.**

Les scores de référence. L'article d'origine donne, en précision sur le test complet : 87,19 % pour BERT utilisé comme encodeur figé, 92,81 % pour USE, 93,01 % pour ConveRT, 93,36 % pour USE et ConveRT combinés, 93,66 % pour BERT affiné. Le message utile pour nous : **un encodeur figé et un classifieur léger se placent à un ou deux points du meilleur modèle affiné**, pour un coût d'entraînement de quelques minutes sur CPU.

Ce qu'il couvre, et surtout ce qu'il ne couvre pas. Le vocabulaire est celui d'une néobanque : recharges (*top-up*), cartes virtuelles, Apple Pay, taux de change. Confronté aux situations du sujet, le constat est net :

Situation du sujet	Couverte ?	Intentions Banking77 concernées
Carte perdue (Inès)	**oui**	`lost_or_stolen_card`, `compromised_card`, `card_swallowed`
Frais (Marc)	**oui**	`extra_charge_on_statement`, `card_payment_fee_charged`, `transfer_fee_charged`, `cash_withdrawal_charge`…
Virement à un proche (Paul)	**partiel**	Les intentions `transfer_*` portent sur l'*état* d'un virement (en attente, refusé, annulé), pas sur « comment en faire un »
Épargne (Sophie)	**non**	—
Crédit auto (Karim)	**non**	—
Appartement (énoncé)	**non**	—
Prêt étudiant (oral)	**non**	—
Insatisfaction	**non**	—
Jargon (oral)	**non**	—

Banking77 couvre le *service*, pas le *conseil*. Il sait reconnaître une carte perdue ou un frais contesté ; il ne contient pas une seule demande d'épargne, de crédit ou de projet immobilier — c'est-à-dire l'exemple même de l'énoncé. Les intentions de conseil sont à créer, en français, par nous. C'est une partie du livrable « données préparées en français ».

Un bruit d'étiquetage à connaître. Certaines étiquettes sont discutables. Dans le jeu d'entraînement, « *What is the word ?* » est rangé sous `direct_debit_payment_not_recognised`, et « *Has there been any activity on my card today ?* » sous `lost_or_stolen_card`. Cela plafonne la précision atteignable et justifie de raisonner aussi au niveau des *familles* d'intentions, plus robustes (section 4.2).

Neuf familles. Nous regroupons les 77 intentions en neuf familles, vérifié par script : chaque intention est rangée une fois et une seule. Le détail est en annexe A.

Famille	Intentions	Entraînement	Test
`carte_perdue`	4	350	160
`carte_usage`	10	1 084	400
`carte_commande`	12	1 465	480
`frais_contestation`	14	2 225	560
`virement`	10	1 409	400
`compte_identite`	8	884	320
`especes`	5	764	200
`change_etranger`	6	815	240
`alimenter_compte`	8	1 007	320
Total	**77**	**10 003**	**3 080**

2.2 Bank Marketing : la base clients

Ce que c'est. Les clients d'une banque portugaise contactés par téléphone entre mai 2008 et novembre 2010 pour souscrire un dépôt à terme (UCI, Moro et al.). Le fichier `bank-full.csv` compte **45 211 clients** et 17 colonnes ; la variante `bank-additional-full.csv` (41 188 lignes) remplace le solde par des indicateurs économiques. Nous partons de `bank-full.csv`, qui contient le solde.

Colonnes	Contenu	Usage pour nous
`age`, `job`, `marital`, `education`	Âge (18 à 95 ans, médiane 39), 12 métiers dont 938 étudiants et 2 264 retraités, situation (« divorced » inclut les veufs), études	Profil, éligibilité (Livret Jeune, LDDS), registre de langue
`balance`	Solde annuel moyen en euros, de −8 019 à 102 127 ; médiane 448 ; **3 766 soldes négatifs (8,3 %)**	Découverts fréquents (Marc), capacité d'épargne
`housing`, `loan`, `default`	Crédit immobilier en cours (55,6 %), crédit personnel (16,0 %), défaut de paiement (1,8 %)	Charges existantes, prudence crédit
`contact`, `day`, `month`, `duration`, `campaign`, `pdays`, `previous`, `poutcome`	Historique des campagnes de démarchage	Seulement `previous` et `poutcome`, pour l'appétence
`y`	A souscrit un dépôt à terme : 5 289 oui (11,7 %)	Cible du modèle d'appétence épargne

La colonne `duration` est une fuite. La documentation de l'UCI le dit explicitement : la durée de l'appel n'est connue qu'*après* l'appel, et elle détermine presque la réponse (un appel de 0 seconde donne toujours « non »). Un modèle qui l'utilise affiche un excellent score et ne sert à rien. Nous l'excluons, ainsi que `contact`, `day` et `month`, propres à la campagne. Le dire au jury est un point de qualité technique gratuit.

2.3 Ce qui manque, et comment on le comble

Bank Marketing ne contient ni revenus, ni enfants, ni charges, ni historique d'opérations. Or l'énoncé demande de personnaliser « selon l'âge, les revenus et l'historique ». Les slides annoncent une version « enrichie de revenus et d'historique simulés » fournie par les organisateurs. Deux cas :

— **Elle arrive à temps.** On la branche derrière un *adaptateur* unique, `src/conseiller/clients.py`, qui expose toujours le même profil au reste du code.

— **Elle tarde.** On simule nous-mêmes, avec une graine fixe et une méthode écrite : revenu mensuel net tiré par métier et âge ; nombre d'enfants à partir de l'âge et de la situation ; charges de crédit si `housing` ou `loan` ; douze mois d'événements (frais, découverts, contacts avec le service client), plus nombreux si le solde est négatif.

Règle de transparence. Toute donnée simulée porte le drapeau `simule=True` et sa méthode est décrite dans la fiche de données. Dans l'interface, un champ simulé s'affiche en italique. Le jury ne doit jamais pouvoir croire qu'un revenu inventé est une donnée réelle.

Les clients de démonstration. Les profils des slides deviennent huit clients fixes, chacun ancré sur une ligne réelle de Bank Marketing (âge, métier, situation, solde, crédits) et complété par simulation. Ils servent à la démo et aux tests.

Id	Client	Ancrage Bank Marketing	Enrichissement simulé (exemple)
C01	Inès, 34 ans	`management`, `single`	3 200 € nets, carte active
C02	Marc, 52 ans	`blue-collar`, `married`, solde négatif	1 850 € nets, 5 découverts en 12 mois, commissions facturées
C03	Sophie, 41 ans	`admin.`, `married`	2 400 € nets, enfants de 8 et 12 ans, Livret A
C04	Paul, 68 ans	`retired`, `divorced`	1 600 €, « peu à l'aise en ligne », fils enregistré comme bénéficiaire
C05	Karim, 29 ans	`technician`, `loan=yes`	1 900 € nets (donné), crédit en cours de 150 €/mois
C06	Julie, 37 ans	`services`	3 contacts au service client aujourd'hui
C07	Léa, 31 ans	`management`, `housing=no`	2 900 € nets, 25 000 € d'épargne
C08	Lucas, 20 ans	`student`	Job étudiant à 450 €, sans épargne

2.4 Le catalogue de produits

L'énoncé le laisse à construire « à partir d'informations publiques ». Nous le limitons à ce qu'un assistant peut honnêtement proposer — des produits *simples* — et nous l'écrivons en JSON, une fiche par produit : identifiant, nom, catégorie, conditions d'éligibilité, plafond, disponibilité de l'argent, à qui il convient, limites, **source publique et date de relevé**. La liste complète et les paramètres sont en annexe B.

Les taux réglementés changent (le taux du Livret A est révisé deux fois par an). Aucun taux n'est écrit en dur dans le code : c'est un champ du catalogue, avec sa date et sa source, relevé le jour même sur le site public. Les plafonds (22 950 € pour le Livret A, 12 000 € pour le LDDS, 10 000 € pour le LEP, 1 600 € pour le Livret Jeune, 61 200 € pour le PEL) sont stables mais sont aussi vérifiés à la source.

CHAPITRE 3

Ce que Timso AI nous apprend

Timso AI est l'assistant de rédaction construit pendant le stage de Yahya pour l'agence de voyage French Touch Travel, et mis en production. Il lit le patrimoine de l'agence — 68 648 courriels, 15 766 journées de voyage vendues, 4 282 fiches de catalogue — et s'en sert pour rédiger des brouillons qu'un conseiller relit avant envoi.

Ce n'est pas le même problème, mais c'est la même famille : **comprendre une demande libre, retrouver le bon produit dans un catalogue, et rédiger sans rien inventer**. Plusieurs décisions y ont été *mesurées* en conditions réelles. Les reprendre nous évite de les redécouvrir en deux jours.

3.1 Les leçons transposables

Leçon de Timso AI	Ce qui a été décidé ou mesuré	Ce qu'on en fait ici
Recherche plutôt qu'affinage	L'affinage d'un LLM a été écarté avant tout travail : coûteux, figé sur une version, il demande des GPU.	**Aucun affinage de LLM.** On n'entraîne qu'une tête de classification, en quelques secondes sur CPU.
Encodeurs E5 en local	`multilingual-e5-large` calculé sur place : aucune donnée client ne sort. Oublier le préfixe `query:`/`passage:` dégrade la pertinence *sans aucune erreur*.	Même famille en version `small`. Les préfixes sont posés par une seule fonction, reprise de `src/search/embed/model.py`.
Pas de base vectorielle	119 107 vecteurs tenaient en 465 Mo ; un produit matrice-vecteur numpy répondait en une centaine de millisecondes, sans index à maintenir.	Le glossaire et le catalogue font quelques centaines d'entrées : **numpy en mémoire**, pas de base vectorielle.
Seuils obtenus par balayage	Seuils de 0,90 et 0,88 choisis en mesurant précision et couverture. Une variante gagnait 2,8 points de couverture pour 0,5 de précision : **rejetée**, car une erreur coûte plus qu'un manque.	Le seuil de confiance du classifieur est fixé par balayage. En dessous, l'assistant **demande** plutôt que de deviner.
Cascade de résolution	Chaque ligne est d'abord rapprochée du dossier en cours, puis du catalogue complet, et n'est liée à un produit que si elle passe le seuil de l'étage.	Même principe pour les modèles : petit d'abord, gros seulement si le petit doute.
Le brouillon, jamais l'envoi	Rien ne part chez un client sans qu'un humain l'ait relu.	L'assistant **oriente**, le conseiller **décide** (crédit). Le passage de main transmet un résumé.

Leçon de Timso AI	Ce qui a été décidé ou mesuré	Ce qu'on en fait ici
Déclarer les outils, puis les exécuter	Les outils MCP séparent la déclaration (un contrat lisible) de l'exécution ; la lecture est libre, les effets de bord passent par un point d'entrée suivi.	Lecture du profil libre ; opposition et virement **seulement après confirmation**, avec une trace dans un journal.
Désactiver la réflexion	Mesuré : 8 000 tokens consommés en réflexion sans une ligne de réponse ; 1 571 tokens pour la réponse complète sans réflexion.	Sur les petits modèles qui raisonnent (Qwen3), `think: false`. C'est de la frugalité directe.
Vérifier le service réel	Un indicateur de santé répondait « vrai » parce qu'une clé était configurée, alors que le service était arrêté depuis quatre jours.	Avant la démo, on interroge vraiment Ollama. S'il ne répond pas, on bascule sur les gabarits.
Ne pas rendre une note obligatoire	20 notes exigées par le formulaire : seules les 6 premières étaient réfléchies, les 14 autres valaient 5/10 par défaut.	Grille d'évaluation humaine courte, champs facultatifs.

3.2 Ce qu'on ne reprend pas

— **L'API Claude.** Interdite ici : la règle impose des modèles open source, en local. C'est précisément ce qui rend l'architecture en cascade nécessaire : on ne peut plus compter sur un très gros modèle pour tout faire.

— **PostgreSQL, Docker, Keycloak.** Justifiés pour un service en production, inutiles pour un démonstrateur de deux jours. Des fichiers CSV et JSON suffisent.

— `multilingual-e5-large`. Avec 560 millions de paramètres, il est près de cinq fois plus gros que la version `small` (118 millions). On ne monte en taille que si le gain est mesuré.

Ce que Timso AI donne au pitch. Au moment des questions, on peut répondre par l'expérience : « Dans un système en production, on a mesuré qu'une erreur de rattachement coûtait plus cher qu'un manque ; c'est pour ça que notre assistant pose une question plutôt que de deviner. » Peu d'équipes pourront s'appuyer sur un système qui a déjà servi de vrais utilisateurs.

CHAPITRE 4

La solution

4.1 Le principe : une cascade

Un seul principe gouverne l'architecture : **chaque étage ne passe la main au suivant que s'il ne sait pas faire lui-même**. Comprendre une demande ne demande pas un LLM ; décider d'un produit ne doit pas en demander un ; mettre en mots un résultat calculé peut en demander un petit ; lever un vrai doute peut justifier un gros, une fois. C'est la lecture littérale de « le plus petit modèle qui suffit », et c'est aussi la réponse à la nuance de CGI sur le « gros modèle à un instant précis ». Un organisateur l'a résumé ainsi : « pour gagner, c'est moins de LLM, plus d'algo ». Dans le cas normal, un tour de conversation fait **au plus un appel à un LLM, à la fin**.

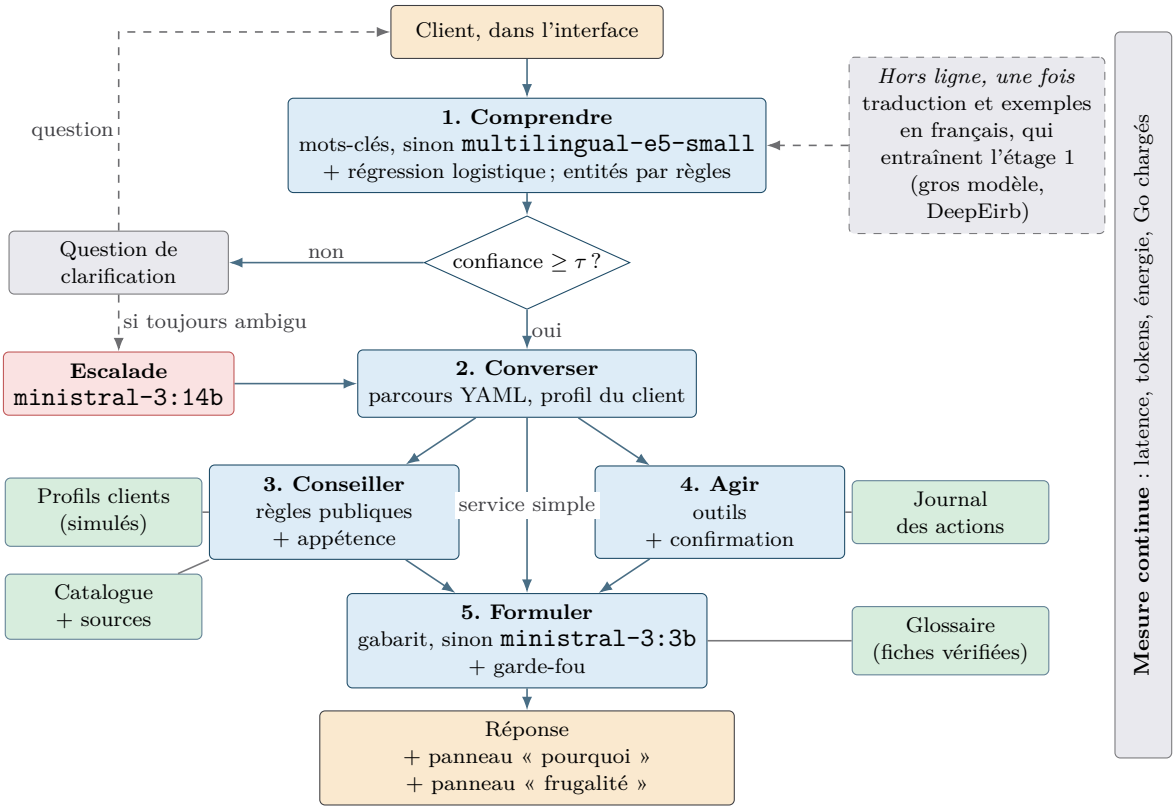


Figure 4.1 – La cascade. Les étages en bleu fonctionnent sans gros modèle ; l'escalade (en rouge) est l'exception, comptée et affichée.

Le tableau ci-dessous fixe pour chaque étage ce qu'il reçoit, ce qu'il rend et ce qu'il coûte au plus. Les budgets de latence sont des *cibles* sur un poste de la salle (RTX 3060) ; les valeurs réelles sont mesurées et reportées dans le pitch.

Étage	Reçoit	Rend	Budget cible
1. Comprendre	Le message, l'état du parcours en cours	Famille, intention, confiance, entités	$<$ 1 ms à $<$ 30 ms
2. Converser	La compréhension, le profil	La prochaine question, ou une demande de conseil ou d'action	$<$ 5 ms
3. Conseiller	Le besoin complété, le profil, le catalogue	Propositions, raisons, produits écartés, alertes	$<$ 20 ms
4. Agir	Une action confirmée	Un résultat (référence, ticket)	$<$ 20 ms
5. Formuler	Les faits structurés	Le texte affiché	0 ms (gabarit) à ∼1,5 s (3B)
Escalade	Le message ambigu	Une intention	∼2 à 4 s, rare

4.2 Étage 1 — Comprendre

Premier filtre : les mots-clés. Avant tout modèle, un lexique d'expressions par famille (« perdu ma carte », « opposition », « frais », « virement », « mettre de côté », « appartement », « prêt étudiant », « c'est quoi »…) est cherché dans le message normalisé (minuscules, accents retirés, formes simples). Coût : moins d'une milliseconde, aucun modèle chargé. Le lexique part des mots les plus discriminants de chaque famille dans les données d'entraînement, puis il est relu à la main. Le filtre **ne conclut que s'il est sûr** : une seule famille touchée, et soit une phrase courte, soit plusieurs expressions trouvées. Un seul mot-clé perdu dans une longue phrase ne suffit pas : le message passe au classifieur. Une expression n'est gardée dans le lexique que si sa précision mesurée sur la validation dépasse 97 %. C'est la suggestion de l'organisateur, et elle se mesure : la part des messages que les mots-clés traitent seuls, et la précision sur cette part.

Classer en deux niveaux. Le classifieur prédit d'abord une *famille* (14 : les 9 familles Banking77 plus 5 nouvelles), puis l'*intention* précise (85 : les 77 de Banking77 plus 8 nouvelles). La famille suffit à choisir le parcours ; l'intention sert à affiner la réponse. Ce double niveau absorbe le bruit d'étiquetage de Banking77 : deux intentions voisines mal séparées appartiennent presque toujours à la même famille.

Le modèle. Les phrases sont transformées en vecteurs par `intfloat/multilingual-e5-small` (118 millions de paramètres, vecteurs de 384 nombres, environ 0,47 Go en float32), avec le préfixe `query:` attendu par la famille E5. Une régression logistique (scikit-learn) est entraînée sur ces vecteurs : quelques secondes sur CPU, un fichier de moins d'un mégaoctet. L'encodeur étant multilingue, on l'entraîne sur trois sources à la fois : Banking77 en anglais, Banking77 traduit en français, et nos exemples français des nouvelles intentions. Pour expliquer ce qu'il a compris, l'assistant affiche aussi la phrase d'entraînement la plus proche (« votre message ressemble à : *j'ai perdu ma carte* »), retrouvée par un produit matrice-vecteur en mémoire : l'idée du RAG, appliquée à la compréhension.

Les nouvelles intentions.

Intention	Famille	Exemple de message
`epargne_projet`	`epargne`	« Je voudrais mettre de côté pour mes enfants »
`credit_immobilier`	`credit`	« Je veux acheter un appartement »
`credit_conso`	`credit`	« Il me faudrait un crédit pour une voiture »
`pret_etudiant`	`credit`	« Comment on fait un prêt étudiant ? »
`faire_virement`	`virement`	« Je dois envoyer 500 € à mon fils »
`question_definition`	`aide`	« C'est quoi un TAEG ? »
`insatisfaction`	`insatisfaction`	« Votre appli ne marche jamais ! »
`hors_sujet`	`conversation`	« Bonjour », « merci », « quel temps fait-il ? »

Pour chacune, environ 80 exemples d'entraînement sont *générés* une fois, hors ligne, par un gros modèle, avec des consignes de variété (registre jeune ou âgé, fautes de frappe, style SMS, phrases longues) ; un membre de l'équipe les relit tous (une vingtaine de minutes). Les 20 exemples de *test* de chaque intention sont *écrits à la main* par l'équipe : tester un classifieur sur des phrases produites par le même générateur que son entraînement surestimerait son score.

Le seuil de confiance τ. Si la probabilité de la famille prédite est au moins τ, on continue. Sinon, l'assistant pose une question fermée construite à partir des deux familles les plus probables : « Vous parlez de votre carte, ou d'un virement ? ». Si la réponse reste ambiguë, et seulement alors, le message part au modèle d'escalade. τ est choisi par balayage sur un jeu de validation, comme dans Timso AI : on retient la plus petite valeur pour laquelle la précision sur les messages acceptés dépasse 97 %. Une erreur de parcours coûte plus qu'une question.

Le contexte de la conversation. Quand un parcours attend une information (un montant, une durée), le message est d'abord lu comme une réponse à cette question : « 250 000 » n'est pas une nouvelle demande. Le classifieur n'est consulté que si le message ne répond pas à la question en cours.

Les entités, par règles. Montants (« 500 € », « 1 900 euros », « 250k »), durées (« 10 ans », « 48 mois »), liens (« mon fils »), objets (voiture, appartement, études), dates relatives (« hier soir ») : des expressions régulières suffisent et coûtent zéro. Si une information manque après les règles, on ne la devine pas avec un LLM : le parcours la demande au client. Un appel au LLM de moins, et aucun risque d'erreur d'extraction.

L'insatisfaction. Deux signaux combinés : le classifieur (intention `insatisfaction`) et l'historique (nombre de contacts du jour). Au troisième contact, la règle de passage de main s'applique même si le ton est neutre.

4.3 Étage 2 — Converser

Un parcours par intention de conseil ou d'action. Chaque parcours est un fichier YAML qui déclare les informations nécessaires, la question à poser pour chacune, l'ordre, et ce qui se passe à la fin (un conseil, une action, un passage de main). Le gestionnaire de dialogue est un automate qui lit ces fichiers : déterministe, testable, et modifiable sans toucher au code.

```
# src/converser/parcours/credit_immobilier.yaml (extrait)
famille: credit
infos:
  revenus_nets:   {source: profil, sinon: "Quels sont vos revenus nets mensuels ?"}
  credits_cours:  {source: profil, sinon: "Avez-vous des credits en cours ?"}
  prix_bien:      {question: "Quel est le prix du bien que vous visez ?"}
```

```
  apport:         {source: profil.epargne, confirmer: true,
                   question: "Quelle part de votre epargne souhaitez-vous y consacrer ?"}
fin: {conseil: credit_immobilier, mention_legale: credit, proposer: rdv_conseiller}
```

Ne jamais demander ce qu'on sait. C'est la forme la plus visible de la personnalisation (E4) : si le profil connaît les revenus, l'assistant *confirme* au lieu de demander (« J'ai noté vos revenus de 2 900 € nets par mois »). Une information simulée est confirmée, jamais affirmée.

Le registre. Un mode « mots simples » s'active de lui-même pour un client âgé de 70 ans ou plus ou signalé « peu à l'aise en ligne » (Paul), et à la demande pour tout le monde : phrases courtes, une seule étape par message, aucun sigle sans explication. Ce n'est pas un autre modèle, c'est un autre jeu de gabarits et une consigne de plus au petit LLM.

Le jargon. Le glossaire (annexe D) est une liste de fiches courtes, rédigées et vérifiées par nous. Quand un terme du glossaire apparaît dans une réponse, il est souligné et explicable d'un clic ; quand le client demande « c'est quoi … », la fiche est retrouvée par similarité de vecteurs, en mémoire, sans LLM.

4.4 Étage 3 — Conseiller

Trois passes. Le moteur de conseil applique d'abord les conditions **d'éligibilité** (dures : âge, revenu, plafond déjà atteint), puis des règles de **pertinence** (horizon, objectif, épargne de précaution existante), puis un **classement**. Chaque règle a un identifiant et une phrase d'explication paramétrée : quand elle s'applique, la phrase remplie entre dans les raisons de la proposition.

Pourquoi, et pourquoi pas. La sortie contient les produits proposés avec leurs raisons *et* les produits écartés avec la règle qui les écarte. C'est l'explication la plus convaincante qui soit pour un client — « le LEP n'est pas proposé parce que votre revenu fiscal dépasse le plafond » — et pour le jury (15 % de la note).

L'appétence pour l'épargne. Bank Marketing dit, pour 45 211 clients, qui a souscrit un dépôt à terme. Une régression logistique entraînée sur les seules caractéristiques du client (âge, métier, situation, études, solde, crédits, campagnes précédentes ; **sans** `duration`) donne une probabilité d'intérêt pour l'épargne. Elle sert à *ordonner* les propositions d'épargne et à expliquer cet ordre par les trois facteurs qui pèsent le plus. On mesure l'aire sous la courbe ROC sur un jeu de test tenu à part ; LightGBM ne remplace la régression logistique que si le gain est mesuré. Les limites sont dites : données portugaises de 2008 à 2010, donc un signal faible et illustratif, jamais une décision.

La prudence sur le crédit. Pour un crédit immobilier, les règles sont celles du Haut Conseil de stabilité financière : **mensualités au plus égales à 35 % des revenus nets, assurance comprise, et durée au plus de 25 ans**. La capacité d'emprunt se calcule à partir de la mensualité maximale m, du taux mensuel i et du nombre de mois n :

$$m = 0{,}35 \times R - C, \qquad \text{capacité} = m \times \frac{1 - (1+i)^{-n}}{i}$$

où R est le revenu net mensuel et C les mensualités déjà en cours. Le taux est un *paramètre daté* du catalogue, affiché comme « taux indicatif ». Pour le crédit à la consommation, la même logique

de taux d'effort s'applique, avec la mention légale obligatoire : « Un crédit vous engage et doit être remboursé. Vérifiez vos capacités de remboursement avant de vous engager. » L'assistant ne promet jamais un accord : il donne une estimation et propose un rendez-vous avec un conseiller, qui décide.

4.5 Étage 4 — Agir

L'oral laissait le choix entre guider et agir (E13). Nous agissons, mais avec une règle reprise de Timso AI : **la lecture est libre, l'effet de bord demande une confirmation explicite**, et chaque action laisse une trace dans un journal.

Outil	Ce qu'il fait (sur le SI simulé)	Confirmation	Rend
`consulter_profil`	Lit le profil et l'historique du client	non	Le profil
`expliquer_frais`	Retrouve les frais du mois dans l'historique et leur cause	non	Liste datée des frais, avec la règle qui les explique
`bloquer_carte`	Met la carte en opposition	**oui**	Une référence d'opposition, l'heure
`preparer_virement`	Prépare un virement vers un bénéficiaire enregistré ; vérifie le solde ; ne l'exécute qu'après accord	**oui**	Un récapitulatif, puis une référence
`transmettre_conseiller`	Crée une demande de rappel avec un résumé de la conversation	oui	Un numéro de ticket

Le résumé transmis au conseiller est construit à partir des faits du parcours (intention, infos recueillies, propositions) : le conseiller n'a pas à reposer les questions. C'est le « brouillon » de Timso AI transposé : l'humain reprend la main avec le travail déjà fait.

4.6 Étage 5 — Formuler

Le gabarit d'abord. Pour la plupart des intentions de service (carte, frais, virement, compte), une réponse à trous, écrite à l'avance et relue, est meilleure qu'une génération : exacte, instantanée, gratuite. Le petit LLM n'intervient que lorsque la réponse dépend de plusieurs faits à articuler (un conseil, une explication de refus).

Un seul appel, à la fin. C'est le seul endroit où un LLM intervient dans le cas normal : une fois par tour, après que tout a été compris, décidé et calculé. L'escalade de l'étage 1 est l'exception, comptée et affichée.

Ce que reçoit le petit LLM. Une consigne système courte (registre de la banque, vouvoiement, interdits), les *faits structurés* produits par les étages 3 et 4 (propositions, raisons, chiffres), et la question en cours. Jamais le catalogue entier, jamais l'historique brut : le contexte reste petit, donc rapide et peu coûteux.

Le garde-fou. Après génération, trois contrôles automatiques : chaque nombre du texte doit figurer dans les faits fournis ; aucune formule interdite (« accordé », « garanti », « sans risque ») ;

longueur bornée. En cas d'échec, la réponse gabarit est affichée à la place et l'échec est compté. Le taux d'échec du garde-fou fait partie des résultats présentés.

Le modèle. `ministral-3:3b` par défaut (3,0 Go en Q4_K_M) : un modèle européen, conçu par Mistral AI, à l'aise en français — ce qui rejoint la question de la souveraineté que CGI a soulevée. Mais ce choix n'est pas un a priori : le chapitre 5 décrit comment il est confirmé ou remplacé par la mesure.

4.7 Mesurer, en continu

Chaque appel à `reply()` renvoie une trace : le niveau qui a compris la demande (mots-clés, classifieur ou escalade), puis, pour chaque étage traversé, son nom, le modèle utilisé, la latence, les tokens consommés (Ollama renvoie `prompt_eval_count` et `eval_count`) et, pendant les campagnes de mesure, l'énergie. L'interface affiche cette trace en direct dans le panneau « frugalité » : le jury voit, pendant la démo, qu'une opposition de carte n'a appelé aucun LLM. Le protocole de mesure de l'énergie est au chapitre 6.

4.8 Un exemple complet : l'appartement

Léa (C07), 31 ans, 2 900 € nets par mois, aucun crédit en cours, 25 000 € d'épargne.

Étape	Ce qui se passe	Modèle
Tour 1 — « Je veux acheter un appartement »		
Comprendre	Famille `credit`, intention `credit_immobilier`. Les mots-clés « acheter » et « appartement » désignent une seule famille, dans une phrase courte : le filtre conclut seul. Entité `objet=appartement`	mots-clés
Converser	Parcours `credit_immobilier`. Revenus et crédits connus par le profil ; épargne connue, à confirmer comme apport. Manque : le prix du bien	—
Formuler	« C'est un beau projet. J'ai noté vos revenus de 2 900 € nets par mois. Quel est le prix du bien que vous visez, et quelle part de vos 25 000 € d'épargne souhaitez-vous y consacrer ? »	gabarit
Tour 2 — « Autour de 250 000, et je peux mettre les 25 000 »		
Comprendre	Lu comme la réponse attendue : prix 250 000 €, apport 25 000 €	règles
Conseiller	Frais de notaire estimés à 7,5 % dans l'ancien : 18 750 €. Besoin de financement : 243 750 €. À un taux indicatif de 3,5 % sur 25 ans, mensualité d'environ 1 220 €, soit **42,1 % des revenus : au-dessus des 35 %**. Prix maximal finançable avec cet apport : environ 212 000 €	règles
Formuler	Explique le calcul, propose trois leviers (bien moins cher, apport plus élevé, co-emprunteur), signale qu'un conseiller peut étudier les aides (PTZ selon conditions), propose un rendez-vous	`ministral-3:3b`
Garde-fou	Tous les nombres du texte figurent dans les faits ; aucune promesse	règles

Le panneau « pourquoi » affiche alors les règles appliquées (taux d'effort maximal de 35 %, durée maximale de 25 ans, estimation des frais de notaire), le taux indicatif avec sa date et sa source, et la ligne écartée : « prêt sur 30 ans : au-delà de la durée maximale ». Le calcul est vérifiable à la main par le jury.

4.9 Les parcours

Neuf parcours couvrent les neuf situations du sujet ; les familles de service restantes de Banking77 reçoivent une fiche de réponse courte et une orientation. Le détail de chaque parcours est en annexe C.

Parcours	Ce que l'assistant demande	Comment il conclut
Carte perdue (Inès)	Quelle carte ; perte ou vol	`bloquer_carte` après confirmation ; rassure sur la responsabilité ; propose une nouvelle carte
Frais (Marc)	Quel frais, si plusieurs	`expliquer_frais` sur l'historique ; plafond légal ; si les incidents se répètent, oriente vers l'offre clientèle fragile
Virement (Paul)	Bénéficiaire, montant, date	`preparer_virement` pas à pas ; rappel : la banque ne demande jamais un code
Épargne (Sophie)	Pour qui, horizon, montant mensuel	Propositions classées, raisons, produits écartés
Appartement (Léa)	Prix, apport	Capacité, taux d'effort, leviers, rendez-vous
Crédit auto (Karim)	Montant, durée, apport	Taux d'effort avec le crédit en cours, mention légale, rendez-vous
Prêt étudiant (Lucas)	Études, montant, caution	Orientation vers le prêt étudiant ; Livret Jeune pour épargner
Jargon	Le terme	Fiche du glossaire
Insatisfaction (Julie)	Rien : on écoute	Reconnaît la frustration, s'excuse, `transmettre_conseiller` avec le résumé des trois contacts

4.10 Conformité

— **Données personnelles.** Toutes les données sont simulées ; tout est traité en local, aucune donnée ne sort de la machine (E8).

— **Règlement européen sur l'IA.** Les systèmes destinés à évaluer la solvabilité des personnes physiques sont classés à haut risque. Notre assistant ne note pas la solvabilité : il applique des règles publiques, donne une estimation indicative, et renvoie la décision à un conseiller. Le modèle d'appétence n'ordonne que des produits d'épargne. Le règlement impose aussi d'informer l'utilisateur qu'il échange avec une IA : un bandeau permanent le dit.

— **Crédit.** La mention légale accompagne toute réponse sur un crédit.

— **Protection.** Toute réponse qui touche à la carte ou au virement rappelle qu'aucun code ne doit être communiqué — une protection simple contre l'arnaque au faux conseiller, qui vise en particulier les clients âgés.

CHAPITRE 5

Les modèles, et comment on les choisit

5.1 Les modèles retenus

Rôle	Modèle	Paramètres	Taille	Où il tourne
Filtre d'entrée (étage 1)	Lexique de mots-clés par famille	—	quelques Ko	CPU
Encodeur (étage 1)	`multilingual-e5-small` (intfloat)	118 M	≈ 0,47 Go	CPU ou GPU
Tête de classification	Régression logistique	≈ 38 000	< 1 Mo	CPU
Base de comparaison	TF-IDF + régression logistique	—	quelques Mo	CPU
Formulation (étage 5)	`ministral-3:3b`, Q4_K_M	≈ 3 G	3,0 Go	GPU (RTX 3060)
Escalade	`ministral-3:14b`, Q4_K_M	≈ 14 G	9,1 Go	GPU, à la demande
Appétence (étage 3)	Régression logistique	≈ 50	< 1 Mo	CPU
Préparation, hors ligne	`ministral-3:14b` ou plus gros, via vLLM	—	—	DeepEirb, une fois

La tête de classification compte environ 38 000 poids : 99 classes (14 familles et 85 intentions) fois 385 (les 384 dimensions du vecteur, plus un biais). Les tailles des modèles Ollama sont celles de la bibliothèque Ollama ; celles des modèles Ministral 3 incluent un encodeur d'images que nous n'utilisons pas.

La mémoire de la RTX 3060 est de 12 Go. `ministral-3:3b` (3,0 Go) et `ministral-3:14b` (9,1 Go) ne tiennent pas ensemble avec leurs caches de contexte. Trois options, par ordre de préférence :

1. l'escalade est envoyée au serveur vLLM de DeepEirb, qui sert le gros modèle à toutes les équipes ; le poste ne garde que le petit ;
2. l'escalade utilise `ministral-3:8b` (6,0 Go), qui tient à côté du 3B ;
3. un seul modèle est chargé à la fois ; l'escalade, rare, accepte quelques secondes de rechargement.

Dans tous les cas, le contexte est réglé au plus juste (`num_ctx` à 4 096 au lieu de 16 384) : moins de mémoire et des réponses plus rapides, comme l'a rappelé Denis Barthou.

5.2 « Le plus petit modèle qui suffit », rendu opérationnel

La règle commune ne dit pas comment on sait qu'un modèle « suffit ». Nous le décidons avant de mesurer, pour ne pas choisir après coup le résultat qui nous arrange. La démarche est celle qu'un organisateur nous a conseillée : partir d'un modèle qui marche, puis descendre.

Protocole. On commence par un modèle qui fait clairement l'affaire : il fixe la référence de qualité. On descend ensuite en taille, candidat par candidat, sur le même jeu et avec le même seuil fixé à l'avance. **On retient le plus petit qui tient encore le seuil.** Un modèle plus gros n'est retenu que si tous les plus petits échouent — c'est la définition exacte de « un modèle plus gros seulement si le gain est mesuré ». Toute l'échelle est évaluée : la courbe qualité, taille et énergie qui en sort va dans le support.

Pour l'encodeur. Candidats : `paraphrase-multilingual-MiniLM-L12-v2` et `multilingual-e5-small` (118 M chacun), puis `multilingual-e5-base` (278 M). Seuil : rester à moins d'un point de F1 macro du meilleur candidat testé, au niveau des familles, sur le test français.

Pour la formulation. Référence : `ministral-3:14b` (9,1 Go, déjà installé), ou un modèle d'environ 30B sur DeepEirb si Denis Barthou en sert un. Puis, en descendant : `gemma4:e2b` (7,2 Go, déjà installé), `ministral-3:8b` (6,0 Go), `ministral-3:3b` (3,0 Go), `qwen3:1.7b` (1,4 Go, réflexion désactivée), `gemma3:1b` (0,8 Go), `qwen3:0.6b` (0,5 Go) et `gemma3:270m` (0,3 Go). Jeu : 30 situations sous forme de faits structurés, tirées des parcours. Seuil : **zéro nombre inventé après garde-fou** et au moins 27 réponses sur 30 jugées correctes et claires en français par deux membres de l'équipe. Notre pari est que `ministral-3:3b` sera le plus petit à tenir le seuil ; la mesure peut descendre plus bas.

Les réglages de génération. Température basse (0,2), au plus 200 tokens produits, réflexion désactivée sur les modèles qui en ont une, modèle gardé en mémoire pendant la démo (`keep_alive`) pour ne pas payer le chargement devant le jury.

5.3 Le gros modèle, à l'instant précis

CGI a encouragé l'usage d'un gros modèle « à un instant T, pour un besoin spécifique ». Nous en faisons deux usages, et seulement deux.

Hors ligne, une fois : préparer les données. Traduire les 13 083 phrases de Banking77 et générer les exemples des nouvelles intentions est un travail de qualité, fait une seule fois. C'est le bon endroit pour un gros modèle : son coût est payé une fois, mesuré avec CodeCarbon, et *amorti* sur toutes les requêtes futures. Le pitch donne les deux chiffres : l'énergie totale de la préparation, et l'énergie par requête en service.

En ligne, rarement : lever un doute. Quand le classifieur reste sous le seuil après une question de clarification. Le taux d'escalade est mesuré sur les scénarios et affiché ; une escalade fréquente signalerait un classifieur insuffisant, pas un besoin de gros modèle.

5.4 La traduction de Banking77

La méthode. Traduction par lots avec une consigne et un glossaire : adapter au contexte bancaire français plutôt que traduire mot à mot.

Anglais (Banking77)	**Français attendu**
top up	alimenter son compte, recharger
transfer	virement
direct debit	prélèvement
statement	relevé de compte
PIN	code confidentiel
ATM	distributeur
card payment declined	paiement par carte refusé
exchange rate	taux de change

Le contrôle. Contrôles automatiques sur tout le jeu (la sortie est bien en français, le rapport de longueur avec l'original est plausible, pas de ligne vide) ; relecture humaine de 100 phrases tirées au hasard, avec le taux de phrases acceptables reporté dans la fiche de données.

Le repli. Si DeepEirb n'est pas accessible lundi soir, la traduction passe par `Helsinki-NLP/opus-mt-en-fr`, un modèle de traduction dédié d'environ 75 millions de paramètres, très rapide sur la RTX 3060. Il connaît moins bien le jargon bancaire : le glossaire est alors appliqué en post-traitement, et la relecture porte sur le jeu de test en priorité.

5.5 Ce qu'il faut demander lundi soir

— **À Denis Barthou** : l'accès SSH à DeepEirb, et un modèle servi par vLLM pour la préparation et l'escalade (`ministral-3:14b` au minimum, un modèle plus gros si disponible pour la traduction).

— **Sur les postes, en filaire** : télécharger `ministral-3:3b`, `qwen3:1.7b`, `gemma3:1b` et `multilingual-e5-small`. Les slides demandent d'éviter les gros téléchargements en wifi.

— **Aux organisateurs** : la version enrichie de Bank Marketing, et la confirmation de la machine de démonstration (DeepEirb ou poste de la salle).

CHAPITRE 6

Évaluer et mesurer

La qualité technique vaut 20 % et s'intitule « résultats mesurés et bien évalués » ; la frugalité vaut 20 % et se mesure. Ce chapitre fixe *avant* de coder ce qu'on mesure, sur quoi, et comment. Les tableaux sont des gabarits : ils seront remplis mardi soir et présentés tels quels.

6.1 Ce qu'on mesure

Mesure	Comment	Sur quoi	Critère
Précision, F1 macro	scikit-learn, par intention et par famille	Tests Banking77 et nos tests	Technique
Taux de réussite	Rejeu automatique des scénarios	30 conversations	Technique, métier
Échecs du garde-fou	Compteur dans la trace	Toutes les réponses générées	Explicabilité
Répartition par niveau	Compteur dans la trace : mots-clés, classifieur, escalade	Tests et scénarios	Frugalité
Taux d'escalade	Compteur dans la trace	Scénarios	Frugalité
Part sans LLM	Compteur dans la trace	Scénarios	Frugalité
Latence	Horloge par étage (p50, p95)	Scénarios	Frugalité
Énergie	CodeCarbon, par lot (section 6.6)	Lots de 200 requêtes	Frugalité
Taille	Go sur disque, quantisation comprise	Chaque modèle chargé	Frugalité
Appétence	Aire sous la courbe ROC	20 % de Bank Marketing tenus à part	Technique

6.2 La compréhension

Trois jeux de test. (a) Le test officiel de Banking77 en anglais, 3 080 phrases ; (b) le même, traduit en français ; (c) nos 160 phrases françaises des 8 nouvelles intentions, écrites à la main. Le jeu (a) rend nos chiffres comparables à l'article d'origine ; les jeux (b) et (c) mesurent ce qui compte pour le sujet.

Configuration	Préc. (a)	Préc. (b)	F1 famille (b+c)	Latence p95	Taille
Référence : BERT affiné (article)	*93,66 %*	—	—	—	*1,4 Go*
Mots-clés seuls, sur la part acceptée	*à mesurer*	*à mesurer*	*à mesurer*	*à mesurer*	Ko
TF-IDF + régression logistique	*à mesurer*	*à mesurer*	*à mesurer*	*à mesurer*	*à mesurer*
MiniLM-L12 + régression logistique	*à mesurer*	*à mesurer*	*à mesurer*	*à mesurer*	0,47 Go
e5-small + régression logistique	*à mesurer*	*à mesurer*	*à mesurer*	*à mesurer*	**0,47 Go**
e5-base + régression logistique	*à mesurer*	*à mesurer*	*à mesurer*	*à mesurer*	1,1 Go
`qwen3:1.7b`, sans exemple	*à mesurer*	*à mesurer*	*à mesurer*	*à mesurer*	1,4 Go
`ministral-3:14b`, sans exemple	*à mesurer*	*à mesurer*	*à mesurer*	*à mesurer*	9,1 Go

Pour les mots-clés, on donne aussi la part des messages qu'ils acceptent : l'organisateur l'estime à environ 30 %, nous la mesurons. La taille de la référence correspond à BERT-Large (340 millions de paramètres en float32). Les deux dernières lignes classent avec un LLM, la liste des intentions dans la consigne : elles montrent ce que coûterait la compréhension « tout LLM ». Le message attendu : un encodeur de 118 millions de paramètres fait aussi bien, ou presque, pour une fraction du coût.

Le seuil τ. Sur un jeu de validation (10 % de l'entraînement, tenus à part), on trace la précision des messages acceptés en fonction de la part de messages acceptés, pour τ de 0,30 à 0,95. On retient le plus petit τ qui donne au moins 97 % de précision. La courbe elle-même va dans le support : elle montre qu'on a *choisi* le compromis.

6.3 Les scénarios de bout en bout

Un scénario est une conversation complète, avec un client donné et des attentes vérifiables automatiquement.

```
# eval/scenarios/sophie_epargne.yaml
client: C03
tours:
  - client: "je voudrais mettre de cote pour mes enfants"
    attendu: {famille: epargne, demande: [horizon]}
    interdit: {demande: [age, enfants]}        # deja connus par le profil
  - client: "dans 10 ans pour leurs etudes, 100 euros par mois"
    attendu: {propose: [livret_a], ecarte: [lep]}
    interdit: {nombre_invente: true}
```

Le jeu. Trente conversations : les neuf parcours, chacun en trois variantes (formulation différente, autre client, réponse en plusieurs tours), plus trois demandes hors périmètre. Chaque membre écrit les scénarios de son module ; Sohayb maintient le programme qui les rejoue. Le jeu est rejoué à chaque intégration : **un scénario qui passait et qui échoue bloque la fusion**.

Ce qui est vérifié. La famille reconnue ; les questions posées, et surtout celles qui *ne doivent pas* l'être (une information déjà connue) ; les produits proposés et écartés ; l'action déclenchée et sa confirmation ; le passage de main ; l'absence de nombre inventé.

6.4 La formulation

Deux indicateurs. **Le taux d'échec du garde-fou**, automatique, sur toutes les réponses générées. **Une évaluation humaine courte** : pour chaque modèle candidat, du 14B au plus petit, 30 réponses notées par deux membres sur trois critères (exact, clair, ton juste), en oui ou non, **champs facultatifs** — la leçon du formulaire de Timso AI.

6.5 La frugalité : trois configurations

Le cœur de la démonstration de frugalité est une comparaison sur le même jeu de scénarios.

Configuration	Ce qu'elle fait
A — Tout LLM	`ministral-3:14b` reçoit le message, le profil et le catalogue dans sa consigne, et fait tout : comprendre, décider, rédiger. C'est ce que ferait une équipe pressée.
B — Cascade	Notre architecture complète.
C — Cascade sans LLM	La même, avec des gabarits à la place du petit LLM : la borne basse en énergie.

	Réussite	Nombres inventés	Wh / 1 000 req.	Latence p95	Go chargés	Sans LLM
A	*à mesurer*	*à mesurer*	*à mesurer*	*à mesurer*	9,1	0 %
B	*à mesurer*	*à mesurer*	*à mesurer*	*à mesurer*	3,5	*à mesurer*
C	*à mesurer*	*à mesurer*	*à mesurer*	*à mesurer*	0,5	100 %

Ce qu'on s'attend à montrer, et qu'il faudra confirmer : B atteint la qualité de A, voire mieux parce que ses décisions sont des règles ; B consomme une fraction de l'énergie de A ; C coûte encore moins mais rédige moins naturellement — ce qui justifie, mesure à l'appui, la présence d'un petit LLM. Si la mesure dit autre chose, c'est la mesure qu'on présente.

6.6 Le protocole de mesure de l'énergie

CodeCarbon mesure l'énergie de la machine entière (processeur, mémoire, GPU Nvidia par NVML). Une requête dure trop peu pour être mesurée seule : on mesure par lots.

1. Charger les modèles et faire une requête de chauffe (le chargement n'est pas compté).
2. Mesurer 60 secondes à vide : puissance de repos P_0.
3. Rejouer un lot de $N = 200$ requêtes tirées des scénarios ; énergie totale E, durée t.
4. Énergie par requête : $(E - P_0 \times t)/N$.
5. Répéter trois fois ; présenter la moyenne et l'écart.

```
from codecarbon import OfflineEmissionsTracker
suivi = OfflineEmissionsTracker(country_iso_code="FRA", measure_power_secs=1,
                                project_name="cascade-B", log_level="error")
suivi.start()
for message, client in lot:
    reply(message, client, {})
suivi.stop()
energie_kwh = suivi.final_emissions_data.energy_consumed
```

La version « hors ligne » de CodeCarbon n'interroge aucun service extérieur : cohérent avec la règle. On présente d'abord l'énergie en wattheures, puis l'équivalent CO_2 calculé par CodeCarbon pour le réseau français. Sur Jetson, si le temps le permet, la puissance est lue avec `tegrastats`.

CHAPITRE 7

L'interface et la démonstration

7.1 L'interface

Une seule page Streamlit, trois zones. La conversation à gauche ; à droite, le profil du client, le panneau « pourquoi » et le panneau « frugalité ». Le jury doit pouvoir lire la décision et son coût sans qu'on ait à les commenter.

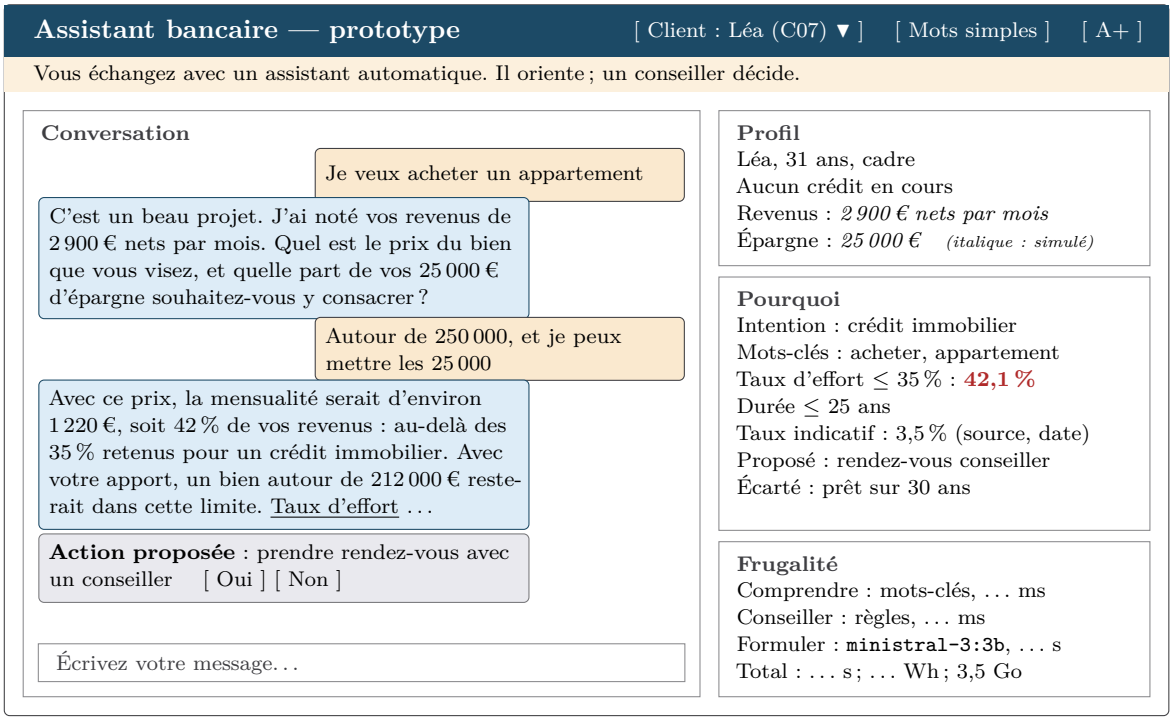


Figure 7.1 – Maquette de l'écran. Les valeurs sont des exemples ; les points de suspension sont remplis en direct par les mesures de la trace.

Accessibilité. Taille de texte réglable, contraste élevé, mode « mots simples », termes du glossaire explicables d'un clic. C'est modeste, mais c'est ce que La Banque Postale a demandé de ne jamais oublier, et ça se montre en dix secondes.

Les messages de démo. Une liste latérale contient les messages exacts du script : un clic les envoie. Pas de faute de frappe devant le jury, pas de temps perdu à taper.

7.2 Le script de la démonstration

Six minutes en direct, sur la machine fournie. Une personne pilote, une autre commente.

Temps	Scène	Ce que le jury voit	Critère
0 :00	Inès : « J'ai perdu ma carte hier soir »	L'assistant demande confirmation, met la carte en opposition, donne une référence et rassure. Panneau frugalité : **compris par les mots-clés, aucun LLM appelé**.	Métier, frugalité
1 :00	Léa : l'appartement	Il ne redemande pas les revenus ; il calcule, refuse avec le calcul, propose des leviers. Panneau pourquoi : la règle des 35 %, la ligne écartée.	Explicabilité
2 :30	Sophie puis Lucas : « Je voudrais mettre de côté »	La même phrase, deux clients, deux conseils différents, chacun avec ses raisons.	Personnalisation
3 :30	Marc : les 8 € de frais	Il retrouve les frais dans l'historique, les explique, cite le plafond légal, oriente vers l'offre clientèle fragile.	Métier, inclusion
4 :30	Julie : « Votre appli ne marche jamais ! »	Il reconnaît la frustration, ne se justifie pas, transmet au conseiller un résumé des trois contacts.	Métier
5 :15	Le bilan	Panneau frugalité cumulé ; graphique des configurations A, B et C.	Frugalité

Paul et le virement en mots simples sont dans la vidéo de secours et servent de réponse si le jury demande « et pour un client âgé ? ».

7.3 Le plan de secours

— **Une vidéo** de tout le script, enregistrée mercredi matin sur la machine de démo.

— **Un mode gabarits** : un interrupteur coupe le petit LLM. La démo continue, moins fluide mais exacte. C'est aussi la configuration C, donc ce n'est pas un aveu d'échec.

— **Une vérification réelle** d'Ollama au lancement de l'interface (pas seulement la présence d'une configuration) et des modèles préchargés avant l'entrée du jury.

— **Une répétition sur la machine de démo** mercredi entre 12h et 13h15.

CHAPITRE 8

L'organisation de l'équipe

8.1 Les principes

— **Un module, un responsable, un suppléant.** Le responsable décide dans son module ; le suppléant connaît le code assez pour le reprendre si besoin, et relit chaque fusion.

— **Des contrats figés lundi soir.** Les modules communiquent par des structures de données définies ensemble, une fois. Chacun développe contre des *bouchons* qui respectent le contrat : personne n'attend personne.

— **`main` tourne toujours.** À tout moment, `streamlit run app.py` doit lancer la démo depuis `main`.

— **Deux intégrations mardi**, à 12h30 et à 18h, avec le jeu de scénarios comme juge.

— **D'abord une solution sûre, ensuite les idées.** Jusqu'à J2, on construit ce qui est prévu. Après, on essaie les idées nouvelles, même exotiques : c'est ce que l'organisateur nous a encouragés à faire, une fois la base solide. Et on se fait plaisir.

8.2 Les trois modules

Le découpage suit la cascade, pas les filières. Chaque module contient une part de données, une part de modèle et une part de logiciel : chacun touche à l'IA, au code et à la mesure, et chacun peut présenter son module au jury avec des chiffres.

	Module 1 — Comprendre et mesurer	**Module 2 — Converser et formuler**	**Module 3 — Conseiller et agir**
Responsable	Younes	Yahya	Sohayb
Suppléant	Yahya	Sohayb	Younes
Étages	1, et la mesure transversale	2, 5, l'escalade, l'interface	3 et 4
Part données	Banking77 en français, exemples des 8 intentions	Glossaire, gabarits	Clients simulés, catalogue
Part modèle	Mots-clés, encodeur, têtes, seuil τ	Choix du petit LLM, garde-fou	Modèle d'appétence
Part logiciel	`comprendre()`, instrumentation, bancs de mesure	`reply()`, automate de dialogue, Streamlit	Moteur de règles, outils, rejeu des scénarios
Dans le pitch	Les résultats et la frugalité	Le problème, l'architecture, la démo	L'explicabilité et la conformité

8.2.1 Module 1 — Comprendre et mesurer (Younes)

Le module où se trouve le calcul lourd — inférence par lots sur DeepEirb, bancs de mesure d'énergie — et aussi un vrai travail de modélisation.

— Obtenir l'accès à DeepEirb ; traduire Banking77 (vLLM ou, à défaut, Marian sur la 3060) ; générer et faire relire les exemples des 8 nouvelles intentions ; écrire la fiche de données.

— Construire le filtre par mots-clés et sa règle de confiance ; entraîner l'encodeur et les deux têtes (famille, intention) ; choisir τ par balayage ; écrire les règles d'extraction des entités ; exposer `comprendre(message, etat)`.

— Remplir le tableau de compréhension du chapitre 6.
— Écrire l'instrumentation (`src/mesure/frugalite.py`) et le banc A/B/C ; produire le graphique du pitch.
— En bonus : faire tourner l'étage 1 et les règles sur la Jetson.

Fichiers : `data/processed/banking77_fr/`, `data/processed/intentions_fr.csv`, `src/comprendre/`, `src/mesure/`, `eval/bench_nlu.py`, `eval/bench_frugalite.py`.

8.2.2 Module 2 — Converser et formuler (Yahya)

Le module de l'orchestration : il appelle les deux autres et porte l'interface.

— Écrire l'automate de dialogue et les neuf parcours YAML ; écrire `reply()`, le point d'entrée unique de la cascade.
— Écrire les gabarits ; brancher le petit LLM via Ollama ; écrire le garde-fou ; dérouler le protocole de choix du modèle de formulation.
— Brancher l'escalade (DeepEirb ou Ollama) ; écrire le glossaire et sa recherche en mémoire.
— Construire l'interface : conversation, profil, panneaux « pourquoi » et « frugalité », mode mots simples, messages de démo ; enregistrer la vidéo de secours.

Fichiers : `src/assistant.py`, `src/converser/`, `app.py`, `data/processed/glossaire.json`.

8.2.3 Module 3 — Conseiller et agir (Sohayb)

Le module des décisions : il doit être juste, testé et lisible, ce qui en fait un module de génie logiciel autant que d'IA.

— Écrire l'adaptateur de la base clients et l'enrichissement simulé ; créer les huit clients de démonstration.
— Écrire le catalogue JSON avec sources et dates ; écrire le moteur de règles (éligibilité, pertinence, classement, raisons, produits écartés) et les calculs de crédit.
— Entraîner et évaluer le modèle d'appétence ; exposer ses trois facteurs principaux.
— Écrire les cinq outils, la confirmation et le journal.
— Écrire le programme de rejeu des scénarios ; le lancer à chaque intégration ; tenir le dépôt Git propre jusqu'au dépôt final.

Fichiers : `src/conseiller/`, `data/processed/clients.csv`, `data/processed/catalogue.json`, `eval/run_scenarios.py`, `tests/`.

8.2.4 Ce qui est commun

Chacun écrit les scénarios de son module (au moins dix). Chacun écrit les diapositives de son module. Les contrats sont écrits ensemble, lundi soir, et ne changent plus qu'à l'unanimité.

8.3 Les contrats entre modules

Un seul fichier, `src/contrats.py`, importé par tous. Les noms de champs sont en français et sans accents.

```
from dataclasses import dataclass, field

@dataclass
class Comprehension:                  # rendu par le module 1
    famille: str                      # "credit", "carte_perdue", ...
    intention: str                    # "credit_immobilier", "lost_or_stolen_card", ...
```

```
    confiance: float                  # probabilite de la famille, entre 0 et 1
    alternatives: list                # [("virement", 0.21), ...] pour la clarification
    entites: dict                     # {"montant": 250000, "lien": "fils", "objet": "voiture"}
    insatisfaction: bool = False
    modele: str = "e5-small+lr"       # ou "mots-cles", ou "ministral-3:14b" (escalade)
    exemple_proche: str = ""          # phrase d'entrainement la plus proche (explication)

@dataclass
class Proposition:                    # rendu par le module 3
    produit_id: str                   # "livret_a"
    raisons: list                     # ["Lucas a 20 ans : Livret Jeune possible (12-25 ans)"]
    sources: list                     # URL publiques du catalogue
    score: float = 0.0

@dataclass
class Conseil:                        # rendu par le module 3
    propositions: list                # [Proposition], triees
    ecartes: list                     # [("lep", "revenu au-dessus du plafond")]
    manque: list                      # ["prix_bien"] : informations a demander
    alertes: list                     # ["taux d'effort 42,1 % > 35 %"]
    faits: dict                       # tous les nombres que le texte a le droit de citer

@dataclass
class Action:                         # rendu par le module 3
    outil: str                        # "bloquer_carte"
    parametres: dict
    confirmee: bool
    resultat: dict = field(default_factory=dict)   # {"reference": "OPP-..."}

@dataclass
class Etape:                          # une ligne du panneau frugalite (module 1)
    nom: str; modele: str; latence_ms: float; tokens: int = 0

@dataclass
class Reponse:                        # rendu par le module 2, affiche par l'interface
    texte: str
    comprehension: Comprehension
    conseil: Conseil | None
    action: Action | None
    escalade: bool
    trace: list                       # [Etape]

def reply(message: str, client_id: str, etat: dict) -> tuple[Reponse, dict]: ...
```

8.4 L'arborescence du dépôt

```
hackathon-IA/
|-- app.py                      interface Streamlit                     (M2)
|-- src/
|   |-- contrats.py             structures partagees                    (tous)
|   |-- assistant.py            reply() : la cascade                    (M2)
|   |-- comprendre/             nlu.py, entites.py, tetes/              (M1)
|   |-- converser/              dialogue.py, parcours/*.yaml,
|   |                           formuler.py, garde_fou.py, glossaire.py (M2)
|   |-- conseiller/             clients.py, catalogue.py, regles.py,
|   |                           appetence.py, outils.py                 (M3)
|   `-- mesure/                 frugalite.py                            (M1)
|-- data/
```

```
|   |-- raw/                    Banking77, Bank Marketing (ignore par git)
|   `-- processed/              jeux francais, clients, catalogue, glossaire
|-- eval/
|   |-- scenarios/*.yaml        30 conversations                          (tous)
|   |-- run_scenarios.py                                                  (M3)
|   |-- bench_nlu.py, bench_frugalite.py                                  (M1)
|-- tests/                      tests unitaires des regles                (M3)
`-- rapport/                    ce document
```

Les données téléchargées sont aujourd'hui dans `data/banking77/` et `data/bank-marketing/` : elles passent dans `data/raw/`, ajouté au `.gitignore`. Les jeux préparés, petits et produits par nous, sont versionnés : ils font partie du livrable.

8.5 Le planning

	Lundi 18h–20h	**Mardi 8h30–12h30**	**Mardi 13h30–18h**	**Mardi 18h–20h (option)**	**Mercredi 8h30–12h**
Younes (M1)	Accès DeepEirb ; lancer la traduction	Mots-clés ; têtes v1 (anglais et français partiel) ; entités ; `comprendre()`	Français complet ; 8 intentions ; seuil τ ; escalade ; instrumentation	Banc A/B/C sans surveillance	Chiffres finaux ; graphique ; Jetson (bonus)
Yahya (M2)	Parcours carte ; squelette de `app.py`	Automate ; parcours carte et frais ; gabarits ; petit LLM branché	Parcours épargne, crédits, virement, insatisfaction ; garde-fou ; panneaux	Scénarios en échec	Vidéo de secours ; finitions de l'interface
Sohayb (M3)	8 clients ; catalogue v0	`clients.py` ; règles épargne et crédit ; opposition ; frais	Appétence ; produits écartés ; virement ; conseiller ; rejeu et scénarios	Scénarios en échec	Dépôt Git final ; README
Tous	Lire ce document ; contrats figés ; bouchons				Diapositives ; deux répétitions ; dépôt à 11h30
Jalon	**J0** à 20h	**J1** à 12h30 : intégration 1	**J2** à 18h : intégration 2, gel	—	**J3** à 11h30 : tout est remis

Tableau 8.1 – Le planning, par demi-journée.

Jalon	**Quand**	**Critère de passage**
J0	Lundi, 20h	`src/contrats.py` écrit et fusionné ; `streamlit run app.py` répond avec les bouchons ; la traduction est lancée (ou son repli décidé).
J1	Mardi, 12h30	Intégration 1 : Inès (carte) et Marc (frais) passent de bout en bout, avec les vrais modules.
J2	Mardi, 18h	Intégration 2 : les neuf parcours passent leurs scénarios principaux ; la trace est complète. **Gel fonctionnel** : après J2, on corrige et on mesure, on n'ajoute plus.
J3	Mercredi, 11h30	Tableaux de résultats remplis ; vidéo enregistrée ; deux répétitions chronométrées faites ; code déposé (étiquette `v1.0`) ; support remis.

8.6 Les priorités

Priorité	Contenu
Indispensable (J2)	Étage 1 mesuré en anglais et en français ; parcours carte, frais, épargne, appartement, crédit auto ; règles avec raisons et produits écartés ; les 8 clients ; petit LLM et garde-fou ; panneaux pourquoi et frugalité ; banc A/B/C.
Important	Virement en mots simples ; insatisfaction et passage de main ; jargon ; prêt étudiant ; appétence ; escalade.
Si le temps le permet	Idées nouvelles, même exotiques, encouragées par l'organisateur une fois la base sûre ; déploiement sur Jetson ; réponse dans la langue du client ; outils exposés en MCP ; saisie vocale locale (Whisper), utile à l'accessibilité.
Hors périmètre	Affinage d'un LLM ; connexion à un vrai système bancaire ; authentification ; base de données serveur.

8.7 Les règles de travail

— Branches courtes `m1/<sujet>`, `m2/<sujet>`, `m3/<sujet>`, fusionnées dans la demi-journée, après relecture du suppléant et passage des scénarios.

— Aucune donnée brute ni aucun secret dans Git ; les modèles ne sont jamais versionnés.

— Un point de cinq minutes toutes les trois heures : fait, bloqué, suivant.

— Tout résultat chiffré est noté au moment où il est obtenu, avec la commande qui l'a produit : le support se construit au fil de l'eau.

— **Définition de « fini » pour un module** : le code est dans `main`, ses scénarios passent, ses mesures sont notées, et sa diapositive est écrite.

CHAPITRE 9

Les risques et leurs parades

Risque	Prob.	Parade	Qui
DeepEirb inaccessible ou saturé lundi soir	moyenne	Traduction par Marian sur la 3060 ; escalade par `ministral-3:8b` en local. La traduction du jeu de test passe en premier.	M1
Traduction de qualité médiocre	moyenne	Glossaire dans la consigne ; contrôles automatiques ; relecture de 100 phrases ; on présente le taux mesuré plutôt que de le cacher.	M1
Le petit LLM rédige mal en français	moyenne	Gabarits pour toutes les intentions de service ; protocole de choix qui peut monter à `ministral-3:8b` si le gain est mesuré.	M2
Les mots-clés se trompent avec assurance	faible	Seules les expressions dont la précision mesurée dépasse 97 % sont gardées ; une seule famille touchée exigée ; sinon, classifieur.	M1
Le classifieur confond des familles	faible	Seuil τ, question de clarification, escalade ; taux mesurés et montrés.	M1
La base enrichie des organisateurs arrive tard ou dans un autre format	moyenne	Enrichissement simulé dès lundi ; un seul adaptateur à modifier le jour où elle arrive.	M3
L'intégration échoue tard	moyenne	Contrats figés à J0 ; bouchons ; deux intégrations datées ; scénarios comme juge.	Tous
Mémoire de la 3060 insuffisante	moyenne	Escalade déportée sur DeepEirb ou 8B ; contexte réduit à 4 096 tokens ; un seul gros modèle chargé à la fois.	M2
CodeCarbon ne voit pas le GPU	faible	Lecture directe de la puissance par NVML (`nvidia-smi`) ; même protocole par lots.	M1
La démo plante devant le jury	faible	Vidéo de secours ; mode gabarits ; vérification réelle d'Ollama ; répétition sur la machine de démo.	M2
Le temps manque	élevée	Priorités figées (chapitre 8) ; gel fonctionnel à J2 ; ce qui n'est pas indispensable est coupé sans débat.	Tous
Un chiffre réglementaire faux dans une réponse	faible	Tout chiffre vient du catalogue, avec sa source et sa date ; garde-fou sur les nombres ; relecture du catalogue par un deuxième membre.	M3

Le risque principal est le temps, pas la technique. Chaque brique de la cascade est simple ; ce qui peut échouer, c'est de vouloir tout faire. Les priorités du chapitre 8 ne sont pas indicatives : à J2, ce qui n'est pas indispensable et pas fini est abandonné.

CHAPITRE 10

Vérification : toutes les cases sont remplies

10.1 Les exigences

Chaque exigence de la section 1.7 est rattachée à un composant et à une preuve visible par le jury.

Nº	Composant	Preuve	Module
E1	Étage 1 : mots-clés, encodeur multilingue, têtes, entités	Précision sur le test français ; démo	M1
E2	Banking77 traduit, 8 intentions, glossaire, catalogue, fiche de données	Fichiers dans `data/processed/` ; taux de relecture	M1, M2, M3
E3	Parcours YAML, questions déduites du profil	Scénarios : questions attendues et interdites	M2
E4	Profil, règles d'éligibilité, appétence	Démo : même phrase, deux clients	M3
E5	Moteur de règles sur un catalogue de produits simples	Panneau pourquoi	M3
E6	Adaptateur et 8 clients ancrés sur Bank Marketing	Sélecteur de client	M3
E7	Catalogue avec source et date par fiche	Annexe B ; panneau pourquoi	M3
E8	Modèles open source servis par Ollama et vLLM, CodeCarbon hors ligne	Aucun appel sortant	Tous
E9	Protocole : descendre en taille, garder le plus petit qui tient le seuil ; escalade rare	Tableaux du chapitre 6	M1, M2
E10	Instrumentation, banc A/B/C	Panneau frugalité ; graphique du pitch	M1
E11	Raisons, produits écartés, sources, garde-fou	Panneau pourquoi ; taux du garde-fou	M2, M3
E12	Étages sans LLM en millisecondes ; petit LLM limité à 200 tokens	Latence p95 mesurée	M1, M2
E13	Outils avec confirmation : opposition, virement, conseiller	Démo Inès	M3
E14	Neuf parcours	Les 30 scénarios	Tous
E15	Glossaire ; prêt étudiant ; mode mots simples	Démo Lucas ; termes cliquables	M2
E16	Script de démo, vidéo, dépôt étiqueté `v1.0`	Jalon J3	Tous
E17	Mots simples, taille du texte, contraste ; offre clientèle fragile	Démo Marc et Paul	M2, M3

N°	Composant	Preuve	Module
E18	Mots-clés et classifieur en entrée ; un seul appel LLM, à la fin	Répartition par niveau ; part sans LLM	M1, M2
E19	Gel fonctionnel à J2, puis exploration	Planning ; priorités	Tous

10.2 Les livrables du sujet

Livrable attendu	Ce que nous livrons	Module
Données préparées en français	Banking77 traduit (13 083 phrases), 8 intentions de conseil en français, glossaire, catalogue ; fiche de données décrivant méthode et contrôles	M1
Modèle de compréhension des intentions	Mots-clés, puis encodeur `multilingual-e5-small` et deux têtes (14 familles, 85 intentions), avec seuil et escalade ; résultats sur trois jeux de test	M1
Chatbot relié à une base clients simulée	Interface Streamlit, `reply()`, 8 clients de démonstration, adaptateur prêt pour la base enrichie	M2, M3
Moteur de conseils personnalisés	Règles d'éligibilité et de pertinence, calculs de crédit, appétence, raisons et produits écartés	M3
Mesures de frugalité	Énergie, latence, taille, part sans LLM ; comparaison A/B/C ; coût de la préparation hors ligne	M1

10.3 La démarche en quatre temps

Les slides demandent une démarche en quatre temps ; le jury « évalue la démarche autant que le résultat ». Chaque temps a sa réponse et sa diapositive.

Temps	Notre réponse
Cadrer	Les neuf situations du sujet ; le constat que Banking77 couvre le service et pas le conseil ; 14 familles et 85 intentions.
Préparer	Traduction outillée et contrôlée ; 8 intentions créées ; tests écrits à la main ; enrichissement simulé déclaré comme tel ; `duration` exclue.
Concevoir	La cascade : chaque étage ne passe la main que s'il ne sait pas faire ; le gros modèle à l'instant précis.
Démontrer	Les tests officiels, les 30 scénarios, la comparaison A/B/C, la démo en direct.

CHAPITRE 11

Comparaison avec la proposition reçue

Un ami de l'équipe nous a transmis une proposition (`infos/propo.md`). Elle est solide et nous en gardons l'essentiel. Ce chapitre dit ce qu'on garde, ce qu'on change, et pourquoi.

11.1 Ce qu'on garde

— **Ne pas viser les 77 intentions comme des parcours** : quelques parcours parfaitement fonctionnels valent mieux que 77 réponses approximatives.

— **La chaîne** message, intention, données manquantes, questions, profil, règles, recommandation, explication.

— **Le LLM ne décide pas** : il comprend, extrait et reformule ; la recommandation vient de règles explicables.

— **Un contrat commun** autour d'une fonction centrale, défini dès le début.

— **Un mode sans LLM** en cas de problème, une vidéo de secours, des répétitions.

— **Des clients synthétiques et un catalogue** construits par nous.

11.2 Ce qu'on change

Point	Proposition reçue	Notre version	Pourquoi
Usage de Banking77	Traduire les catégories utiles, créer quelques exemples	Traduire tout et évaluer sur le test officiel, en anglais et en français	La qualité technique (20 %) demande des résultats « bien évalués », comparables à une référence publique
Preuve de frugalité	Mesurer latence et consommation	Comparer trois configurations, dont une « tout LLM », sur le même jeu	Sans point de comparaison, un chiffre d'énergie ne prouve pas « le plus petit modèle qui suffit »
Gros modèle	Absent	Hors ligne pour préparer les données ; en ligne en escalade rare, comptée	CGI a dit que c'est « là que vous allez innover »
Profondeur	Guider	Agir, avec confirmation (opposition, virement, transmission)	L'oral ouvrait explicitement cette possibilité
Explicabilité	Afficher les règles utilisées	Raisons, produits écartés, sources datées, facteurs d'appétence, garde-fou mesuré	15 % de la note ; le « pourquoi pas » est ce qui convainc

Point	Proposition reçue	Notre version	Pourquoi
Valeurs de La Banque Postale	Absentes	Mots simples, glossaire, offre clientèle fragile, passage de main	Accessibilité et inclusion ont été mises en avant par sa directrice SI
Bank Marketing	Profils, propension « éventuellement »	Appétence mesurée, `duration` exclue (fuite documentée)	Un point de rigueur que le jury peut vérifier
Conformité	Absente	Règlement européen sur l'IA, mention légale du crédit, transparence	Jury bancaire
Répartition	Données et métier / IA et backend / interface, mesures et slides	Trois modules qui suivent la cascade, chacun avec données, modèle et logiciel	La personne 3 cumulait l'interface, les mesures et les slides ; personne n'était responsable de l'évaluation

En résumé. La proposition reçue décrit un bon MVP. La nôtre garde son squelette et ajoute ce qui fait gagner des points sur la grille : des résultats comparables à une référence, une preuve de frugalité par comparaison, une explicabilité qui inclut le « pourquoi pas », et les valeurs du client.

CHAPITRE 12

Le pitch, et ce qu'on fait ce soir

12.1 Les quinze minutes

Trois voix, une par module : le jury entend chaque responsable parler de ce qu'il a construit.

Temps	Partie	Contenu	Qui
0 :00 – 1 :30	Le problème	Un client écrit à sa banque ; un Français sur quatre est client de La Banque Postale ; l'expérience client est sa priorité n° 1 ; la règle : open source, local, frugal.	Yahya
1 :30 – 4 :00	La démarche	Les quatre temps ; le constat sur Banking77 ; la cascade (une figure) ; le gros modèle à l'instant précis.	Yahya
4 :00 – 10 :00	La démonstration	Le script du chapitre 7.	Yahya pilote, Sohayb commente
10 :00 – 12 :30	Les résultats	Compréhension sur les trois jeux de test ; scénarios ; tableau A/B/C ; coût de la préparation hors ligne.	Younes
12 :30 – 14 :00	L'explicabilité	Raisons et produits écartés ; garde-fou ; règlement européen sur l'IA ; mention légale.	Sohayb
14 :00 – 15 :00	Limites et suite	Ce qui est simulé ; ce qu'il faudrait pour 17 000 points de contact.	Younes

12.2 Trois messages

1. « Notre assistant comprend souvent avec de simples mots-clés, sinon avec 118 millions de paramètres ; il décide avec des règles que le client peut lire ; il n'appelle un LLM qu'une fois, à la fin, pour mettre en mots ce qui est déjà calculé. »
2. « Nous l'avons mesuré contre une version où un LLM de 14 milliards de paramètres fait tout. » (suivi des chiffres)
3. « Chaque conseil dit pourquoi — et pourquoi pas. »

12.3 Les questions probables du jury

Question	Réponse préparée
Pourquoi ne pas tout confier à un LLM ?	Parce qu'on l'a mesuré : la configuration A fait tout avec un LLM de 14 milliards de paramètres ; voici sa qualité, son énergie et sa latence face à la cascade.
Comment mesurez-vous l'énergie ?	CodeCarbon en mode hors ligne, par lots de 200 requêtes, puissance de repos soustraite, trois répétitions. Une requête seule est trop courte pour être mesurée honnêtement.
Et si le classifieur se trompe ?	En dessous du seuil τ, il ne devine pas : il pose une question fermée, puis escalade. τ a été choisi par balayage pour 97 % de précision sur les messages acceptés. Voici la courbe.

Question	Réponse préparée
Le LLM peut-il inventer un taux ?	Il ne reçoit que des faits calculés, et chaque nombre de sa réponse est contrôlé contre ces faits ; en cas d'écart, la réponse gabarit s'affiche. Voici le taux d'échec du garde-fou.
Pourquoi Ministral ?	Parce qu'en descendant depuis le 14B, c'est le plus petit qui tient notre seuil de qualité en français — voici la courbe — et qu'il est européen. Si un plus petit avait suffi, le protocole l'aurait retenu.
Des mots-clés, en 2026 ?	Oui : ils traitent une part mesurée des demandes pour un coût quasi nul, et ils disent quand ils ne sont pas sûrs. Le reste passe au classifieur. Moins de LLM, plus d'algorithmes.
Bank Marketing, ce sont des données portugaises de 2008 ?	Oui. Elles ancrent des profils réalistes et donnent un signal d'appétence faible, présenté comme tel. L'adaptateur permet de brancher une vraie base sans toucher au reste.
Et la conformité ?	Données simulées et traitement local. Le règlement européen classe à haut risque la notation de solvabilité : nous n'en faisons pas, un conseiller décide. Transparence : l'utilisateur sait qu'il parle à une IA. Mention légale du crédit.
Comment passer à 17 000 bureaux ?	Le coût par requête est mesuré, donc extrapolable. Les étages 1 à 4 tournent sur CPU ; seul le petit LLM a besoin d'un GPU, et un serveur partagé suffit. Les pistes : voix locale et réponse dans la langue du client, dans la ligne de l'outil multilingue annoncé pour novembre.
Pourquoi pas d'affinage ?	Deux jours, des GPU partagés, et une tête de classification entraînée en secondes qui suffit. C'est aussi la conclusion d'un système en production que nous avons construit : la recherche bat l'affinage quand le modèle de base évolue vite.
Que se passe-t-il hors périmètre ?	L'assistant le dit, et propose un conseiller. Il ne fait pas semblant.

12.4 Ce qu'on fait ce soir

1. Lire la page de synthèse et le chapitre 8 (vingt minutes) ; valider ou amender la répartition, puis ne plus y revenir.
2. Écrire `src/contrats.py` ensemble (trente minutes).
3. Rendre le dépôt GitHub privé : il est public, et il va contenir des éléments tirés de supports marqués « Interne ».
4. Déplacer les données téléchargées dans `data/raw/` et l'ajouter au `.gitignore`.
5. **Younes** : écrire à Denis Barthou pour DeepEirb et le modèle vLLM ; lancer la traduction, ou décider du repli.
6. **Yahya** : squelette de `app.py` et de `reply()` avec bouchons ; parcours carte.
7. **Sohayb** : les 8 clients et le catalogue v0 ; squelette du rejeu des scénarios.
8. En filaire, télécharger `ministral-3:3b`, `qwen3:1.7b`, `gemma3:1b` et `multilingual-e5-small` sur un poste de la salle.
9. Vérifier J0 avant de partir : `streamlit run app.py` répond.

ANNEXE A

Taxonomie des intentions

Les 77 intentions de Banking77, rangées en neuf familles (vérifié par script : chacune une fois et une seule), puis les huit intentions que nous créons.

Famille	Intentions
carte_perdue (4)	lost_or_stolen_card, compromised_card, card_swallowed, lost_or_stolen_phone
carte_usage (10)	card_not_working, contactless_not_working, pin_blocked, change_pin, activate_my_card, card_about_to_expire, card_acceptance, declined_card_payment, virtual_card_not_working, pending_card_payment
carte_commande (12)	card_arrival, card_delivery_estimate, order_physical_card, get_physical_card, getting_spare_card, getting_virtual_card, get_disposable_virtual_card, disposable_card_limits, card_linking, visa_or_mastercard, supported_cards_and_currencies, apple_pay_or_google_pay
frais_contestation (14)	extra_charge_on_statement, card_payment_fee_charged, transfer_fee_charged, cash_withdrawal_charge, exchange_charge, top_up_by_card_charge, top_up_by_bank_transfer_charge, transaction_charged_twice, card_payment_not_recognised, direct_debit_payment_not_recognised, cash_withdrawal_not_recognised, request_refund, Refund_not_showing_up, reverted_card_payment?
virement (10)	transfer_into_account, cancel_transfer, pending_transfer, transfer_timing, failed_transfer, declined_transfer, beneficiary_not_allowed, transfer_not_received_by_recipient, receiving_money, balance_not_updated_after_bank_transfer
compte_identite (8)	edit_personal_details, verify_my_identity, why_verify_identity, unable_to_verify_identity, verify_source_of_funds, passcode_forgotten, terminate_account, age_limit
especes (5)	atm_support, pending_cash_withdrawal, declined_cash_withdrawal, wrong_amount_of_cash_received, balance_not_updated_after_cheque_or_cash_deposit
change_etranger (6)	exchange_rate, card_payment_wrong_exchange_rate, wrong_exchange_rate_for_cash_withdrawal, exchange_via_app, fiat_currency_support, country_support
alimenter_compte (8)	automatic_top_up, pending_top_up, top_up_limits, top_up_reverted, topping_up_by_card, top_up_failed, verify_top_up, top_up_by_cash_or_cheque
epargne (1)	epargne_projet
credit (3)	credit_immobilier, credit_conso, pret_etudiant
virement (+1)	faire_virement
aide (1)	question_definition
insatisfaction (1)	insatisfaction
conversation (1)	hors_sujet

Total : 14 familles, 85 intentions. Les noms `Refund_not_showing_up` et `reverted_card_payment?` sont repris tels qu'ils figurent dans Banking77.

ANNEXE B

Le catalogue de produits

Produits simples, conditions publiques. **Chaque fiche du fichier JSON porte la source publique et la date du relevé** ; les valeurs ci-dessous sont à vérifier à la source le jour de la saisie, et les taux réglementés, qui changent, n'y figurent volontairement pas.

Produit	Pour qui	Plafond, limites	Argent disponible	Convient pour
Livret A	Tout le monde, mineurs compris ; un par personne	22 950 €	Oui	Épargne de précaution ; épargne d'un enfant
LDDS	Majeurs domiciliés fiscalement en France ; un par personne	12 000 €	Oui	Compléter le Livret A
LEP	Revenu fiscal de référence sous un plafond annuel (à relever)	10 000 €	Oui	Revenus modestes : taux plus élevé
Livret Jeune	12 à 25 ans	1 600 €	Oui	Premier livret d'un jeune
PEL	Tout le monde ; versements réguliers obligatoires	61 200 €	Non : un retrait clôt le plan	Projet immobilier à plusieurs années
CEL	Tout le monde	15 300 €	Oui	Petit projet, complément du PEL
Crédit immobilier	Majeurs	Mensualités $\leq$ 35 % des revenus nets, assurance comprise ; durée $\leq$ 25 ans (27 dans certains cas)	—	Achat d'un logement ; décision par un conseiller
Prêt à taux zéro	Primo-accédants, sous conditions de ressources et de zone	Selon conditions	—	Complément d'un crédit immobilier ; éligibilité vérifiée par un conseiller
Prêt personnel	Majeurs	Capacité de remboursement ; mention légale obligatoire	—	Voiture, travaux, équipement
Prêt étudiant	Étudiants majeurs	Montant et caution selon l'offre ; remboursement différé possible ; version garantie par l'État sous conditions	—	Financer ses études

Produit	Pour qui	Plafond, limites	Argent disponible	Convient pour
Offre clientèle fragile	Personnes en situation de fragilité financière	Tarif mensuel plafonné ; commission d'intervention limitée à 4 € par opération et 20 € par mois	—	Inclusion ; proposée par un conseiller
Opposition carte (service)	Tout titulaire d'une carte	—	Immédiat	Perte, vol, fraude

Règle générale sur les frais. Hors offre clientèle fragile, la commission d'intervention est plafonnée par la loi à 8 € par opération et 80 € par mois (article R312-4-1 du Code monétaire et financier). C'est un plafond, pas un prix : le montant réellement facturé est celui de la grille tarifaire de la banque, à relever sur son site.

ANNEXE C

Le détail des parcours

P : information lue dans le profil (confirmée si simulée). Q : question posée au client. E : entité extraite du message.

Parcours	Informations	Règles, outils	Conclusion
Carte perdue	Carte concernée (P ; Q s'il y en a plusieurs) ; perte ou vol (Q) ; quand (E)	`bloquer_carte`, avec confirmation	Référence, heure ; rassurer ; proposer une nouvelle carte ; rappel : ne jamais communiquer son code
Frais	Période (E ou P) ; frais visé (Q s'il y en a plusieurs)	`expliquer_frais` ; plafond légal	Explication datée ; si les incidents se répètent, orientation vers l'offre clientèle fragile ; transmission si contestation
Virement	Bénéficiaire (P ; Q) ; montant (E ; Q) ; date (Q, immédiat par défaut)	`preparer_virement` ; solde suffisant ; bénéficiaire enregistré	Récapitulatif, confirmation, référence ; mode mots simples ; rappel contre l'arnaque
Épargne	Pour qui (P : enfants ; Q) ; horizon (Q) ; montant mensuel (Q) ; épargne existante (P)	Éligibilité (âge, revenu, plafonds atteints) ; pertinence (horizon court : livrets ; projet immobilier : PEL, CEL) ; appétence	Propositions classées avec raisons ; produits écartés
Crédit immobilier	Revenus (P) ; crédits en cours (P) ; prix (Q) ; apport (P, confirmé)	35 % ; 25 ans ; frais de notaire estimés ; capacité	Estimation, leviers, rendez-vous ; mention légale
Crédit à la consommation	Objet (E) ; montant (Q) ; durée (Q) ; revenus et crédits (P)	Taux d'effort, crédit en cours compris ; reste à vivre (paramètre interne)	Estimation prudente ; mention légale ; rendez-vous
Prêt étudiant	Statut (P) ; études et durée (Q) ; montant (Q) ; caution possible (Q)	Éligibilité (majeur, étudiant)	Orientation vers le prêt étudiant ; Livret Jeune ; rendez-vous
Jargon	Terme (E, par le glossaire)	Recherche dans le glossaire, en mémoire	Fiche courte ; proposition d'un exemple
Insatisfaction	Contacts du jour (P)	Règle des trois contacts ; ton	Excuses ; reformulation du problème ; `transmettre_conseiller` avec résumé

ANNEXE D

Le glossaire

Fiches courtes, écrites par nous et relues ; c'est le texte que l'assistant affiche, sans LLM.

Terme	Explication en mots simples
Agios	Les intérêts et frais que la banque facture quand votre compte est à découvert.
Apport personnel	L'argent que vous mettez vous-même dans un achat, sans l'emprunter.
Assurance emprunteur	Une assurance qui rembourse tout ou partie de votre crédit si vous ne pouvez plus le faire (décès, invalidité…). Elle est presque toujours demandée pour un crédit immobilier.
Commission d'intervention	Des frais facturés quand la banque doit traiter une opération qui pose problème, par exemple un paiement alors que votre solde est insuffisant. La loi les plafonne.
Découvert autorisé	La possibilité, prévue avec votre banque, d'avoir un solde négatif jusqu'à un certain montant. Il coûte des agios.
Épargne de précaution	Une réserve d'argent disponible à tout moment pour faire face à un imprévu ; on conseille souvent trois à six mois de dépenses.
Frais de notaire	Les taxes et frais payés lors de l'achat d'un logement, en plus du prix : environ 7 à 8 % dans l'ancien, 2 à 3 % dans le neuf.
IBAN	Le numéro qui identifie un compte bancaire ; il faut le donner pour recevoir un virement.
LDDS	Livret de développement durable et solidaire : un livret d'épargne disponible, sans impôt sur les intérêts, plafonné à 12 000 €, réservé aux majeurs.
LEP	Livret d'épargne populaire : un livret mieux rémunéré, réservé aux personnes dont les revenus sont sous un plafond.
Livret A	Le livret d'épargne le plus courant : argent disponible à tout moment, intérêts sans impôt, taux fixé par l'État, plafond de 22 950 €.
Livret Jeune	Un livret pour les 12–25 ans, plafonné à 1 600 €.
Opposition	Le blocage définitif d'une carte perdue ou volée, pour que personne ne puisse s'en servir.
PEL	Plan épargne logement : on verse régulièrement pendant plusieurs années, en vue d'un projet immobilier ; un retrait ferme le plan.
Prélèvement	Un paiement demandé directement à votre banque par une entreprise que vous avez autorisée (énergie, téléphone…).
Reste à vivre	Ce qui vous reste chaque mois une fois payés vos charges et vos crédits.
TAEG	Taux annuel effectif global : le coût total d'un crédit (intérêts, frais, assurance obligatoire) exprimé en pourcentage par an. C'est le chiffre qui permet de comparer deux offres.
Taux d'endettement	La part de vos revenus qui part chaque mois dans vos crédits. Pour un crédit immobilier, elle ne doit pas dépasser 35 %.

ANNEXE E

Commandes utiles

Ollama sur un poste de la salle (d'après les slides de Denis Barthou).

```
export PATH=/opt/ollama/bin:${PATH}
export OLLAMA_MODELS=/opt/ollama/models
export OLLAMA_CONTEXT_LENGTH=4096          # au plus juste (16384 par defaut sur les slides)
ollama serve &                             # un seul serveur par machine
ollama pull ministral-3:3b                 # en filaire
ollama list
```

Appel à Ollama avec mesure. La réponse contient `prompt_eval_count`, `eval_count` et les durées en nanosecondes, ce qui alimente la trace.

```
curl -s localhost:11434/api/chat -d '{
  "model": "ministral-3:3b",
  "messages": [{"role": "system", "content": "..."},
               {"role": "user", "content": "..."}],
  "stream": false,
  "keep_alive": "30m",
  "options": {"temperature": 0.2, "num_ctx": 4096, "num_predict": 200}
}'
# Pour un modele qui raisonne (qwen3) : ajouter  "think": false
```

Serveur vLLM sur DeepEirb. vLLM expose une API compatible OpenAI ; l'adresse et le nom du modèle sont donnés par Denis Barthou.

```
curl -s http://<deepeirb>:<port>/v1/chat/completions \
  -H "Content-Type: application/json" \
  -d '{"model": "<modele>", "temperature": 0,
       "messages": [{"role": "user", "content": "Traduis en francais ..."}]}'
```

Lancer l'interface et les mesures. Depuis la racine du dépôt, une fois les modules en place :

```
python3 -m venv .venv && source .venv/bin/activate
pip install sentence-transformers scikit-learn streamlit pyyaml codecarbon pandas
streamlit run app.py
python eval/run_scenarios.py          # rejoue les 30 scenarios
python eval/bench_nlu.py              # tableau de comprehension
python eval/bench_frugalite.py A B C  # comparaison des configurations
```