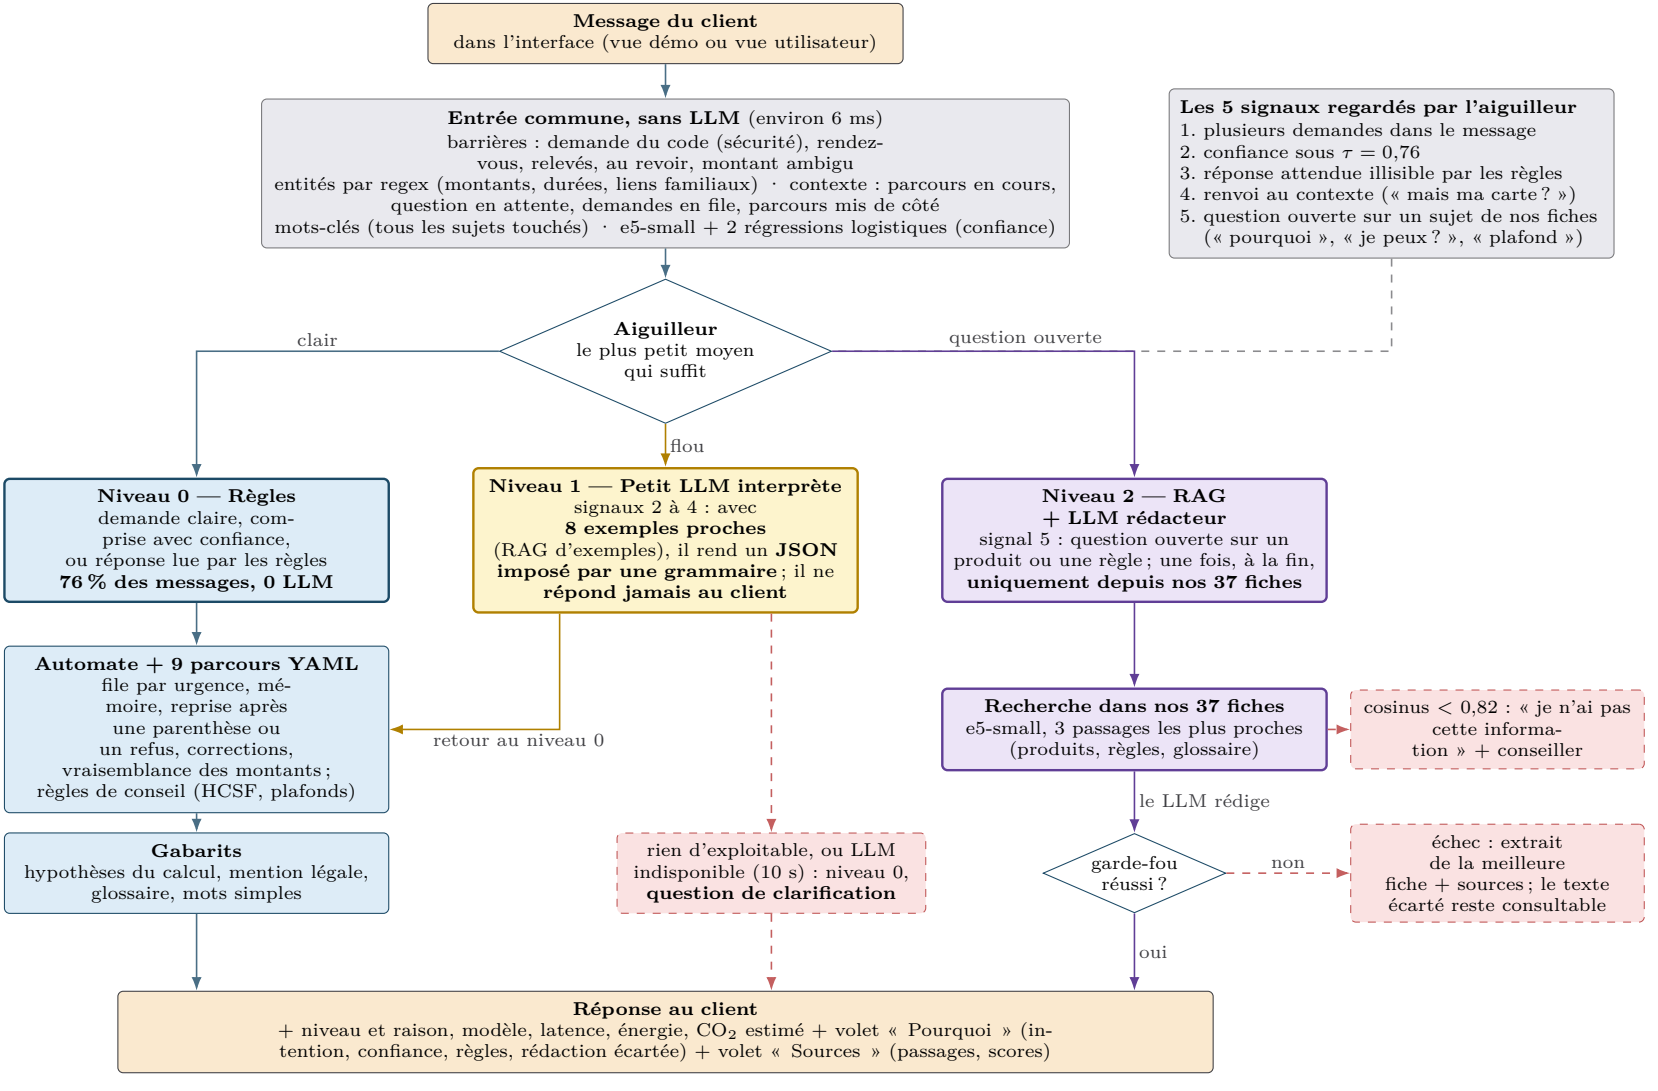
L'aiguilleur : le plus petit moyen qui suffit, message par message

Vue d'ensemble — chaque niveau est détaillé dans les pages suivantes



niveau 0, règles · niveau 1, petit LLM qui comprend · niveau 2, RAG et LLM qui rédige · replis sûrs : jamais de devinette

Un seul modèle pour les niveaux 1 et 2 : `qwen3:1.7b` (1,4 Go). La décision est prise à chaque message : une conversation passe de 1 à 2, puis à 0.

Niveau 0 — Règles : la majorité des messages, sans LLM

Le début du scénario de démonstration (Inès, C01) — à gauche la conversation, à droite ce qui se passe

Client : J'ai perdu ma carte et je veux faire un virement.

mots-clés : **2 sujets** (carte perdue, virement) → file par urgence : 1. carte perdue, 2. virement

Assistant : Je comprends, il faut agir vite. Faites opposition tout de suite : dans votre espace bancaire sécurisé, rubrique Opposition, ou en appelant votre conseiller. [...] Rappel : la banque ne vous demandera jamais votre code confidentiel. Passons maintenant à votre autre demande : un virement. [...] À qui voulez-vous envoyer l'argent ?

parcours « carte perdue » : consigne **immédiate**, aucun accès au compte (périmètre du kick-off), puis la demande suivante de la file : le virement

Client : c'est pour mon papa
(le « oui » qui le précède passe au niveau 1 : page suivante)

réponse attendue lue par les règles : « papa » → bénéficiaire = père (mémorisé)

Assistant : Quel montant voulez-vous envoyer ?

Client : 100000000

vraisemblance : au moins 10 fois les revenus mensuels → alerte, avec le solde du profil (1 450 €)

Assistant : Attention : 100 000 000 €, c'est un montant très inhabituel, bien au-delà de votre solde (1 450 €) : vérifiez-le avant de valider. Pour effectuer ce virement, utilisez votre espace bancaire sécurisé [...] Je ne peux pas accéder à votre compte ni exécuter le virement.

parcours « virement » terminé : orientation vers l'espace sécurisé, sans accès au compte

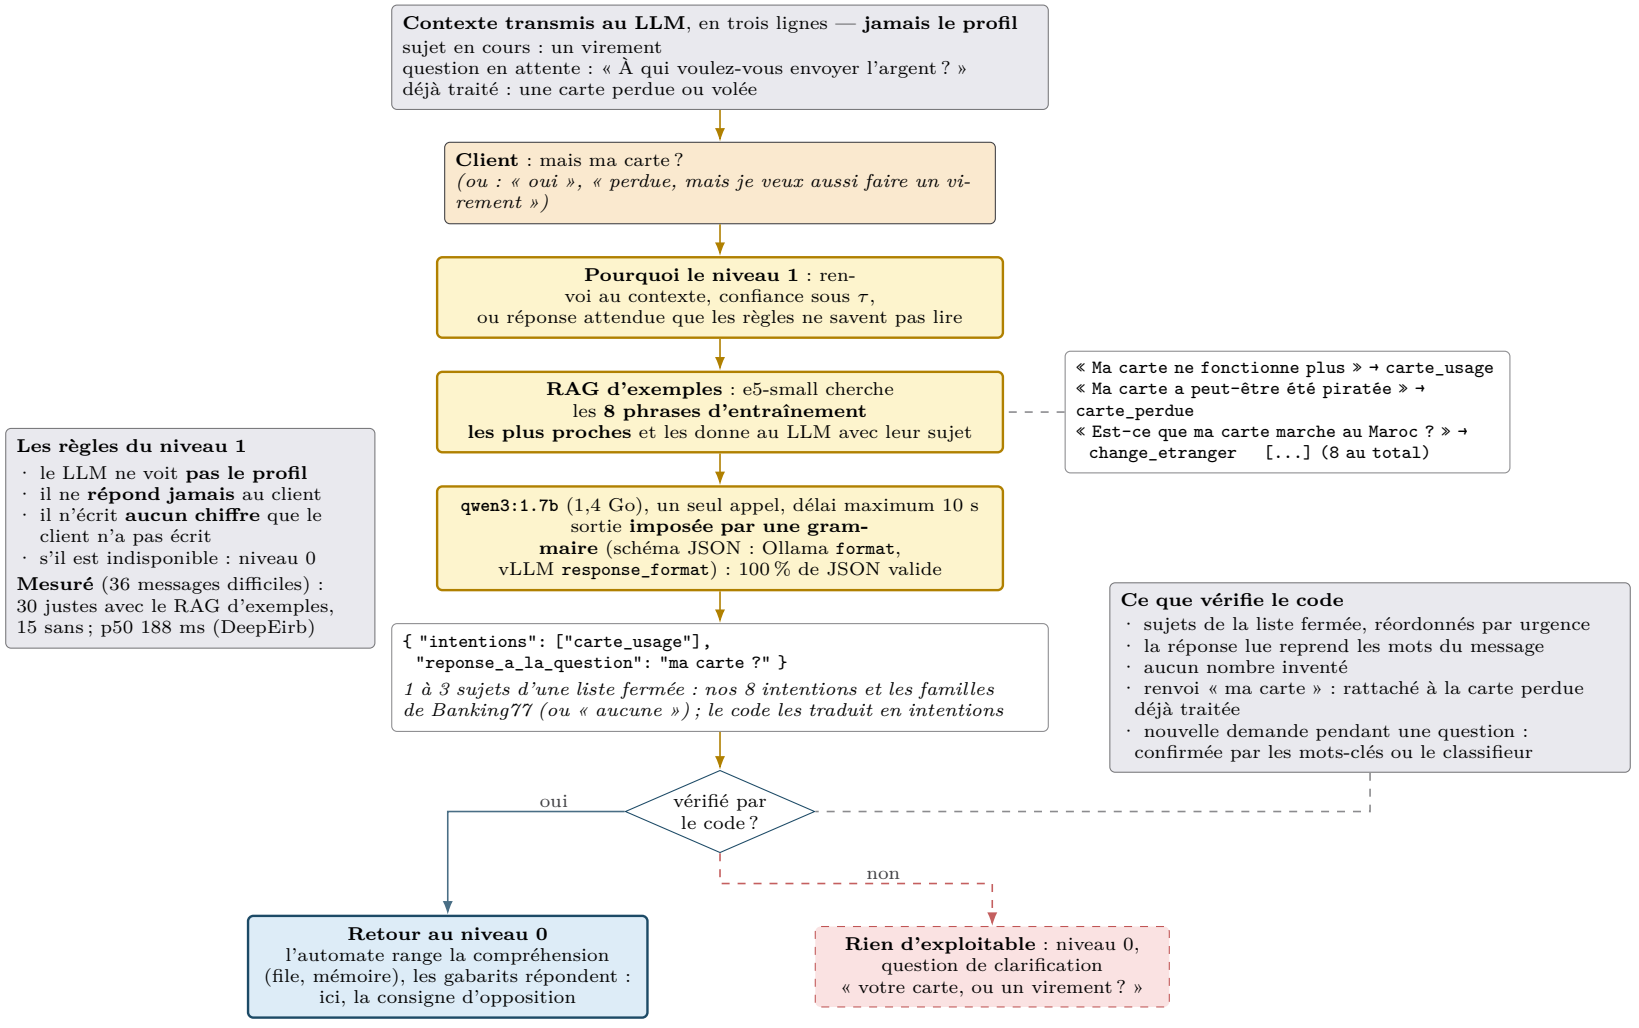
Ce qui travaille au niveau 0

- barrières : demande du code, rendez-vous, relevés
- automate de dialogue et 9 parcours YAML
- file des demandes, par ordre d'urgence
- mémoire : reprise après une parenthèse
- reprise après un refus (« finalement oui »)
- corrections (« plutôt 8000 ») : conseil recalculé
- vraisemblance des montants
- règles de conseil (HCSF, plafonds)
- gabarits, glossaire, mots simples

Coût : 0 LLM, quelques ms ; 0,4 Wh pour 1 000 messages (CodeCarbon)

Niveau 1 — Un petit LLM qui comprend, sans répondre

Il remplace la devinette par une compréhension structurée, que le code vérifie avant de s'en servir



Niveau 2 — RAG : chercher dans nos fiches, puis rédiger en citant

Le même encodeur que pour comprendre ; un LLM seulement quand il faut rédiger, et sous garde-fou

Au démarrage de l'application, une fois (environ 1 s)

37 fiches sourcées
11 produits du catalogue,
4 règles (HCSF,
notaire, frais),
18 termes du glossaire,
4 fiches écrites à la main

→ **Une fiche, un passage**
avec sa source
et sa date

→ **e5-small**
préfixe `passage:`
(déjà chargé : aucun
modèle en plus)

→ **Index en mémoire**
37 vecteurs,
sans base vectorielle

Client : Je peux retirer de mon PEL avant 4 ans ?

e5-small, préfixe `query:`, similarité avec chaque passage ;
recherche hybride :
bonus si la question nomme le sujet

comparaison

3 passages les plus proches, avec leur score

cosinus ≥ 0,82 ?

non → « Je n'ai pas cette information dans mes fiches » + conseiller — jamais d'invention

oui

`qwen3:1.7b` rédige, une fois, délai max 20 s
consigne : répondre **uniquement** avec les passages, les citer [1] [2], rester bref

garde-fou réussi ?

oui → **Assistant** : Oui, mais les fonds ne sont pas définitivement bloqués. Le retrait anticipé entraîne la clôture et des conséquences selon l'ancienneté [1]. Revenons à votre virement : quel montant voulez-vous envoyer ?
Sources : [1] Plan épargne logement (Service-Public, 27/10/2026) ; [2] PEL (glossaire) ; [3] LEP

non → **Repli** : « D'après nos fiches : » l'extrait de la meilleure fiche, avec ses sources, sans LLM. Le texte écarté est montré dans « Pourquoi », mots absents surlignés

Le garde-fou
- **tous les chiffres** viennent des passages
- **fidélité** : au moins 80 % des mots de la réponse viennent des passages
- aucune formule interdite, longueur plausible
- une citation (ajoutée si la réponse est fidèle)

Quand le niveau 2 ?
- question ouverte sur un produit ou une règle, hors parcours
- « pourquoi ? » après un conseil : les passages sont les phrases du conseil (« Votre simulation »)

Les chiffres restent ceux des fiches et des règles : le LLM ne calcule rien

Mesuré (22 questions, DeepEirb) :
bonne fiche dans les 3 passages : 18/18
hors de nos fiches, refusé : 4/4
réponses justes : 22/22 ; p50 391 ms

L'interface de la démo, dans le style de Timso AI

Page web (FastAPI + HTML), thème « Bordeaux & lin » : vue démo (tout voir) ou vue utilisateur (les messages seuls) ; chaque réponse montre son niveau, sa raison, son énergie, son CO_2 et ses sources ; la barre de scénario joue la démo d'un clic

