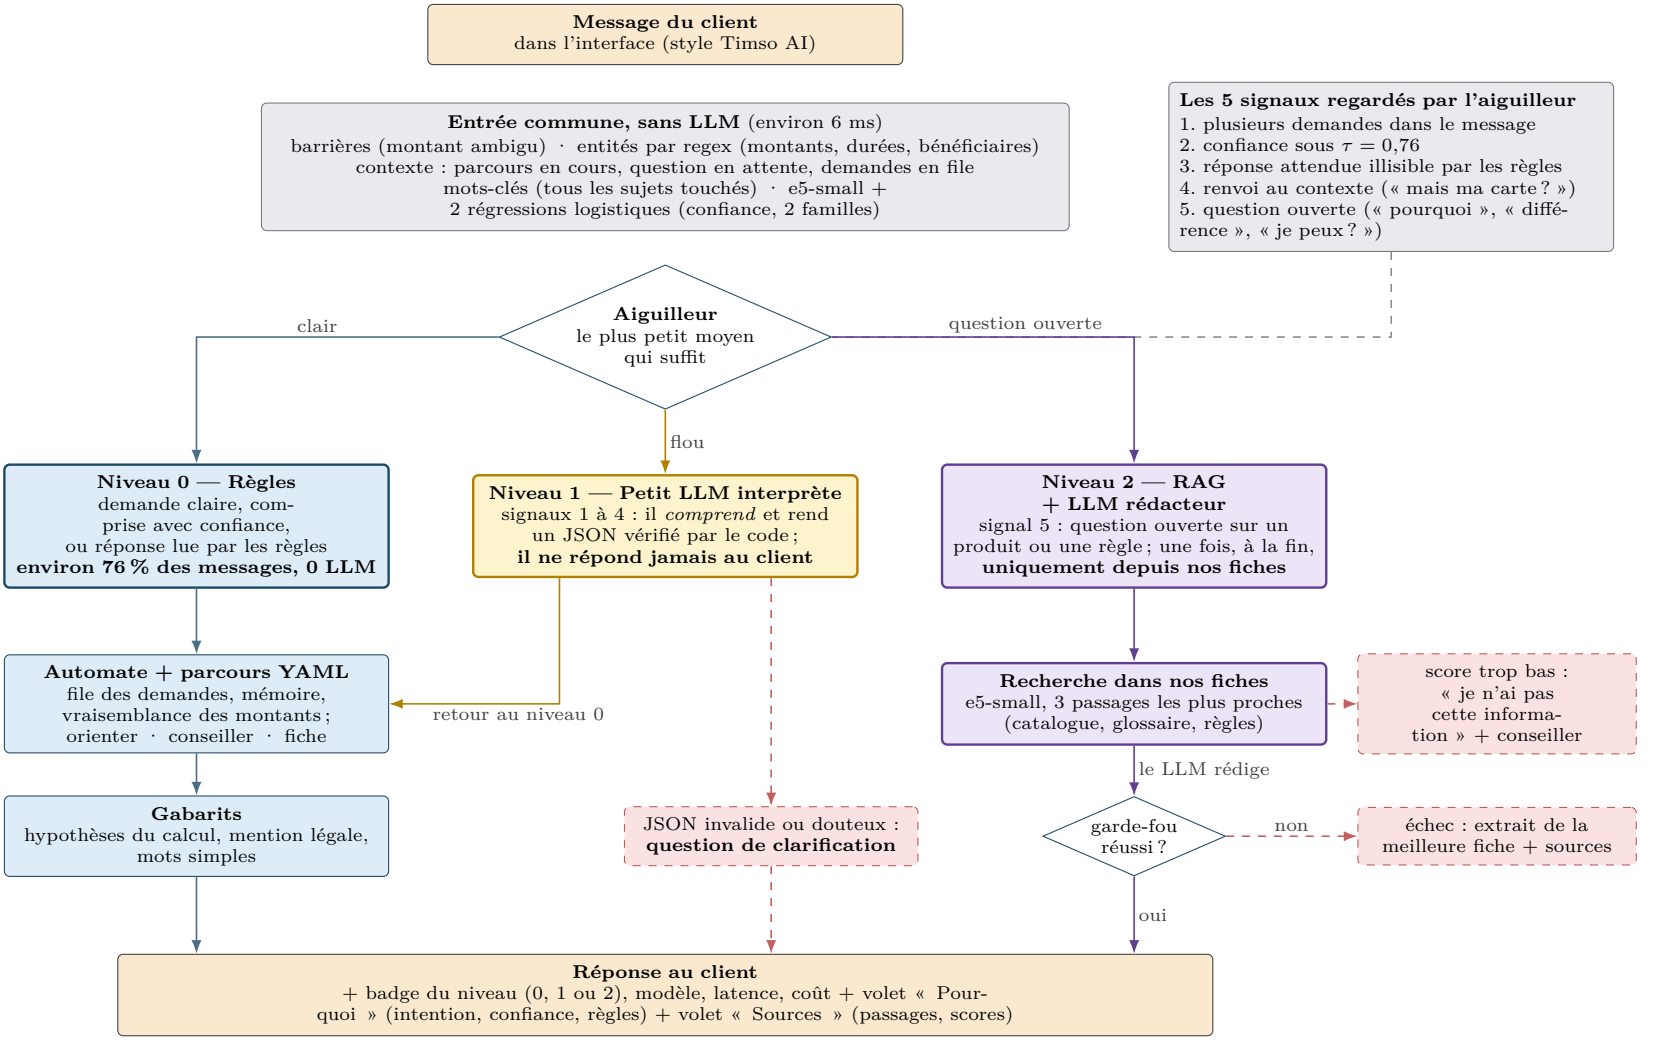
L’aiguilleur : le plus petit moyen qui suffit, message par message

Vue d’ensemble — chaque niveau est détaillé dans les pages suivantes



Si le LLM ne répond pas (serveur coupé, délai dépassé), le message retombe au niveau 0 ou en clarification.

Niveau 0 — Règles : la majorité des messages, sans LLM

Votre test, tel qu'il se déroulera après les corrections — à gauche la conversation, à droite ce qui se passe

Client : J'ai perdu ma carte et je veux faire un virement.

mots-clés : **2 sujets** (carte perdue, virement) → file par urgence : 1. carte perdue, 2. virement

Assistant : Je comprends, il faut agir vite. Faites opposition tout de suite : dans votre espace bancaire sécurisé, rubrique Opposition, ou en appelant votre conseiller. [. . .]
Passons à votre virement : à qui voulez-vous envoyer l'argent ?

parcours « carte perdue » : consigne **immédiate**, sans demander « perdue ou volée ? » puis la demande suivante de la file : le virement

Client : mon père

réponse attendue lue par les règles : bénéficiaire = père (mémorisé)

Assistant : Quel montant voulez-vous envoyer ?

Client : 100000000

vraisemblance : 100 000 000 € comparés au solde (1 450 €) et aux revenus du profil → alerte

Assistant : Ce montant dépasse largement votre solde (1 450 €) : vérifiez-le. Pour faire ce virement, utilisez votre espace bancaire sécurisé ; je n'ai aucun accès à votre compte.

parcours « virement » terminé : orientation sans accès au compte (périmètre du kick-off)

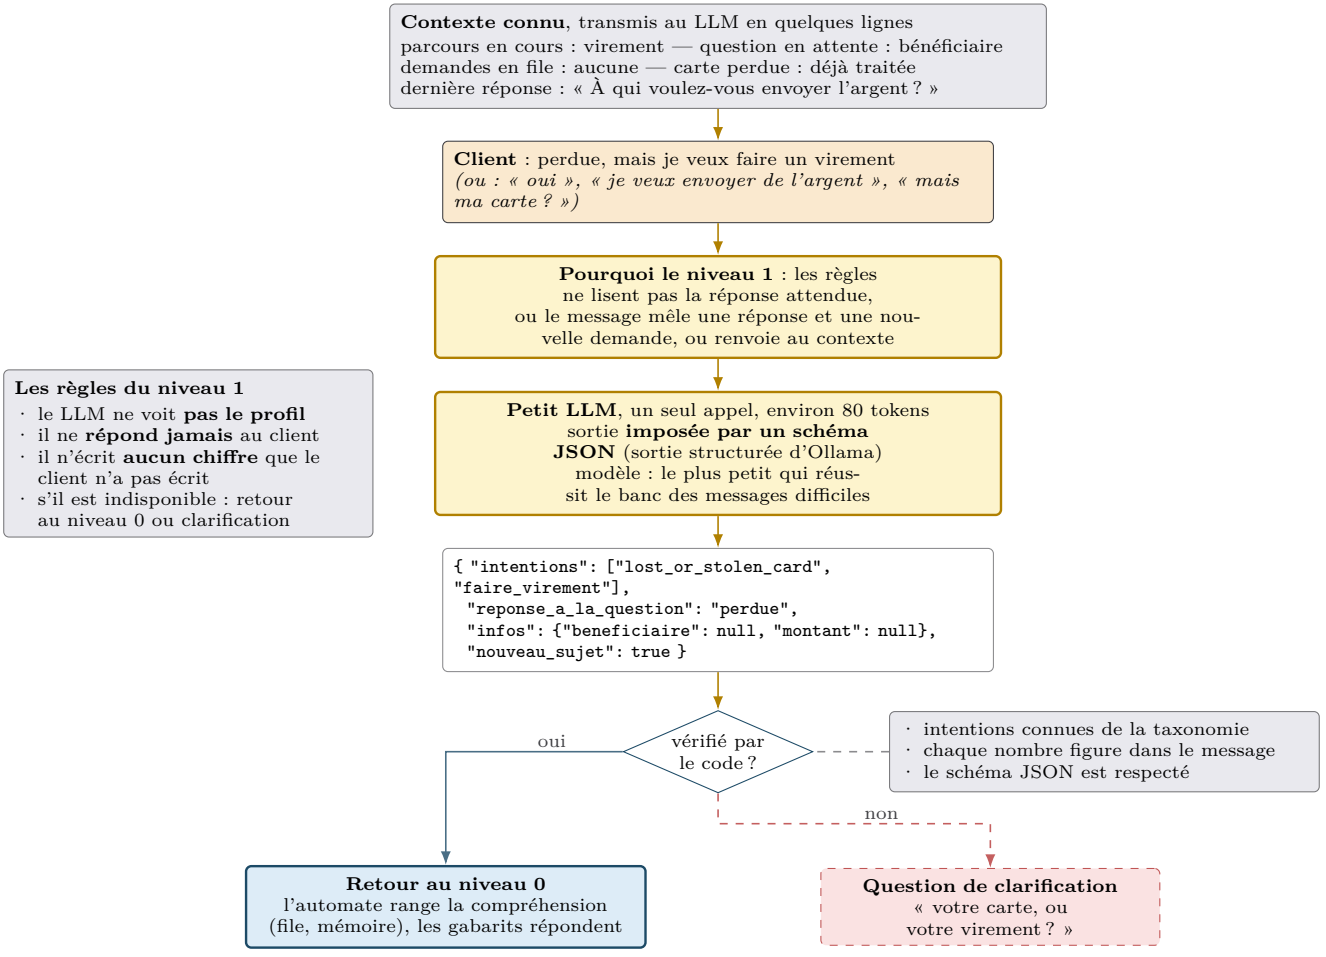
Ce qui travaille au niveau 0

- automate de dialogue (`dialogue.py`)
- 9 parcours YAML
- **file des demandes** (nouveau)
- **mémoire par parcours** (nouveau)
- **vraisemblance des montants** (nouveau)
- règles de conseil (M3)
- gabarits, glossaire, mots simples

Coût : 0 LLM, quelques ms, moins de 0,5 Wh pour 1 000 messages

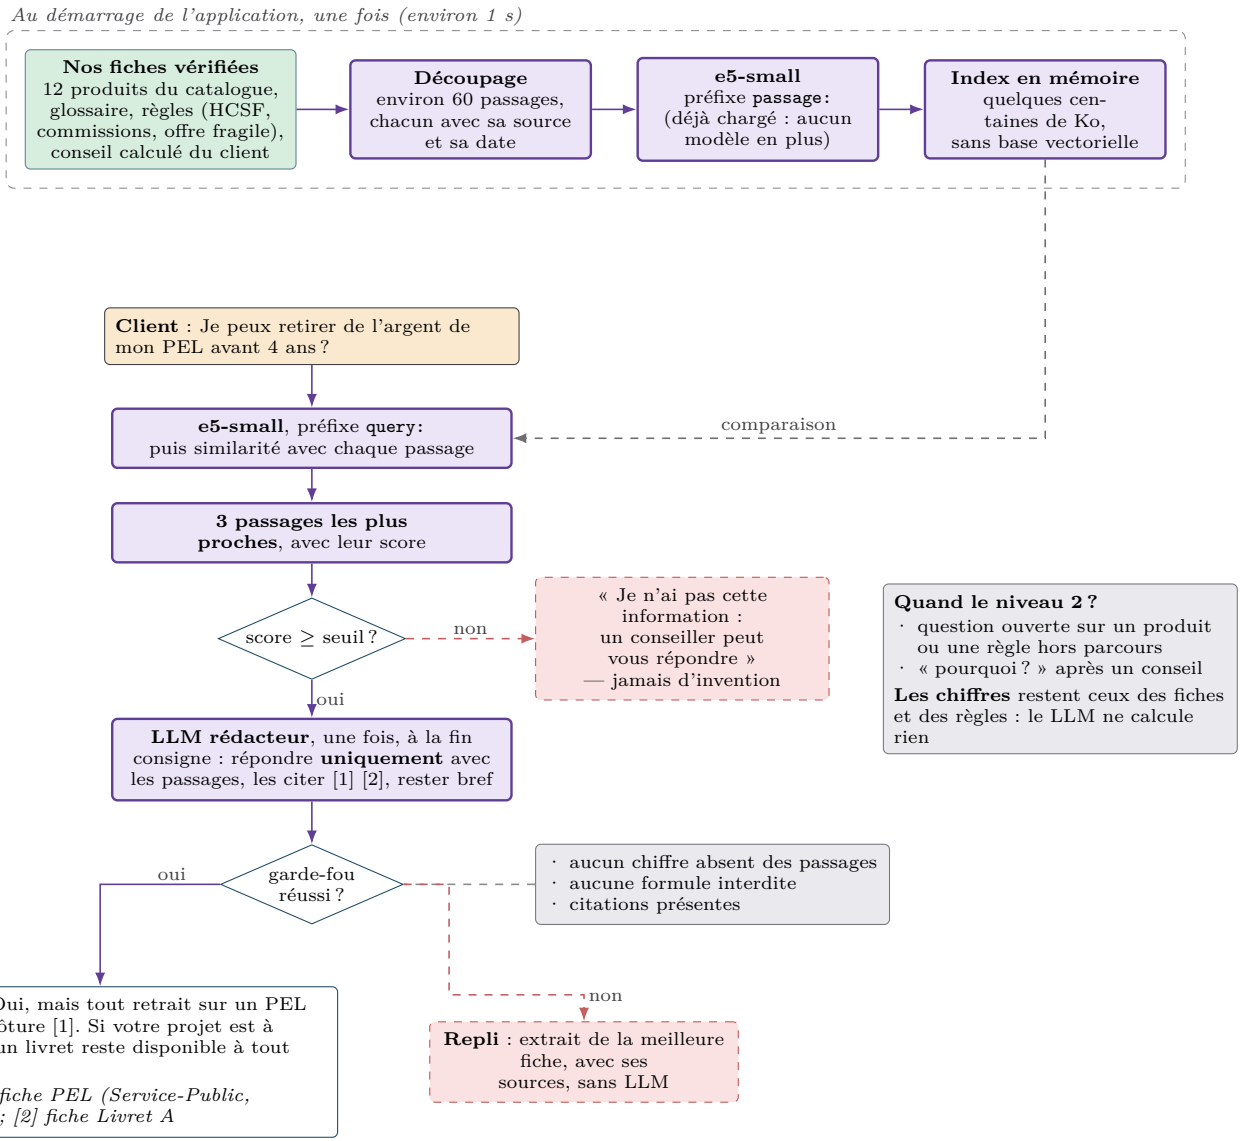
Niveau 1 — Un petit LLM qui comprend, sans répondre

Il remplace la devinette par une compréhension structurée, que le code vérifie avant de s'en servir



Niveau 2 — RAG : chercher dans nos fiches, puis rédiger en citant

Le même encodeur que pour comprendre ; un LLM seulement quand il faut rédiger, et sous garde-fou



L’interface de la démo, dans le style de Timso AI

Page web (FastAPI + HTML), thème sombre : chaque réponse montre son niveau, son coût, son raisonnement et ses sources

