Un assistant bancaire frugal, explicable, et qui agit

Comprendre, personnaliser, conseiller — avec le plus petit calcul qui suffit

Yahya Sohayb Younes

Hackathon IA — La Banque Postale × CGI × ENSEIRB-MATMECA — Sujet 1

Mercredi 28 octobre 2026

Le problème

Un client écrit à sa banque

« Je veux acheter un appartement. »
« J'ai perdu ma carte hier soir, je fais quoi ? »
« Pourquoi j'ai payé 8 € de frais ce mois-ci ? »

L'assistant doit **comprendre**, **poser les bonnes questions**, tenir compte de **la situation du client** et proposer une piste.

- Un Français sur quatre est client de La Banque Postale.
- L'expérience client est sa **priorité IA n° 1**.
- La règle : **open source, local**, le plus petit modèle qui suffit, frugalité **mesurée**.

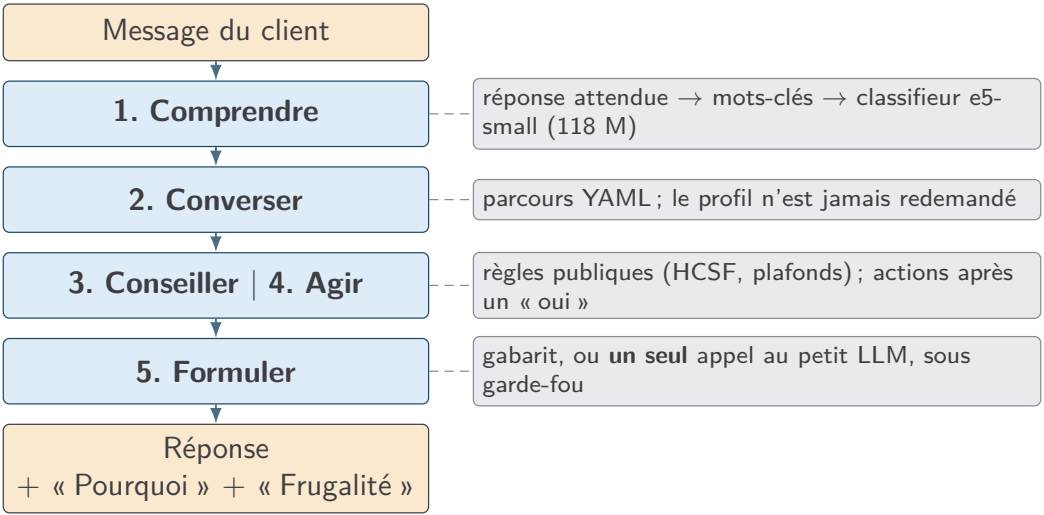
Notre démarche, en quatre temps

Yahya

Cadrer	Les 9 situations du sujet. Constat : Banking77 couvre le *service* (carte, frais, virements), pas le *conseil* (épargne, crédit, logement).
Préparer	**Banking77 n'est pas traduit** : un encodeur multilingue comprend le français. 8 intentions créées ; un test français écrit à la main ; la colonne `duration` de Bank Marketing exclue (fuite).
Concevoir	Une cascade : chaque étage ne passe la main que s'il ne sait pas faire.
Démontrer	Tests officiels, scénarios de bout en bout, comparaison avec une version « tout LLM », démo en direct.

L'architecture : une cascade

Yahya



Le moins cher d'abord

Yahya

Comprendre sans LLM

1. la réponse à la question en cours ;
2. les mots-clés, s'ils sont sûrs ;
3. le classifieur, au-dessus du seuil τ ;
4. sinon : une question au client, puis un conseiller.

Les messages incompris sont journalisés pour améliorer le système.

Décider sans LLM

Des règles que le client peut lire ; chaque conseil dit **pourquoi**, et **pourquoi pas**.

Le LLM : une fois, à la fin

Il met en mots des faits calculés. Le garde-fou refuse tout chiffre inventé ou oublié.

« Le vélo pour aller chercher le pain, la voiture pour le week-end. »

Démonstration en direct

Yahya pilote, Sohayb commente

Client	Message	Ce qu'on montre
Inès, 34 ans	« J'ai perdu ma carte »	Opposition après un « oui » ; aucun LLM
Léa, 31 ans	« Je veux acheter un appartement »	Revenus non redemandés ; 42,1 % $>$ 35 % ; « et avec 200 000 ? » recalculé
Sophie / Lucas	« Je voudrais mettre de côté »	Même phrase, deux clients, deux conseils
Marc, 52 ans	« Pourquoi 8 € de frais ? »	Historique, plafond légal, offre clientèle fragile
Julie	« Votre appli ne marche jamais ! »	Excuses, passage de main avec résumé
Paul, 68 ans	« Envoyer 500 € à mon fils »	Mots simples, pas à pas, confirmation

Démo de secours : 15 tours rejoués par le vrai pipeline, 0 appel au LLM, 2,5 ms par tour (gabarits, sur un portable).

Choisir le LLM en descendant en taille

Yahya

Seuil fixé avant de mesurer : **zéro chiffre inventé ni oublié** et **27 réponses sur 30** jugées bonnes. On garde **le plus petit** qui tient le seuil.

Banc en cours : résultats à venir.

Résultats : comprendre

Configuration	Test anglais	Test français	Latence	Taille
Référence : BERT affiné (article)	*93,7 %*	—	—	*1,4 Go*
Mots-clés (part acceptée)	—	*à mesurer*	< 1 ms	Ko
TF-IDF + régression logistique	*à mesurer*	*à mesurer*	*à mesurer*	Mo
e5-small + régression logistique	*à mesurer*	*à mesurer*	*à mesurer*	**0,47 Go**
LLM 14B, sans exemple	*à mesurer*	*à mesurer*	*à mesurer*	9,1 Go

L'écart anglais $\rightarrow$ français mesure ce que l'encodeur transfère **sans traduire**.

Résultats : frugalité

Configuration	Scénarios réussis	Wh / 1 000 req.	Go chargés	Sans LLM
A — un LLM 14B fait tout	*à mesurer*	*à mesurer*	9,1	0 %
B — notre cascade	*à mesurer*	*à mesurer*	3,5	*à mesurer*
C — cascade, gabarits seuls	9 / 9	*à mesurer*	0,5	100 %

Énergie : CodeCarbon hors ligne, par lots de 200 requêtes, puissance de repos soustraite.

Explicabilité : pourquoi, et pourquoi pas

Léa : 250 000 €, 25 000 € d'apport, 2 900 € nets.

- Mensualité $\approx$ 1 220 € sur 25 ans à 3,5 % (taux indicatif daté).
- **42,1 % > 35 %** : règle `HCSF-taux-effort`.
- Écarté : prêt sur 30 ans (`HCSF-duree`).
- Proposé : un bien autour de 212 000 €, et un conseiller.

Ce que voit le client

Les règles appliquées, les produits proposés *et écartés*, la source de chaque paramètre. Le calcul se vérifie à la main.

Confiance et conformité

Sohayb

- **Règlement européen sur l'IA** : la notation de solvabilité est à haut risque ; nous n'en faisons pas, un conseiller décide. Le client sait qu'il parle à une IA.
- **Mention légale** sur toute réponse de crédit ; aucune promesse.
- **Aucune action sans un « oui »** ; rappel : jamais de code confidentiel.
- **Données simulées, traitement local** : rien ne sort de la machine.
- **Inclusion** : mots simples, jargon expliqué, offre clientèle fragile.

Limites et suite

Ce qui est simulé

Profils et historiques (Bank Marketing enrichi), système bancaire, taux indicatifs.

Pour 17 000 bureaux

Coût par requête mesuré, donc extrapolable ; compréhension et règles sur CPU ; un serveur partagé pour le petit LLM ; voix locale et réponse dans la langue du client.

Merci

Notre assistant comprend avec de simples mots-clés ou un modèle de 118 millions de paramètres, décide avec des règles que le client peut lire, et n'appelle un LLM qu'une fois, à la fin, pour mettre en mots ce qui est déjà calculé.