# Un assistant bancaire frugal, explicable et prudent

## Un aiguilleur : à chaque message, le plus petit moyen qui suffit

Yahya Sohayb Younes

Hackathon IA — La Banque Postale × CGI × ENSEIRB-MATMECA — Sujet 1

Mercredi 28 octobre 2026

# Le problème



## Un client écrit à sa banque

« Je veux acheter un appartement. »
« J'ai perdu ma carte hier soir, je fais quoi ? »
« Pourquoi j'ai payé 8 € de frais ce mois-ci ? »

L'assistant doit **comprendre**, **poser les bonnes questions**, tenir compte de **la situation du client** et proposer une piste.

- Un Français sur quatre est client de La Banque Postale.
- L'expérience client est sa **priorité IA n° 1**.
- La règle : **open source, local**, le plus petit modèle qui suffit, frugalité **mesurée**.

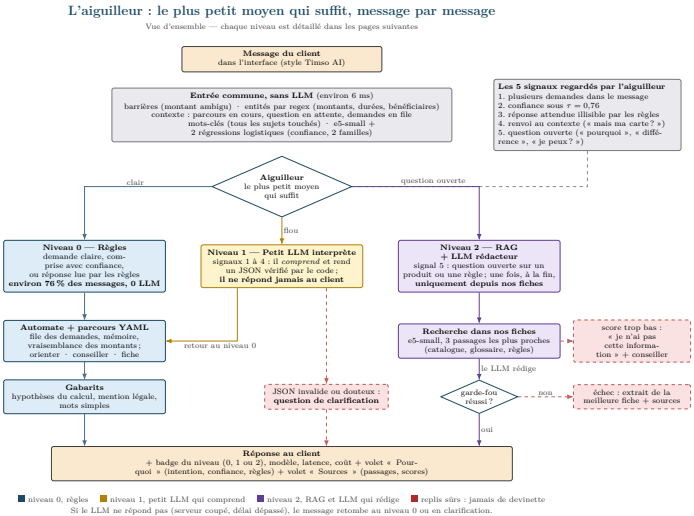
# Notre démarche, en quatre temps

Yahya

| | |
|---|---|
| **Cadrer** | Les 9 situations du sujet. Constat : Banking77 couvre le *service* (carte, frais, virements), pas le *conseil* (épargne, crédit, logement). |
| **Préparer** | **Banking77 n'est pas traduit** : un encodeur multilingue comprend le français. 8 intentions créées ; un test français écrit à la main ; la colonne `duration` de Bank Marketing exclue (fuite). |
| **Concevoir** | Une cascade : chaque étage ne passe la main que s'il ne sait pas faire. |
| **Démontrer** | Tests officiels, scénarios de bout en bout, comparaison avec une version « tout LLM », démo en direct. |

# L'architecture : un aiguilleur

Yahya



# Le plus petit moyen qui suffit, message par message

Yahya

| Niveau | Quand, et comment | Coût |
|---|---|---|
| **0 — règles** | Demande claire : mots-clés ou classifieur ($\geq \tau$), parcours YAML, règles publiques, gabarits. Plusieurs demandes : l'urgence d'abord. | 0 LLM |
| **1 — comprendre** | Message flou, réponse libre, renvoi au contexte : un **petit LLM** + **RAG d'exemples** rend un **JSON imposé par une grammaire**, vérifié par le code. Il ne répond jamais au client. | 1 appel |
| **2 — répondre** | Question ouverte : **RAG sur 37 fiches sourcées**, un LLM rédige en citant ; garde-fou (chiffres, fidélité), sinon l'extrait. | 1 appel |

La décision est prise **à chaque message** : une conversation passe de 1 à 2, puis à 0. La mémoire (parcours, demandes en file, informations données) est commune ; après une parenthèse, on reprend.

*« Le vélo pour aller chercher le pain, la voiture pour le week-end. »*

# Démonstration en direct

Yahya pilote, Sohayb commente

| Client | Message | Ce qu'on montre |
|---|---|---|
| Inès, 34 ans | « J'ai perdu ma carte et je veux faire un virement » | Niveau 0 : la carte d'abord, puis le virement |
| | « oui », « c'est pour mon papa » | Niveau 1 : le petit LLM comprend la réponse libre |
| | « Je peux retirer de mon PEL avant 4 ans ? » | Niveau 2 : réponse citée, puis « Revenons à votre virement » |
| | « 100000000 » | Montant invraisemblable, comparé au solde |
| Léa, 31 ans | Appartement, 250 000, puis « pourquoi ? » | $41{,}3\,\% > 35\,\%$ ; le niveau 2 explique le conseil |
| Sophie / Lucas | « Je voudrais mettre de côté » | Même phrase, deux clients, deux conseils |
| Marc, 52 ans | « Pourquoi 8 € de frais ? » | Cause fréquente, plafond légal, offre clientèle fragile |
| Paul, 68 ans | « Envoyer 500 € à mon fils » | Mots simples, automatiquement |

Interface web (style Timso AI) : badge de niveau, sources, coût de chaque réponse, chaîne des niveaux.

Secours : `?client=C01&rejouer` rejoue la démo, et le PDF de la démo de secours.

# Choisir le LLM de chaque niveau, en descendant en taille

Yahya

## Niveau 1 — comprendre (36 messages difficiles)

| Modèle | Taille | Justes, avec RAG d'exemples | sans | JSON valide | Latence p50 |
|---|---|---|---|---|---|
| `ministral-3:8b` | 6,0 Go | **31/36** | 31/36 | 100 % | 0,3 s |
| `gemma4:e2b` | 4,6 Go | **29/36** | 23/36 | 100 % | 0,2 s |
| `ministral-3:3b` | 3,0 Go | **33/36** | 31/36 | 100 % | 0,3 s |
| `qwen3:1.7b` (retenu) | 1,4 Go | **30/36** | 15/36 | 100 % | 0,2 s |
| `gemma3:1b` | 0,8 Go | **17/36** | 16/36 | 100 % | 0,5 s |

36 messages difficiles écrits par l'équipe (réponses libres, demandes mêlées, renvois au contexte). JSON imposé par une grammaire. Mesuré sur DeepEirb, RTX 6000 Ada 48 Go.

## Niveau 2 — répondre en citant (22 questions)

| Rédaction | Garde-fou réussi | Réponses justes | Latence p50 | Tokens |
|---|---|---|---|---|
| *sans LLM (extrait)* | — | 21/22 | 0,0 s | 0 |
| `ministral-3:8b` | 4/18 | 21/22 | 0,7 s | 329 |
| `gemma4:e2b` | 9/18 | 21/22 | 0,3 s | 343 |
| `ministral-3:3b` | 3/18 | 21/22 | 0,5 s | 335 |
| `qwen3:1.7b` (retenu) | 9/18 | 22/22 | 0,4 s | 381 |
| `gemma3:1b` | 1/18 | 21/22 | 0,4 s | 355 |

Recherche (e5-small, 37 fiches) : bonne fiche parmi les 3 passages pour 18/18 questions ; 4/4 questions hors de nos fiches refusées. Mesuré sur DeepEirb, RTX 6000 Ada 48 Go.

**Retenu : `qwen3:1.7b` (1,4 Go) pour les deux niveaux**, le plus petit qui tient chacun ; un seul modèle chargé. Le RAG d'exemples double sa justesse (15 → 30). Plus gros n'est pas plus fidèle.

# Résultats : comprendre

Younes

| Configuration | Anglais (intention, 77) | Français (routage) | Latence p50 | Taille |
|---|---|---|---|---|
| *Référence : BERT affiné (article)* | *93,7 %* | — | — | *0,44 Go* |
| Mots-clés | — | 19,2 % acceptés, 100,0 % justes | $<$ 0,1 ms | 2 Ko |
| TF-IDF + rég. logistique | 89,2 % | 66,8 % | 0,3 ms | 3,9 Mo |
| **e5-small + rég. logistique** | **92,3 %** | **84,8 %** | 6,3 ms | 470,8 Mo |
| **Étage 1** : mots-clés puis e5 ($\tau$) | — | 76,4 % compris, 96,9 % justes | 6,1 ms | — |
| `ministral-3:14b` seul | famille 52,9 % | 83,2 % | 77,6 ms | 9,10 Go |
| `qwen3:1.7b` seul | famille 6,8 % | 29,2 % | 17,7 ms | 1,40 Go |

Test anglais : 3 080 phrases Banking77 ; test français : 250 phrases écrites par l'équipe, jamais vues à l'entraînement. Routage : bonne famille pour une demande de service, bonne intention pour nos parcours. Mesuré sur DeepEirb, RTX 6000 Ada 48 Go.

Entraîné sur Banking77 **en anglais, sans traduction** : l'encodeur multilingue transfère au français. Sous $\tau$, une question fermée ; jamais de devinette.

# Résultats : frugalité



| Configuration | Scénarios | Wh / 1 000 req. | Latence p95 | Go | Sans LLM |
|---|---|---|---|---|---|
| A — un LLM fait tout (`ministral-3:14b`) | à juger | 115,41 | 2299 ms | 9,1 | 0 % |
| **B — notre aiguilleur (niveaux 0, 1, 2)** (`qwen3:1.7b`) | 15 / 15 | 5,53 | 527 ms | 1,9 | 76 % |
| C — niveau 0 seul (règles, sans LLM) | 15 / 15 | 0,178 | 19 ms | 0,5 | 100 % |

Énergie : CodeCarbon hors ligne, lots de 200 requêtes × 3 (A : 40 × 1) après chauffe, puissance de repos soustraite. Mesuré sur DeepEirb, RTX 6000 Ada 48 Go. Aiguilleur : niveau 0 : 76 %, niveau 1 : 12 %, niveau 2 : 12 % des messages.

Notre aiguilleur réussit les 15 scénarios avec **17 fois moins d'énergie** que le 14B qui fait tout (11,5 contre 194 Wh pour 1 000 messages, sans même soustraire le repos), 5 fois moins de mémoire et une latence p95 de 0,5 s au lieu de 2,3 s : 76 % des messages n'appellent aucun LLM.

# Explicabilité : pourquoi, et pourquoi pas

Sohayb

**Léa** : 250 000 €, 25 000 € d'apport, 2 900 € nets.

- Mensualité $\approx$ 1 197 € sur 25 ans à 3,32 % (taux moyen Banque de France, daté), hors assurance.
- **41,3 % $>$ 35 %** : règle `HCSF-taux-effort` ; non retenu, sans refus bancaire.
- Écarté : prêt sur 30 ans (`HCSF-duree`).
- Budget indicatif $\approx$ 215 000 € ; à 200 000 €, 32,2 % : un conseiller étudie.

## Ce que voit le client

Les règles appliquées, les produits proposés *et écartés*, la source de chaque paramètre. Le calcul se vérifie à la main.

# Confiance et conformité



- **Règlement européen sur l'IA** : la notation de solvabilité est à haut risque ; nous n'en faisons pas, un conseiller décide. Le client sait qu'il parle à une IA.
- **Mention légale** sur toute réponse de crédit ; aucune promesse.
- **Aucun accès au compte, aucune opération** (périmètre du kick-off) : l'assistant explique et oriente ; rappel : jamais de code confidentiel.
- **LLM encadrés** : au niveau 1, il ne voit pas le profil et ne répond pas ; au niveau 2, il ne répond qu'à partir de fiches sourcées, sinon « je n'ai pas cette information ».
- **Données simulées, traitement local** : rien ne sort de la machine.
- **Inclusion** : mots simples, jargon expliqué, offre clientèle fragile.

# Limites et suite



## Ce qui est simulé

Profils et historiques (Bank Marketing enrichi), système bancaire, taux indicatifs.

## Pour 17 000 bureaux

Coût par requête mesuré, donc extrapolable ; compréhension et règles sur CPU ; un serveur partagé pour le petit LLM ; voix locale et réponse dans la langue du client.

# Merci

*Notre assistant comprend avec de simples mots-clés ou un modèle de 118 millions de paramètres, décide avec des règles que le client peut lire, et n'appelle un petit LLM qu'à un instant précis : pour comprendre un message flou, ou répondre en citant nos fiches.*