Un assistant bancaire frugal, explicable et prudent

Comprendre, personnaliser, conseiller — avec le plus petit calcul qui suffit

Yahya Sohayb Younes

Hackathon IA — La Banque Postale × CGI × ENSEIRB-MATMECA — Sujet 1

Mercredi 28 octobre 2026

Le problème

Un client écrit à sa banque

« Je veux acheter un appartement. »
« J'ai perdu ma carte hier soir, je fais quoi ? »
« Pourquoi j'ai payé 8 € de frais ce mois-ci ? »

L'assistant doit **comprendre**, **poser les bonnes questions**, tenir compte de **la situation du client** et proposer une piste.

- Un Français sur quatre est client de La Banque Postale.
- L'expérience client est sa **priorité IA n° 1**.
- La règle : **open source, local**, le plus petit modèle qui suffit, frugalité **mesurée**.

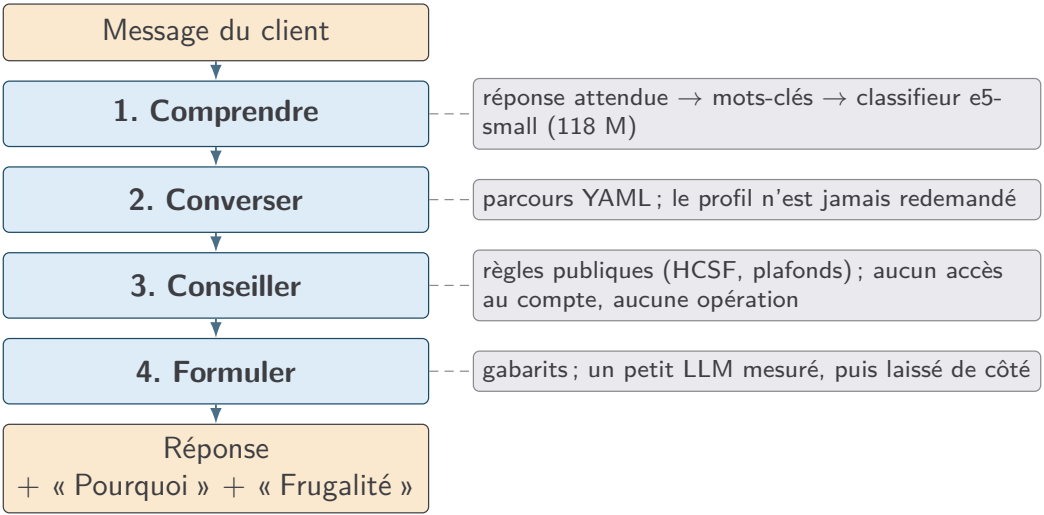
Notre démarche, en quatre temps

Yahya

Cadrer	Les 9 situations du sujet. Constat : Banking77 couvre le *service* (carte, frais, virements), pas le *conseil* (épargne, crédit, logement).
Préparer	**Banking77 n'est pas traduit** : un encodeur multilingue comprend le français. 8 intentions créées ; un test français écrit à la main ; la colonne `duration` de Bank Marketing exclue (fuite).
Concevoir	Une cascade : chaque étage ne passe la main que s'il ne sait pas faire.
Démontrer	Tests officiels, scénarios de bout en bout, comparaison avec une version « tout LLM », démo en direct.

L'architecture : une cascade

Yahya



Le moins cher d'abord

Yahya

Comprendre sans LLM

1. la réponse à la question en cours ;
2. les mots-clés, s'ils sont sûrs ;
3. le classifieur, au-dessus du seuil τ ;
4. sinon : une question au client, puis un conseiller.

Les messages incompris sont journalisés pour améliorer le système.

Décider sans LLM

Des règles que le client peut lire ; chaque conseil dit **pourquoi**, et **pourquoi pas**.

Le LLM : mesuré, pas indispensable

Six LLM essayés pour reformuler des faits calculés, sous garde-fou. Aucun n'apporte assez : les gabarits suffisent.

« Le vélo pour aller chercher le pain, la voiture pour le week-end. »

Démonstration en direct

Yahya pilote, Sohayb commente

Client	Message	Ce qu'on montre
Inès, 34 ans	« J'ai perdu ma carte »	Guidée vers l'opposition, sans accès au compte
Inès	« Ma carte ne marche plus au distributeur »	Pas de mot-clé : le classifieur comprend, sans traduction
Léa, 31 ans	« Je veux acheter un appartement »	Revenus non redemandés ; 41,3 % > 35 % ; « et avec 200 000 ? » : 32,2 %
Sophie / Lucas	« Je voudrais mettre de côté »	Même phrase, deux clients, deux conseils
Marc, 52 ans	« Pourquoi 8 € de frais ? »	Cause fréquente, plafond légal, offre clientèle fragile
Julie	« Votre appli ne marche jamais ! »	Excuses ; conseiller, réclamation, médiateur
Paul, 68 ans	« Envoyer 500 € à mon fils »	Mots simples, automatiquement ; guidé vers son espace

Démo de secours : 13 tours rejoués par le vrai pipeline, 0 appel au LLM, environ 6 ms par tour (sur un portable).

Choisir le LLM en descendant en taille

Yahya

Seuil fixé avant de mesurer : **zéro chiffre inventé ni oublié** et **27 réponses sur 30** jugées bonnes. On garde **le plus petit** qui tient le seuil.

Modèle	Taille	Garde-fou	Juges	Latence p50	Tokens
`ministral-3:14b`	9,1 Go	23/30	*à juger*	2,6 s	483
`ministral-3:8b`	6,0 Go	27/30	*à juger*	1,9 s	478
`gemma4:e2b`	4,6 Go	27/30	*à juger*	0,6 s	449
`ministral-3:3b`	3,0 Go	22/30	*à juger*	0,8 s	461
`qwen3:1.7b`	1,4 Go	30/30	*à juger*	0,6 s	484
`gemma3:1b`	0,8 Go	25/30	*à juger*	0,4 s	419

Mesuré sur DeepEirb, RTX 6000 Ada 48 Go. Garde-fou : aucun chiffre inventé ni oublié, longueur plausible.

Les plus gros touchent aux chiffres (14B : 23/30). `qwen3:1.7b` les respecte, mais efface parfois une phrase qui compte (« aucun refus bancaire ») : 13 scénarios sur 14. **Décision : les gabarits suffisent, le LLM reste désactivé.**

Résultats : comprendre

Younes

Configuration	Anglais (intention, 77)	Français (routage)	Latence p50	Taille
Référence : BERT affiné (article)	*93,7 %*	—	—	*0,44 Go*
Mots-clés	—	19,2 % acceptés, 100,0 % justes	$<$ 0,1 ms	2 Ko
TF-IDF + rég. logistique	89,2 %	66,8 %	0,3 ms	3,9 Mo
e5-small + rég. logistique	**92,3 %**	**84,8 %**	6,3 ms	470,8 Mo
Étage 1 : mots-clés puis e5 (τ)	—	76,4 % compris, 96,9 % justes	6,1 ms	—
`ministral-3:14b` seul	famille 52,9 %	83,2 %	77,6 ms	9,10 Go
`qwen3:1.7b` seul	famille 6,8 %	29,2 %	17,7 ms	1,40 Go

Test anglais : 3 080 phrases Banking77 ; test français : 250 phrases écrites par l'équipe, jamais vues à l'entraînement. Routage : bonne famille pour une demande de service, bonne intention pour nos parcours. Mesuré sur DeepEirb, RTX 6000 Ada 48 Go.

Entraîné sur Banking77 **en anglais, sans traduction** : l'encodeur multilingue transfère au français. Sous τ, une question fermée ; jamais de devinette.

Résultats : frugalité

Configuration	Scénarios	Wh / 1 000 req.	Latence p95	Go	Sans LLM
A — un LLM fait tout (`ministral-3:14b`)	à juger	109,30	2020 ms	9,1	0 %
B — cascade + petit LLM (`qwen3:1.7b`)	13 / 14	6,22	581 ms	1,9	74 %
C — notre cascade, sans LLM	14 / 14	0,004	6 ms	0,5	100 %

Énergie : CodeCarbon hors ligne, lots de 200 requêtes × 3 (A : 40 × 1) après chauffe, puissance de repos soustraite. Mesuré sur DeepEirb, RTX 6000 Ada 48 Go.

Sans LLM, la cascade réussit tous les scénarios avec **plus de 3 000 fois moins d'énergie** que le 14B qui fait tout, même sans soustraire le repos (0,04 contre 155 Wh pour 1 000 requêtes).

Explicabilité : pourquoi, et pourquoi pas

Sohayb

Léa : 250 000 €, 25 000 € d'apport, 2 900 € nets.

- Mensualité $\approx$ 1 197 € sur 25 ans à 3,32 % (taux moyen Banque de France, daté), hors assurance.
- **41,3 % $>$ 35 %** : règle `HCSF-taux-effort` ; non retenu, sans refus bancaire.
- Écarté : prêt sur 30 ans (`HCSF-duree`).
- Budget indicatif $\approx$ 215 000 € ; à 200 000 €, 32,2 % : un conseiller étudie.

Ce que voit le client

Les règles appliquées, les produits proposés *et écartés*, la source de chaque paramètre. Le calcul se vérifie à la main.

Confiance et conformité

- **Règlement européen sur l'IA** : la notation de solvabilité est à haut risque ; nous n'en faisons pas, un conseiller décide. Le client sait qu'il parle à une IA.
- **Mention légale** sur toute réponse de crédit ; aucune promesse.
- **Aucun accès au compte, aucune opération** (périmètre du kick-off) : l'assistant explique et oriente ; rappel : jamais de code confidentiel.
- **Données simulées, traitement local** : rien ne sort de la machine.
- **Inclusion** : mots simples, jargon expliqué, offre clientèle fragile.

Limites et suite

Ce qui est simulé

Profils et historiques (Bank Marketing enrichi), système bancaire, taux indicatifs.

Pour 17 000 bureaux

Coût par requête mesuré, donc extrapolable ; compréhension et règles sur CPU ; un serveur partagé pour le petit LLM ; voix locale et réponse dans la langue du client.

Merci

Notre assistant comprend avec de simples mots-clés ou un modèle de 118 millions de paramètres, décide avec des règles que le client peut lire, et répond sans LLM : nous en avons mesuré six, aucun n'apportait assez pour son coût.