Un assistant bancaire frugal, explicable et prudent

Un aiguilleur : à chaque message, le plus petit moyen qui suffit

Yahya Sohayb Younes

Hackathon IA — La Banque Postale × CGI × ENSEIRB-MATMECA — Sujet 1

Mercredi 28 octobre 2026

Le problème

Un client écrit à sa banque

« Je veux acheter un appartement. »
« J'ai perdu ma carte hier soir, je fais quoi ? »
« Pourquoi j'ai payé 8 € de frais ce mois-ci ? »

L'assistant doit **comprendre**, **poser les bonnes questions**, tenir compte de **la situation du client** et proposer une piste.

- Un Français sur quatre est client de La Banque Postale.
- L'expérience client est sa **priorité IA n° 1**.
- La règle : **open source, local**, le plus petit modèle qui suffit, frugalité **mesurée**.

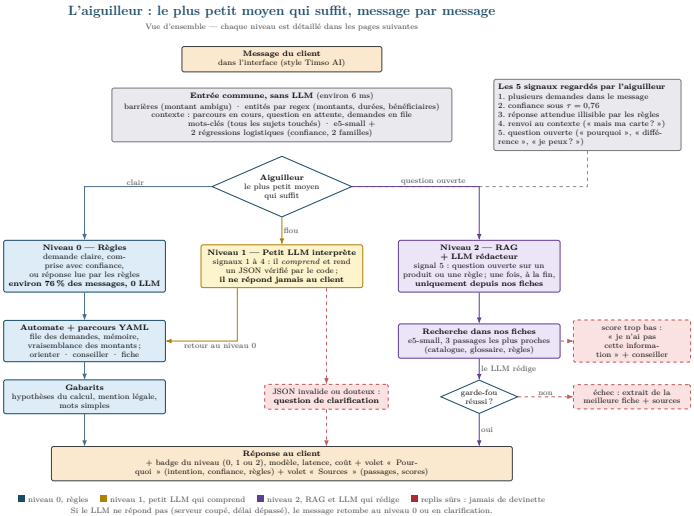
Notre démarche, en quatre temps

Yahya

Cadrer	Les 9 situations du sujet. Constat : Banking77 couvre le *service* (carte, frais, virements), pas le *conseil* (épargne, crédit, logement).
Préparer	**Banking77 n'est pas traduit** : un encodeur multilingue comprend le français. 8 intentions créées ; un test français écrit à la main ; la colonne `duration` de Bank Marketing exclue (fuite).
Concevoir	Une cascade : chaque étage ne passe la main que s'il ne sait pas faire.
Démontrer	Tests officiels, scénarios de bout en bout, comparaison avec une version « tout LLM », démo en direct.

L'architecture : un aiguilleur

Yahya



Le plus petit moyen qui suffit, message par message

Yahya

Niveau	Quand, et comment	Coût
0 — règles	Demande claire : mots-clés ou classifieur ($\geq \tau$), parcours YAML, règles publiques, gabarits. Plusieurs demandes : l'urgence d'abord.	0 LLM
1 — comprendre	Message flou, réponse libre, renvoi au contexte : un **petit LLM** + **RAG d'exemples** rend un **JSON imposé par une grammaire**, vérifié par le code. Il ne répond jamais au client.	1 appel
2 — répondre	Question ouverte : **RAG sur 37 fiches sourcées**, un LLM rédige en citant ; garde-fou (chiffres, fidélité), sinon l'extrait.	1 appel

La décision est prise **à chaque message** : une conversation passe de 1 à 2, puis à 0. La mémoire (parcours, demandes en file, informations données) est commune ; après une parenthèse, on reprend.

« Le vélo pour aller chercher le pain, la voiture pour le week-end. »

Démonstration en direct

Yahya pilote, Sohayb commente

Client	Message	Ce qu'on montre
Inès, 34 ans	« J'ai perdu ma carte et je veux faire un virement »	Niveau 0 : la carte d'abord, puis le virement
	« oui », « c'est pour mon papa »	Niveau 1 : le petit LLM comprend la réponse libre
	« Je peux retirer de mon PEL avant 4 ans ? »	Niveau 2 : réponse citée, puis « Revenons à votre virement »
	« 100000000 »	Montant invraisemblable, comparé au solde
Léa, 31 ans	Appartement, 250 000, puis « pourquoi ? »	$41{,}3\,\% > 35\,\%$; le niveau 2 explique le conseil
Sophie / Lucas	« Je voudrais mettre de côté »	Même phrase, deux clients, deux conseils
Marc, 52 ans	« Pourquoi 8 € de frais ? »	Cause fréquente, plafond légal, offre clientèle fragile
Paul, 68 ans	« Envoyer 500 € à mon fils »	Mots simples, automatiquement

Interface web (style Timso AI) : badge de niveau, sources, coût de chaque réponse, chaîne des niveaux.

Secours : `?client=C01&rejouer` rejoue la démo, et le PDF de la démo de secours.

Choisir le LLM de chaque niveau, en descendant en taille

Yahya

Niveau 1 — comprendre (36 messages difficiles)

Modèle	RAG d'exemples	Justes	JSON valide	Latence p50	Tokens
`qwen3:1.7b`	oui	28/36	100 %	2,7 s	597
`qwen3:1.7b`	non	15/36	100 %	1,7 s	434

36 messages difficiles écrits par l'équipe (réponses libres, demandes mêlées, renvois au contexte). JSON imposé par une grammaire. Mesuré sur portable (CPU, essai avant DeepEirb).

Niveau 2 — répondre en citant (22 questions)

Rédaction	Garde-fou réussi	Réponses justes	Latence p50	Tokens
sans LLM (extrait)	—	21/22	0,0 s	0
`qwen3:1.7b`	13/18	22/22	2,6 s	369

Recherche (e5-small, 37 fiches) : bonne fiche parmi les 3 passages pour 18/18 questions ; 4/4 questions hors de nos fiches refusées. Mesuré sur portable (CPU, essai avant DeepEirb).

On garde **le plus petit** modèle qui tient chaque niveau. Le RAG d'exemples fait plus que doubler la justesse du niveau 1. Déjà appris : *reformuler* un conseil chiffré n'apporte rien (les gros modèles touchent aux chiffres) ; le LLM sert à *comprendre* et à *répondre aux questions ouvertes*.

Résultats : comprendre

Younes

Configuration	Anglais (intention, 77)	Français (routage)	Latence p50	Taille
Référence : BERT affiné (article)	*93,7 %*	—	—	*0,44 Go*
Mots-clés	—	19,2 % acceptés, 100,0 % justes	$<$ 0,1 ms	2 Ko
TF-IDF + rég. logistique	89,2 %	66,8 %	0,3 ms	3,9 Mo
e5-small + rég. logistique	**92,3 %**	**84,8 %**	6,3 ms	470,8 Mo
Étage 1 : mots-clés puis e5 (τ)	—	76,4 % compris, 96,9 % justes	6,1 ms	—
`ministral-3:14b` seul	famille 52,9 %	83,2 %	77,6 ms	9,10 Go
`qwen3:1.7b` seul	famille 6,8 %	29,2 %	17,7 ms	1,40 Go

Test anglais : 3 080 phrases Banking77 ; test français : 250 phrases écrites par l'équipe, jamais vues à l'entraînement. Routage : bonne famille pour une demande de service, bonne intention pour nos parcours. Mesuré sur DeepEirb, RTX 6000 Ada 48 Go.

Entraîné sur Banking77 **en anglais, sans traduction** : l'encodeur multilingue transfère au français. Sous τ, une question fermée ; jamais de devinette.

Résultats : frugalité

Configuration	Scénarios	Wh / 1 000 req.	Latence p95	Go	Sans LLM
A — un LLM fait tout (`ministral-3:14b`)	à juger	109,30	2020 ms	9,1	0 %
B — notre aiguilleur (niveaux 0, 1, 2)	*à mesurer*	*à mesurer*	*à mesurer*	—	—
C — niveau 0 seul (règles, sans LLM)	14 / 14	0,004	6 ms	0,5	100 %

Énergie : CodeCarbon hors ligne, lots de 200 requêtes × 3 (A : 40 × 1) après chauffe, puissance de repos soustraite. Mesuré sur DeepEirb, RTX 6000 Ada 48 Go.

Le niveau 0 seul réussit tous les scénarios avec **plus de 3 000 fois moins d'énergie** que le 14B qui fait tout (0,04 contre 155 Wh pour 1 000 requêtes, sans même soustraire le repos). L'aiguilleur n'ajoute un petit LLM qu'aux messages qui en ont besoin.

Explicabilité : pourquoi, et pourquoi pas

Sohayb

Léa : 250 000 €, 25 000 € d'apport, 2 900 € nets.

- Mensualité $\approx$ 1 197 € sur 25 ans à 3,32 % (taux moyen Banque de France, daté), hors assurance.
- **41,3 % $>$ 35 %** : règle `HCSF-taux-effort` ; non retenu, sans refus bancaire.
- Écarté : prêt sur 30 ans (`HCSF-duree`).
- Budget indicatif $\approx$ 215 000 € ; à 200 000 €, 32,2 % : un conseiller étudie.

Ce que voit le client

Les règles appliquées, les produits proposés *et écartés*, la source de chaque paramètre. Le calcul se vérifie à la main.

Confiance et conformité

- **Règlement européen sur l'IA** : la notation de solvabilité est à haut risque ; nous n'en faisons pas, un conseiller décide. Le client sait qu'il parle à une IA.
- **Mention légale** sur toute réponse de crédit ; aucune promesse.
- **Aucun accès au compte, aucune opération** (périmètre du kick-off) : l'assistant explique et oriente ; rappel : jamais de code confidentiel.
- **LLM encadrés** : au niveau 1, il ne voit pas le profil et ne répond pas ; au niveau 2, il ne répond qu'à partir de fiches sourcées, sinon « je n'ai pas cette information ».
- **Données simulées, traitement local** : rien ne sort de la machine.
- **Inclusion** : mots simples, jargon expliqué, offre clientèle fragile.

Limites et suite

Ce qui est simulé

Profils et historiques (Bank Marketing enrichi), système bancaire, taux indicatifs.

Pour 17 000 bureaux

Coût par requête mesuré, donc extrapolable ; compréhension et règles sur CPU ; un serveur partagé pour le petit LLM ; voix locale et réponse dans la langue du client.

Merci

Notre assistant comprend avec de simples mots-clés ou un modèle de 118 millions de paramètres, décide avec des règles que le client peut lire, et n'appelle un petit LLM qu'à un instant précis : pour comprendre un message flou, ou répondre en citant nos fiches.